Работу выполнили Жилин Андрей Игоревич и Зимин Андрей Валерьевич

Подготовка окружения

Импорт необходимых библиотек

In [5]:
```
import math

import pandas as pd
import numpy as np
import datetime
from matplotlib import pyplot as plt

import matplotlib.patches as mpatches

from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
##from mpl_toolkits import mplot3d
##import seaborn as sns
from sklearn.model_selection import train_test_split
```

Чтение Датасета

In [6]:
```
df = pd.read_csv("data/iris.csv")
df.head()
```

Out[6]:

	sepal_length	sepal_width	petal_length	petal_width	variety
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

1 и 2 Задания

Текст заданий

Текст заданий

1 Следует привести задачу классификации к бинарной. Т.е. рассматриваем ирисы 2-х классов: Setosa и non-Setosa.

2 Из признаков оставляем только 2: sepal length и sepal width.

Небольшие пояснения

Оставляем признаки "sepal_length" и "sepal_width", а также выделяем variety в отдельный dataframe. Класс iris-setosa помечаем 1, остальные классы помечаем -1.

In [7]:
```
y = pd.DataFrame()
X = df[["sepal_length", "sepal_width"]].to_numpy() #отбираем нужные признаки
y['variety'] = df["variety"].apply(lambda x: int(x == "Iris-setosa") - int(x != "Iris-setosa")) #функция для 1 и -1
y = y[['variety']].to_numpy() #переводим в numpy так как наш градиентный спуск работает с нампаем

print("Матрица признаков объектов:")
print(X[:10])
print("\nМатрица-столбец меток классов:")
print(y[45:55])
```

```
Матрица признаков объектов:
[[5.1 3.5]
 [4.9 3. ]
 [4.7 3.2]
 [4.6 3.1]
 [5.  3.6]
 [5.4 3.9]
 [4.6 3.4]
 [5.  3.4]
 [4.4 2.9]
 [4.9 3.1]]

Матрица-столбец меток классов:
[[ 1]
 [ 1]
 [ 1]
 [ 1]
 [ 1]
 [-1]
 [-1]
 [-1]
 [-1]
 [-1]]
```

Выводы по первому и второму заданию

Импортировали данные и убедились в их корректности. Данные нам известные и хорошо знакомые.

Подготовка перед выполнением третьего задания

Наш градиентный спуск

Наша реализация градиентного спуска с комментариями, взято из предыдущей лабораторной работы.

In [8]:
```
class GradientDescent:
    def __init__(self, train_x, train_y, h = 0.00005, eps=0.1, start_weights=None, logging=False, min_iterations=0, strategy="packag
        np.random.seed(seed)
        #часть за данные
        self.X = train_x #тренировочная выборка
        self.y = train_y #целевой признак
        self.strategy = strategy #название стратегии(package, mini-batch или stochastic)

        #метаданные
        self.width = len(train_x[0]) + 1 #ширина тренировочной выборки
        self.height = len(train_x) #высота тренировочной выборки

        #модель
        self.batch_size = batch_size
        self.min_iterations = min_iterations
        self.h = h #шаг градиентного спуска h > 0
        self.lambda_ = lambda_ #коэффициент регуляризации
        self.eps = eps #точность градиентного спуска
        self.strategies = {'package': self.step_package, 'mini-batch': self.step_mini_batch, 'stochastic': self.step_mini_batch}
        if strategy == 'stochastic':
            self.batch_size = 1
        if start_weights is None: #задание стартовых весов
            self.w = np.full(self.width, 1)
        else:
            self.w = start_weights

        self.X = np.concatenate((np.ones(self.height).reshape(-1, 1), self.X), axis=1) #фиктивная единица
        self.q = self.calc_q() # инициализируем ошибку

        #логи
        self.logging = logging #вывод логов в консоль
        self.qs = np.array([]) #величина ошибки
        self.curr_timer = None #текущий таймер
        self.timer = np.array([]) #массив для хранения время итераций
        self.iter_num = 0 #количество итераций


    def start_timer(self): #засечь время
        self.curr_timer = datetime.datetime.now()

    def stop_timer(self): #становить и записать время
        self.timer = np.append(self.timer, np.array(datetime.datetime.now() - self.curr_timer))

    def get_time(self): #общее время выполнения программы
        return self.timer.sum()

    def get_times(self): #получить время по шагам
        return self.timer

    def step_package(self): #шаг пакетного градиентного спуска

        self.w = self.w - self.h * self.grad()  #вычисляем градиент по пакету и меняем веса


    def step_mini_batch(self): #шаг стохастического градиентного спуска или mini-batch зависит от размера пакета

        idx = np.random.randint(self.height, size=self.batch_size) # формируем индексы пакета
```

```
        self.w = self.w - self.h * self.grad(self.X[idx, :], self.y[idx, :]) #вычисляем градиент по пакету и меняем веса


    def grad(self, X = None, y = None): #вычисление градиента по пакету(подходит для mini-batch, package и stochastic)
        if X is None or y is None or np.size(X)==0 or np.size(y)==0:
            X = self.X
            y = self.y

        return (X.T.dot(X.dot(self.w) - y[:, 0]))*(2/self.height)

    def fit(self): #запуск градиентного спуска

        q = 2*self.q

        if self.logging:
            print("Величина ошибки на каждом шаге")

        while abs(self.q - q) > self.eps or self.iter_num < self.min_iterations:
            self.start_timer()
            q = self.q #переприсваеваем значение ошибки
            self.strategies[self.strategy]()
            self.qs = np.append(self.qs, q) #запоминаем значение ошибки
            self.q = self.calc_q() #вычисление значение ошибки после новых весов
            self.iter_num += 1
            self.stop_timer()
            if self.logging:
                print(f"Шаг {self.iter_num}: ошибка {round(self.q, int(np.log(1/self.eps)/np.log(10)))};") #логи
        if self.logging:
            print(f"Время работы: {self.get_time().microseconds/1000:.02f} мс")
        return self.w


    def calc_q(self):

        return np.mean((np.dot(self.X, self.w) - self.y[:, 0]) ** 2) #вычисление ошибки

    def predict(self, X):
        X =  np.concatenate((np.ones(len(X)).reshape(-1, 1), X), axis=1) #фиктивная единица
        return np.dot(X, self.w).reshape(-1, 1) #предсказание
```

Наш метод опорных векторов

Реализация нашего метода опорных векторов

Класс метода опорных векторов наследуется от градиентного спуска, так как для оптимизации будет использоваться градиентный спуск. Переопределим градиент, функцию вычисления ошибки и предсказания.

В SVM в качестве оптимальной разделяющей прямой мы принимаем такую разделяющую прямую, которая максимально удалена от отбоих классов (имеет максимальный отступ). Для поиска такой прямой будем использовать функцию потерь Hingle Loss

$$L(w, x, y) = \lambda ||w||_2^2 + \sum_i^n max(0, 1 - y_i\langle w, x_i\rangle)$$

Где λ - коэффициент регуляризации (необязателен). Тогда градиент функции потерь будет иметь вид:

$$\nabla_w L(y, X, w) = 2\lambda w + \sum_i^n \begin{cases} 0, \text{при } 1 - y_i\langle w, x_i\rangle \leq 0 \\ -y_i * x_i, \text{при } 1 - y_i\langle w, x_i\rangle > 0 \end{cases}$$

In [9]:
```
class SupportVectorMachine(GradientDescent):#наследуемся от градиентного спуска

    def grad(self, X = None, y = None): #переопределяем вычисление градиента для нового класса svm
        if X is None or y is None or np.size(X)==0 or np.size(y)==0:
            X = self.X
            y = self.y

        # Создаем булеву маску для объектов
        margins = 1 - y[:, 0] * np.dot(X, self.w)
        mask = margins > 0
        # Вычисляем градиент, используя булеву маску
        grad = -np.sum(y[mask, :] * X[mask], axis=0)
        # Добавляем коэффициент регуляризации
        return 2 * self.lambda_ * self.w  + grad

    def calc_q(self): #переопределяем функцию ошибки
        loss_result = self.lambda_*((self.w**2).sum())
        for i in range(self.height):
            loss_result += max(np.array([0.0]), 1 - self.y[i]*np.dot(self.w, self.X[i, :])) #линейное ядро
        return loss_result

    def predict(self, X): #переопределяем функцию предсказания
        X =  np.concatenate((np.ones(len(X)).reshape(-1, 1), X), axis=1) #фиктивная единица
        return np.sign(np.dot(X, self.w).reshape(-1, 1)) #предсказание
```

Наш класс для вычисления метрик

Повторение одних и тех же действий не очень полезно, особенно в программировании, потому необходимые вычисления метрик были вынесены в отдельный класс и будут вызываться как понадобится

Отдельно можно обратить внимание на метод get_hyper_p_2_params, здесь мы получаем уравнение двумерной гиперплоскости выражая один вес через другой, можно его расширить для больших размерностей, но пока задача для двумерного аффинного пространства

Приведем простой вывод формулы гиперплоскости

Гиперплоскость в общем виде
$w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = 0$
$w_nx_n = -(w_0 + w_1x_1 + w_2x_2 + \dots + w_{n-1}x_{n-1})$
$x_n = -\frac{w_0 + w_1x_1 + w_2x_2 + \dots + w_{n-1}x_{n-1}}{w_n}$
Теперь x_n можно переобозначить как $f(x_1, x_2, \dots, x_{n-1})$
$f(x_1, x_2, \dots, x_{n-1}) = -\frac{w_0 + w_1x_1 + w_2x_2 + \dots + w_{n-1}x_{n-1}}{w_n}$

Вот мы и получили уравнение гиперплоскости

In [10]:
```
class Counter:
    def __init__(self, X_train, X_test, y_train, y_test, model):
        self.X_train = X_train
        self.X_test = X_test
        self.y_train = y_train
        self.y_test = y_test
        self.y_pred_train = model.predict(self.X_train)
        self.y_pred_test = model.predict(self.X_test)
        self.model = model
    def plot_confusion_matrix(self, y, y_pred, label): #построение матрицы
        cm = confusion_matrix(y, y_pred)
        print('Матрица ошибок, полученная методом confusion_matrix\n', cm)

        ConfusionMatrixDisplay.from_predictions(y, y_pred)

        plt.title(f'Матрица ошибок для {label}')
        plt.show()

    def calc_metrics(self, y, y_pred): #расчет всех метрик для классификации
        acc = accuracy_score(y, y_pred)
        pre = precision_score(y, y_pred)
        rec = recall_score(y, y_pred)
        f1 = f1_score(y, y_pred)
        print(f"accuracy: {acc:.03f}")
        print(f"precision: {pre:.03f}")
        print(f"recall: {rec:.03f}")
        print(f"f1: {f1:.03f}")


    def try_model(self): #построение confusion matrix и расчет метрик на тестовой и тренировочной выборках
        self.y_pred_train = self.model.predict(self.X_train)
        self.y_pred_test = self.model.predict(self.X_test)
        print("Метрики для тренировочной выборки")
        self.calc_metrics(self.y_train, self.y_pred_train)
        print()
        print('Метрики для тестовой выборки')
        self.calc_metrics(self.y_test, self.y_pred_test)
        self.plot_confusion_matrix(self.y_train, self.y_pred_train, 'тренировочной выборки')
        self.plot_confusion_matrix(self.y_test, self.y_pred_test, 'тестовой')
```

Задание 3

Текст задания

Выполните процедуру классификации 3 раза. В рамках данной процедуры:

- Разбейте выборку случайным образом на обучающую (100 объектов) и тестовую.
- Проведите на обучающей выборке обучение с линейной моделью SVM и выведите диаграмму рассеяния классов с линией гиперплоскости разделения.
- Приведите формулу разделяющей гиперплоскости.
- Оцените точность классификации на тестовой и обучающей выборках.

Первая модель(три в одном)

Разбиение выборки на обучающую (мы помним, что объектов 150, потому параметр тестовой части 0.33, чтобы в обучающей было 100)

In [11]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=19) #устанавливаем random_state 19, чтобы не
```

Проведите на обучающей выборке обучение с линейной моделью SVM и выведите диаграмму рассеяния классов с линией гиперплоскости разделения.

Мы хотим обучить тремя методами градиентного спуска и их сравнить для проведения дальнейших двух запусков

На первом запуске будем сравнивать пакетный, mini-batch и стохастический, на остальных двух будем запускать только один из них

Пакетный градиентный спуск

In [12]:
```
svm = SupportVectorMachine(X_train,y_train, h=0.005, min_iterations=1000) #вызывает пакетный градиентный спуск
w_ = svm.fit()  #веса
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
3.080 + -3.390 x1 + 4.837 x2 = 0
```

Посчитаем метрики

In [13]:
```
cntr_svm = Counter(X_train, X_test, y_train, y_test, svm)
cntr_svm.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.990
precision: 1.000
recall: 0.970
f1: 0.985

Метрики для тестовой выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [ 1 32]]
```

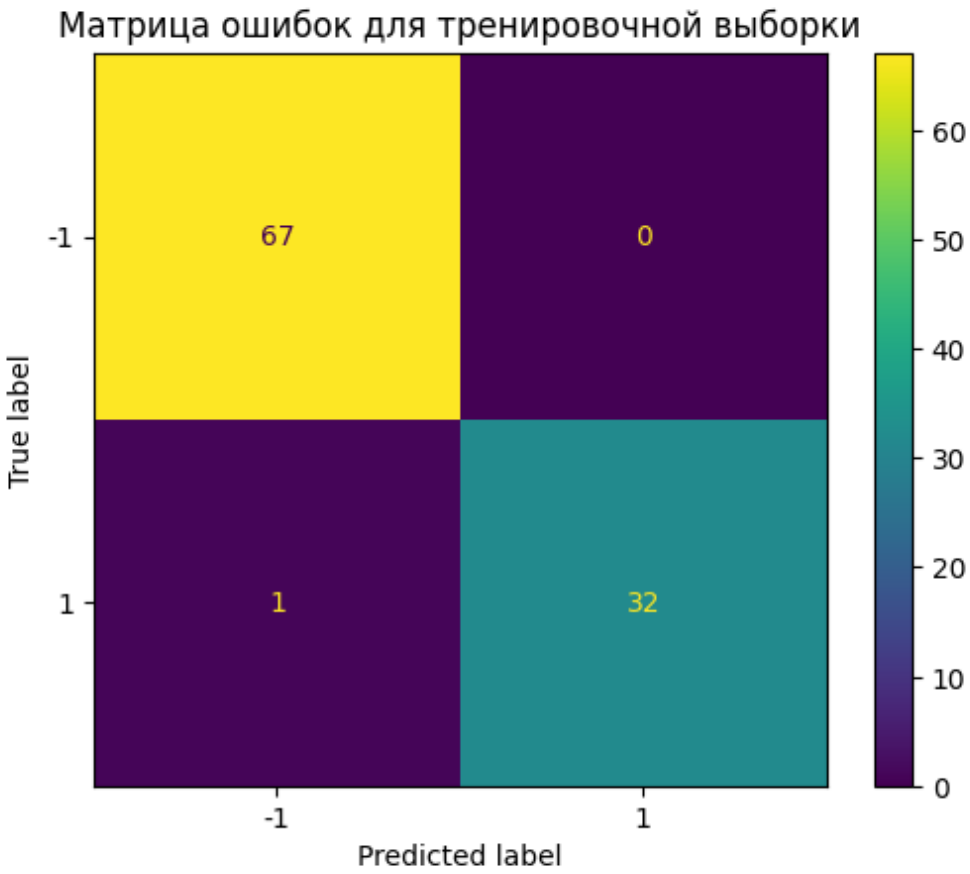


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [ 0 17]]
```

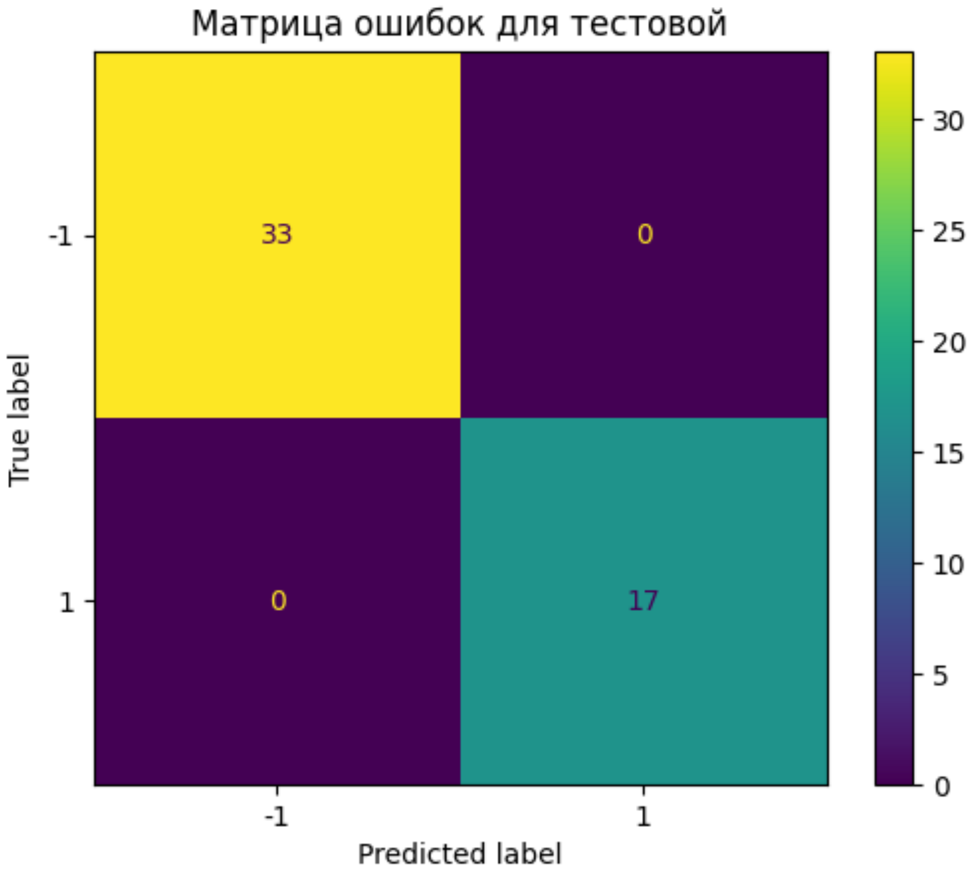

mini-batch

Всё то же самое для mini batch, но у него поменяем шаг, чтобы не разошелся

In [14]:
```
svm_mini_batch = SupportVectorMachine(X_train, y_train, h=0.005, min_iterations=1000, strategy='mini-batch', batch_size=10)
w_ = svm_mini_batch.fit()  #веса
print("Уравнение разделяющей гиперплоскости:")
```

```
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
1.350 + -2.069 x1 + 3.040 x2 = 0
```

Вновь считаем метрики

In [15]:
```
cntr_svm_mini_batch = Counter(X_train, X_test, y_train, y_test, svm_mini_batch)
cntr_svm_mini_batch.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.990
precision: 1.000
recall: 0.970
f1: 0.985

Метрики для тестовой выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [ 1 32]]
```

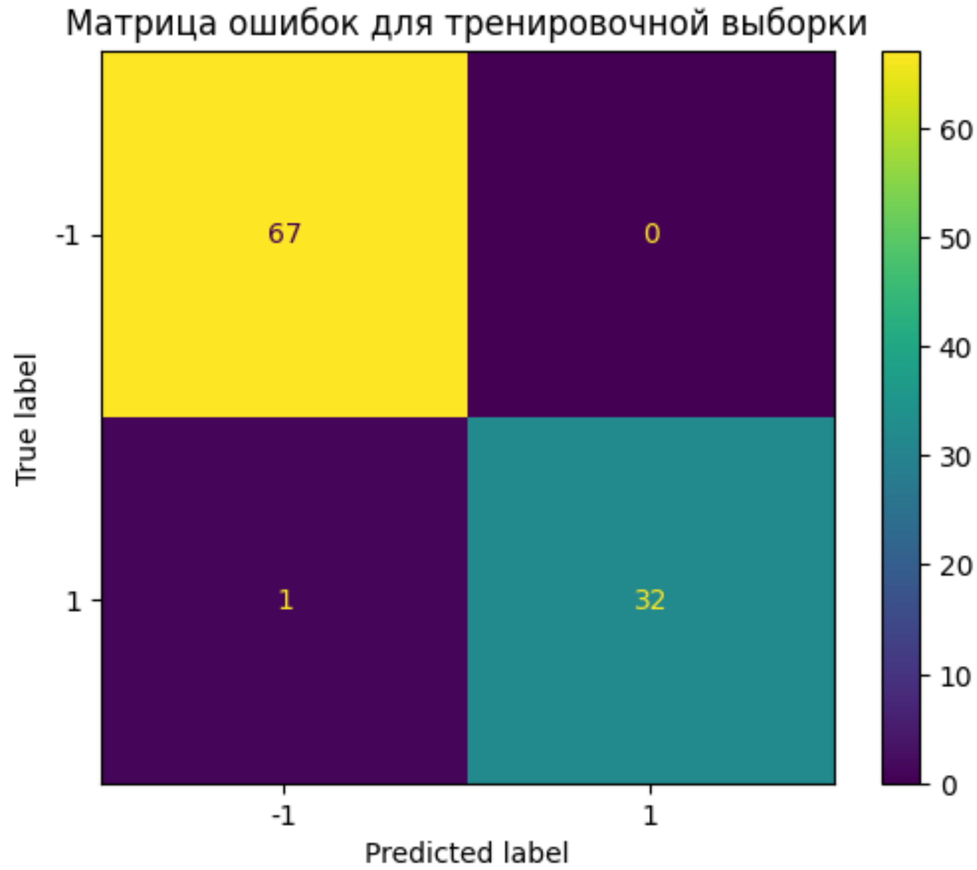


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [ 0 17]]
```

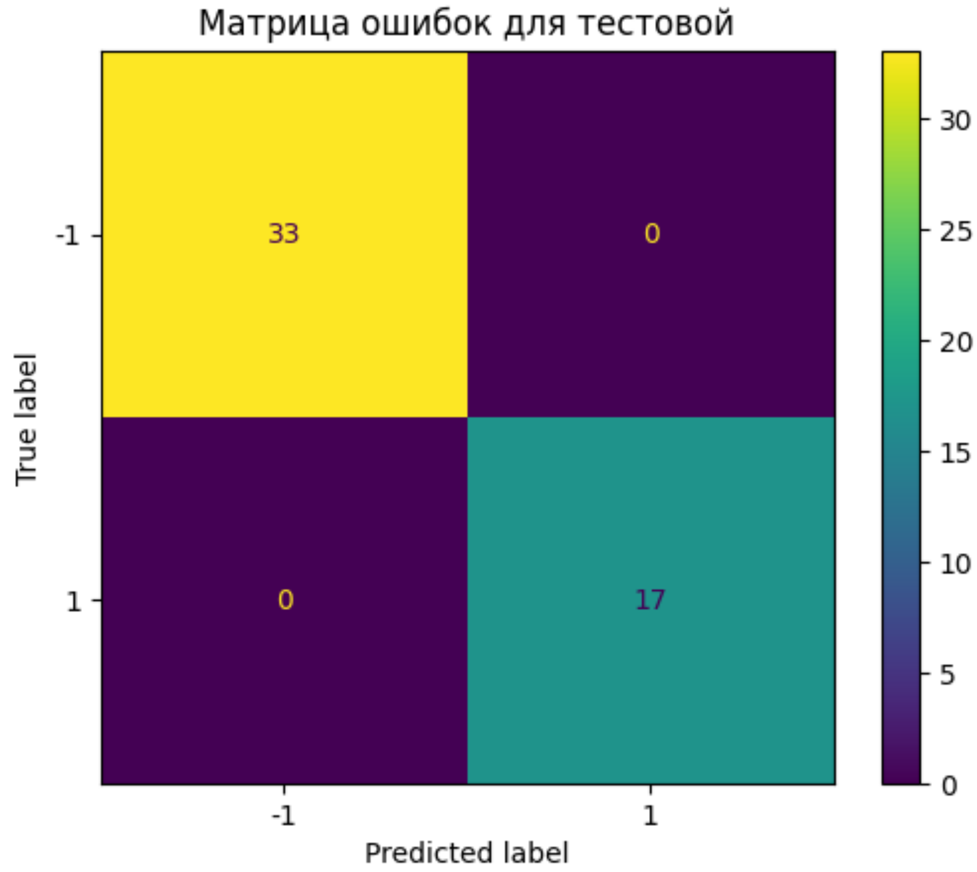

Стохастический градиентный спуск

Остался последний способ, реализованный у нас, это стохастический градиент спуск задаем те же параметры, что и у mini-batch

In [16]:
```
svm_stochastic = SupportVectorMachine(X_train, y_train, h=0.005, min_iterations=1000, strategy='stochastic')
w_ = svm_stochastic.fit()
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
0.895 + -1.027 x1 + 1.448 x2 = 0
```

Метрики для стохастического

```
In [17]: cntr_svm_stochastic = Counter(X_train, X_test, y_train, y_test, svm_stochastic)
         cntr_svm_stochastic.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.990
precision: 1.000
recall: 0.970
f1: 0.985

Метрики для тестовой выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [ 1 32]]
```

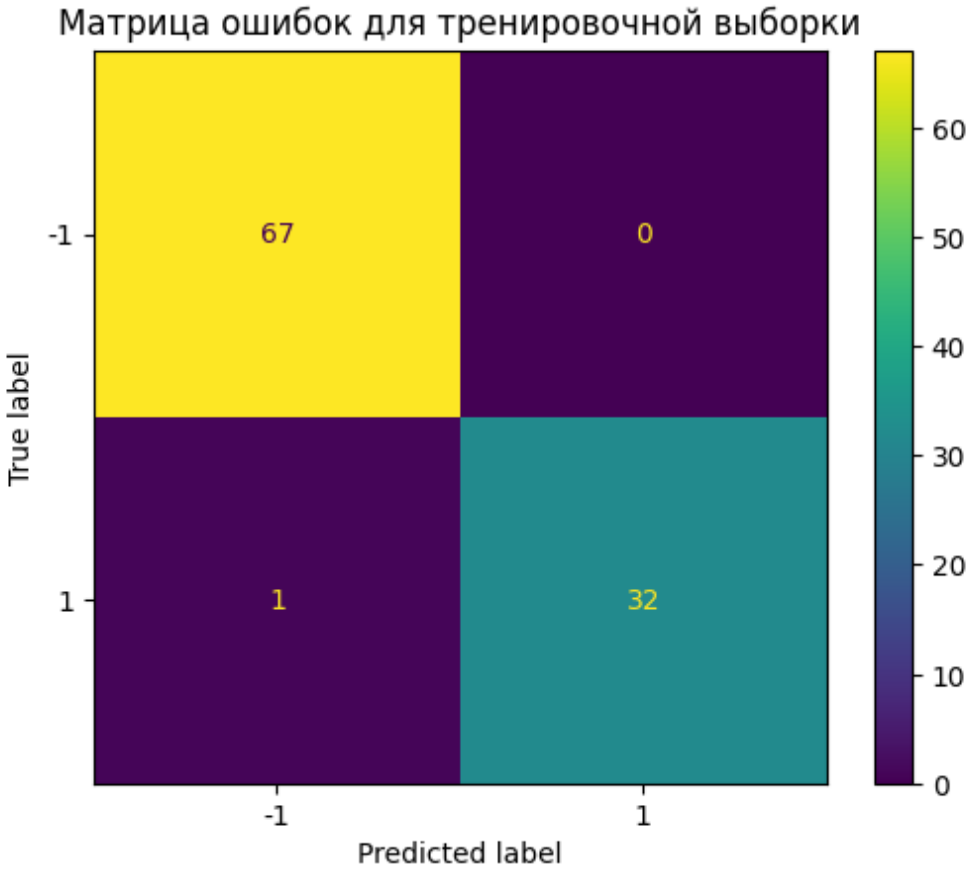


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [ 0 17]]
```

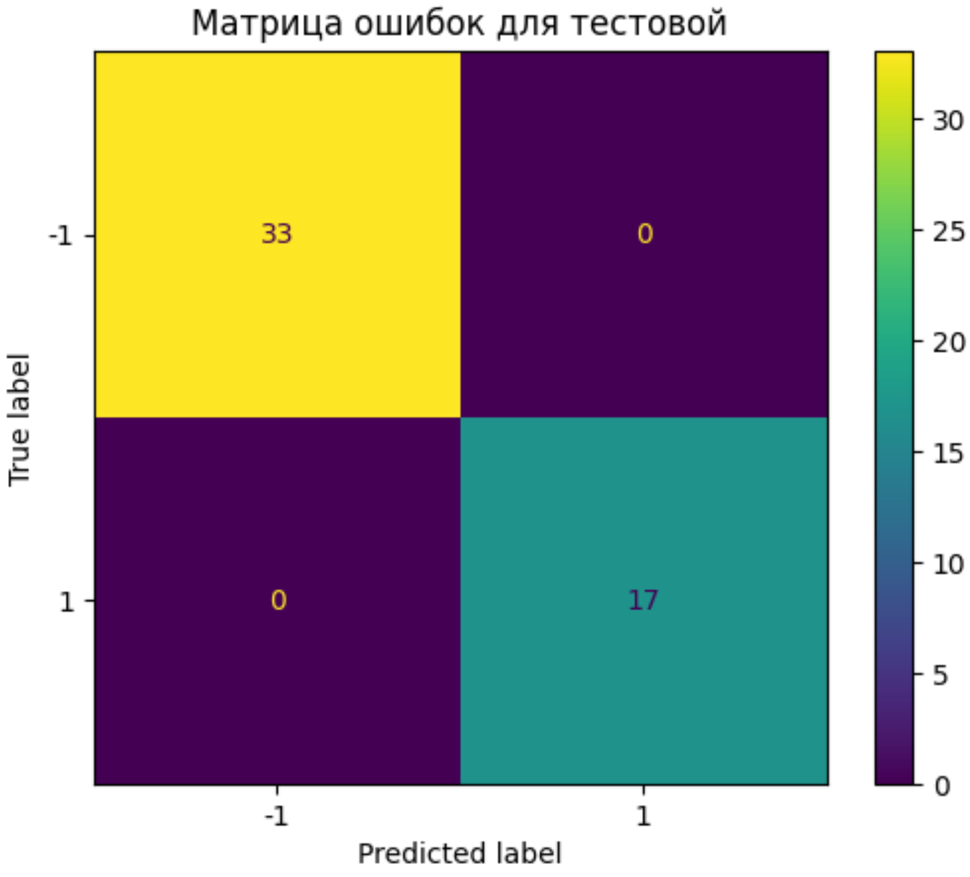

Разделяющая гиперплоскость для всех трех

Строим гиперплоскость всех троих способов разделения

```
In [18]: x1 = np.arange(-10, 15, 0.05)
         x2 = np.arange(-10, 15, 0.05)


         xgrid, ygrid = np.meshgrid(x1, x2)

         svm_w = svm.w
         svm_stochastic_w = svm_stochastic.w
         svm_mini_batch_w = svm_mini_batch.w

         svm_z = svm_w[0] + svm_w[2] * xgrid + svm_w[1]*ygrid
         svm_stochastic_z = svm_stochastic_w[0] + svm_stochastic_w[2] * xgrid + svm_stochastic_w[1]*ygrid
         svm_mini_batch_z = svm_mini_batch_w[0] + svm_mini_batch_w[2] * xgrid + svm_mini_batch_w[1]*ygrid

         fig = plt.figure(figsize=(12, 12))

         # Обучающая выборка
```

```python
ax = fig.add_subplot(221)


scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")
plt.contour(x1, x2, svm_z, colors="yellow", levels=[0])
plt.contour(x1, x2, svm_stochastic_z, colors="black", levels=[0])
plt.contour(x1, x2, svm_mini_batch_z, colors="green", levels=[0])

svm_patch = mpatches.Patch(color="yellow", label='Пакетный градиентный спуск')
svm_s_patch = mpatches.Patch(color="black", label='Стохастический градиентный спуск')
svm_m_patch = mpatches.Patch(color="green", label='Mini-batch градиентный спуск')

plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

ax.set_title('Обучающая выборка')
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
ax.legend(handles=[svm_patch, svm_s_patch, svm_m_patch])


#тестовая выборка
ax = fig.add_subplot(222)

scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")

plt.contour(x1, x2, svm_z, colors="yellow", levels=[0])
plt.contour(x1, x2, svm_stochastic_z, colors="black", levels=[0])
plt.contour(x1, x2, svm_mini_batch_z, colors="green", levels=[0])

svm_patch = mpatches.Patch(color="yellow", label='Пакетный градиентный спуск')
svm_s_patch = mpatches.Patch(color="black", label='Стохастический градиентный спуск')
svm_m_patch = mpatches.Patch(color="green", label='Mini-batch градиентный спуск')

plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")

ax.set_title('Тестовая выборка')
ax.add_artist(legend1)

ax.legend(handles=[svm_patch, svm_s_patch, svm_m_patch])
```

Out[18]: <matplotlib.legend.Legend at 0x212b712b6e0>

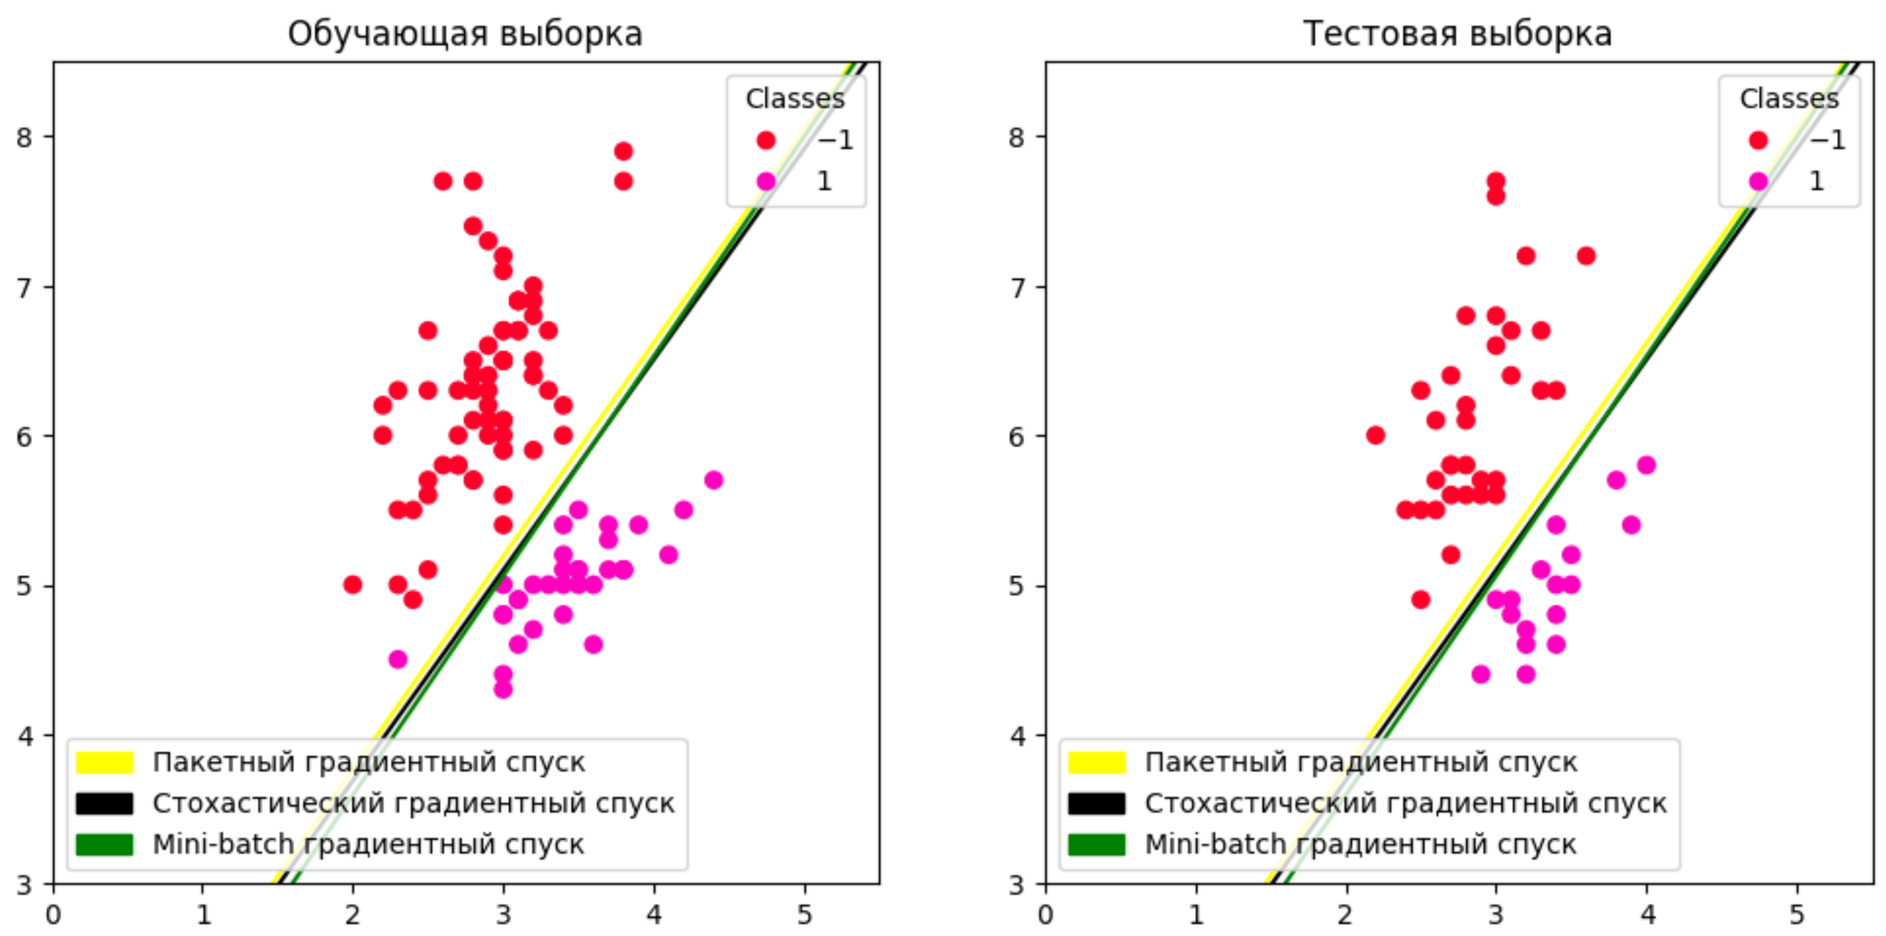

Мини-выводы

По итогу метрики accuracy, precision и recall оказались одинаковыми, как следствие этого f0 тоже одинаковые

Визуально кажется, что все-таки пакетный градиентный спуск и mini-batch остается это узнать по функции ошибки

In [19]:
```python
print(f"SVM с пакетной оптимизацией: {svm.q[0]:.02f}")
print(f"SVM с мини-батч оптимизацией: {svm_mini_batch.q[0]:.02f}")
print(f"SVM с стохастической оптимизацией: {svm_stochastic.q[0]:.02f}")
```

```
SVM с пакетной оптимизацией: 2.88
SVM с мини-батч оптимизацией: 6.30
SVM с стохастической оптимизацией: 15.49
```

Вывод по первой модели

У пакетного меньше всего ошибка, дальше будем продолжать работать с ним

Вторая модель(только пакетный)

Новое разбиение для новой модели

In [20]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=20)
```

In [21]:
```
svm_2 = SupportVectorMachine(X_train,y_train,  h=0.0005, min_iterations=10000)
svm_2.fit()  #веса
w_ = svm_2.fit()
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
2.709 + -2.812 x1 + 4.017 x2 = 0
```

Метрики

In [22]:
```
cntr_svm_2 = Counter(X_train, X_test, y_train, y_test, svm_2)
cntr_svm_2.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.990
precision: 1.000
recall: 0.970
f1: 0.985

Метрики для тестовой выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [ 1 32]]
```

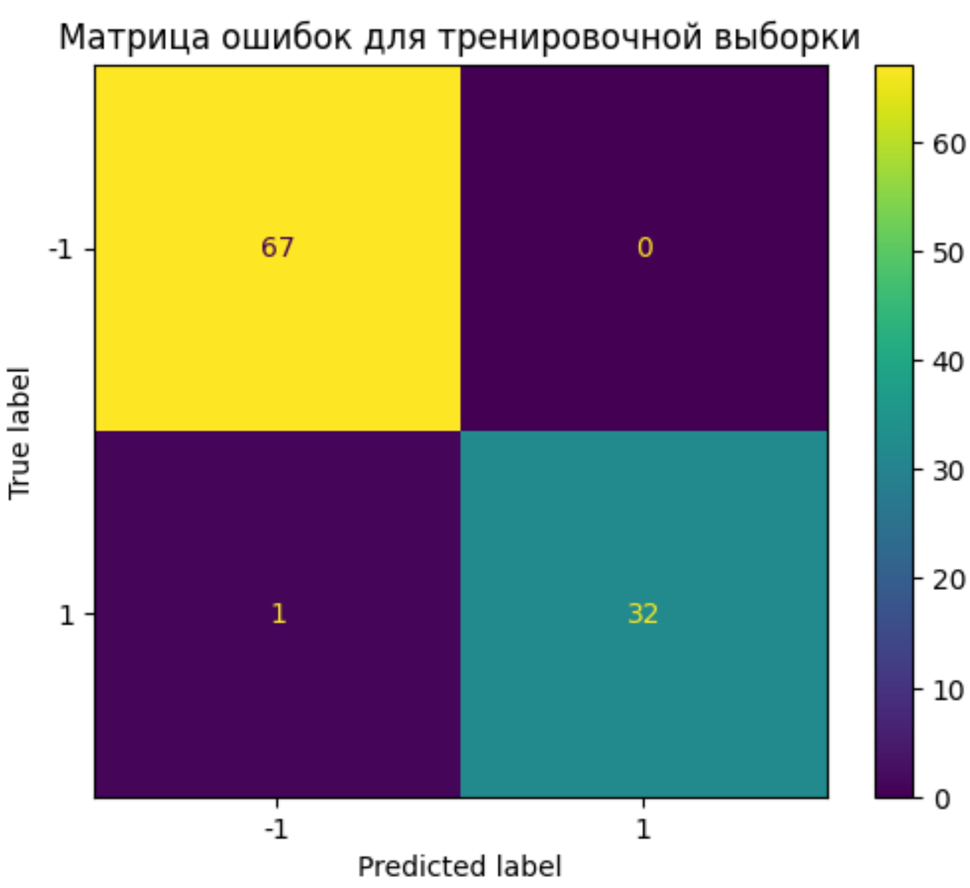


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [ 0 17]]
```

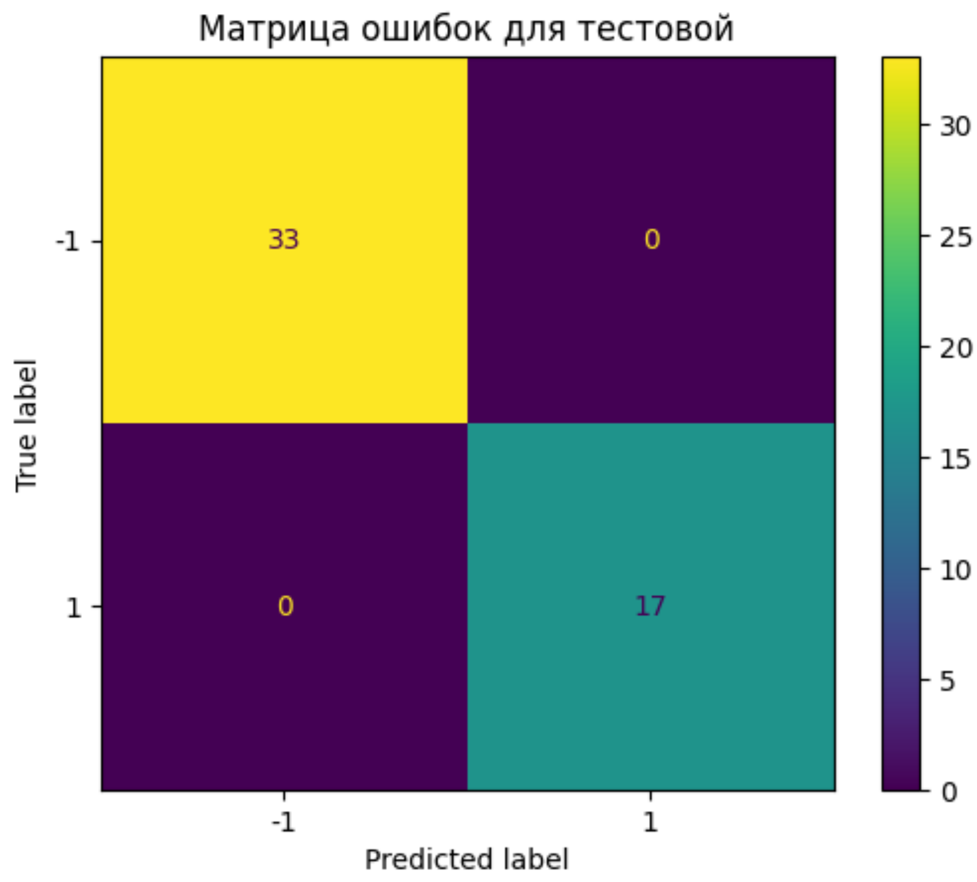

График гиперплоскости

In [23]:
```
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)

w = svm_2.w

xgrid, ygrid = np.meshgrid(x1, x2)
z = w[0] + w[2] * xgrid + w[1]*ygrid


# Обучающая выборка
fig = plt.figure(figsize=(12, 12))


ax = fig.add_subplot(221)
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")

ax.set_title('Обучающая выборка')


legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)


#тестовая выборка
ax = fig.add_subplot(222)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")




legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.set_title('Тестовая выборка')
ax.add_artist(legend1)


plt.show()
```

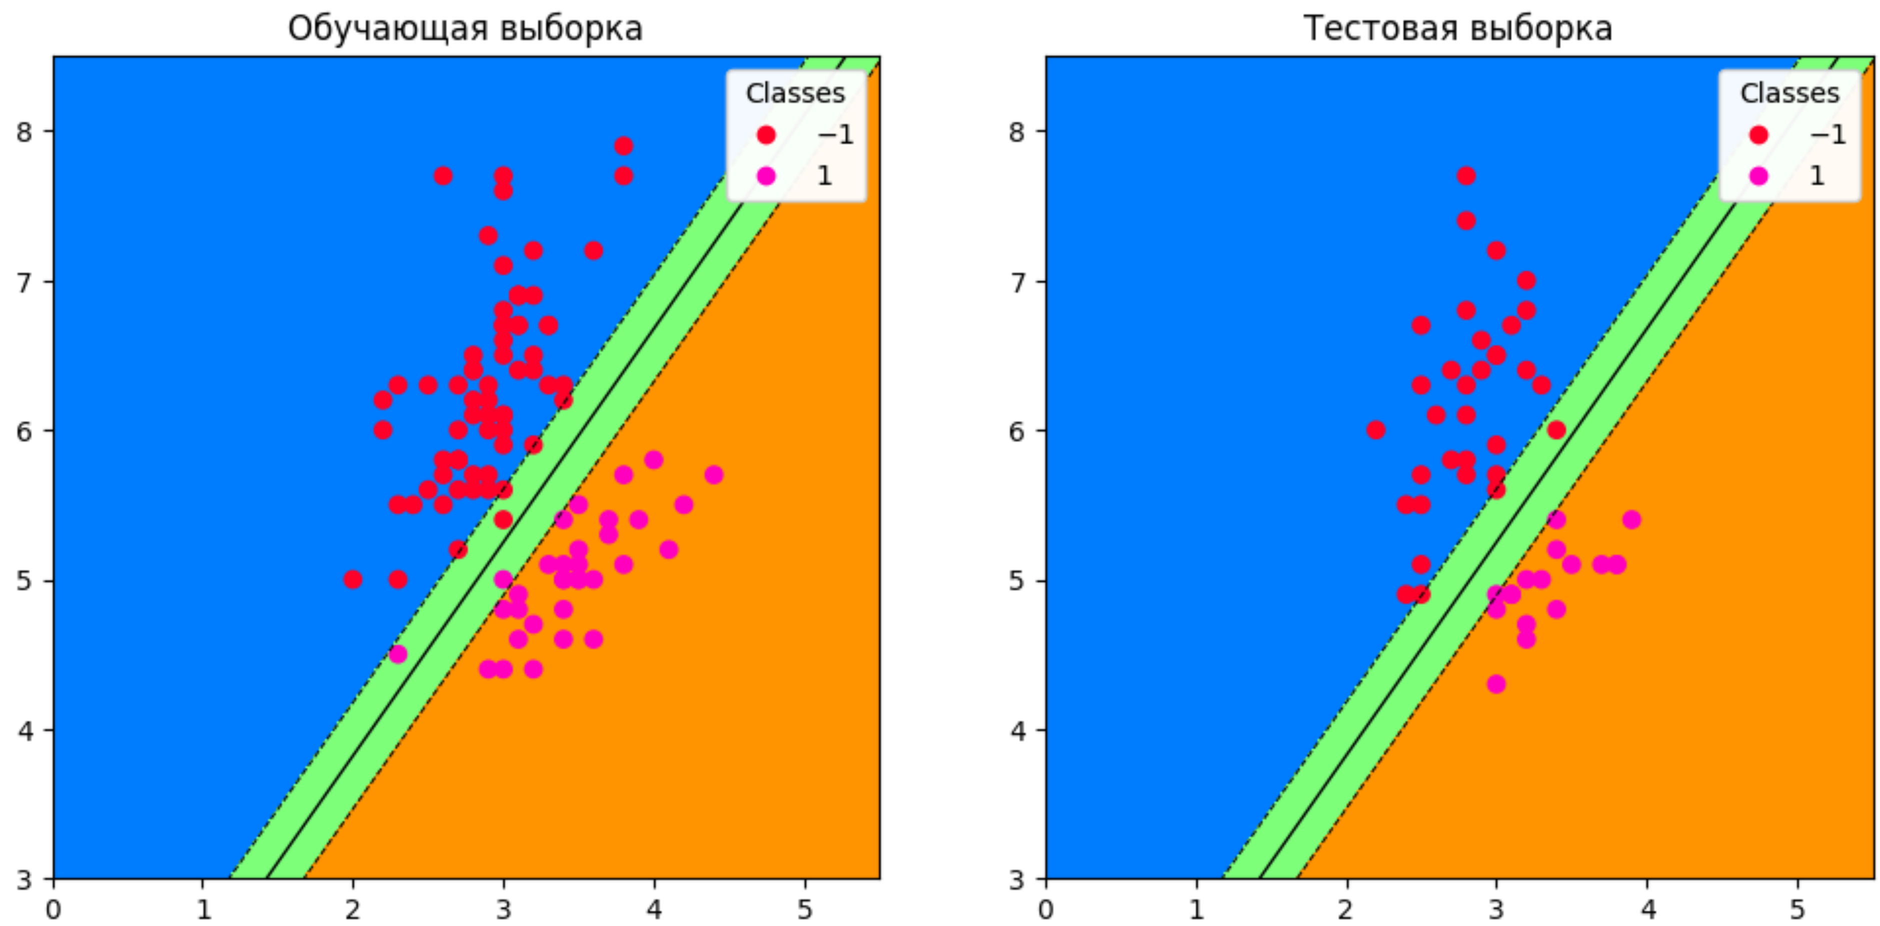

Получилось достаточно неплохо, однако видно, что неидеально. Есть один объект класса 1, который попал к классу -1. Также есть несколько объектов в margin-зоне.

Третья модель

In [24]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=122)
```

In [25]:
```
svm_3 = SupportVectorMachine(X_train, y_train, min_iterations=10000)
w_ = svm_3.fit()
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
1.295 + -1.992 x1 + 3.053 x2 = 0
```

In [26]:
```
cntr_svm_3 = Counter(X_train, X_test, y_train, y_test, svm_3)
cntr_svm_3.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.990
precision: 1.000
recall: 0.971
f1: 0.986

Метрики для тестовой выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000
Матрица ошибок, полученная методом confusion_matrix
 [[65  0]
 [ 1 34]]
```

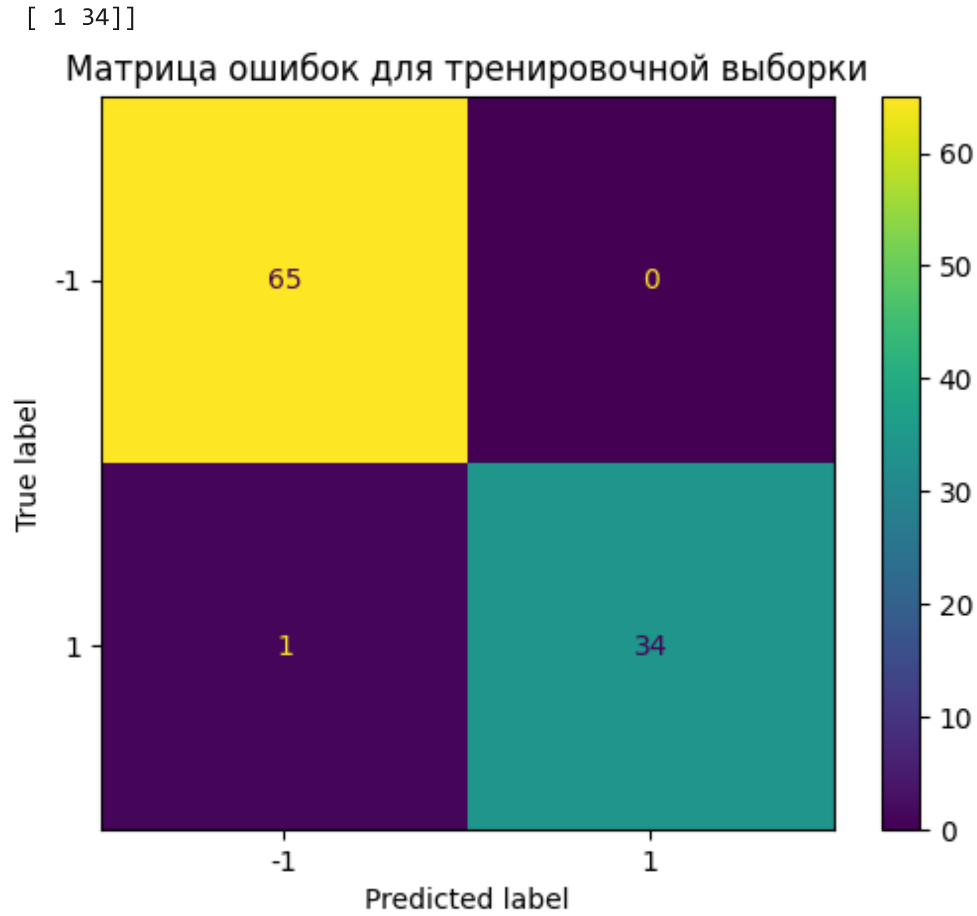


```
Матрица ошибок, полученная методом confusion_matrix
 [[35  0]
 [ 0 15]]
```

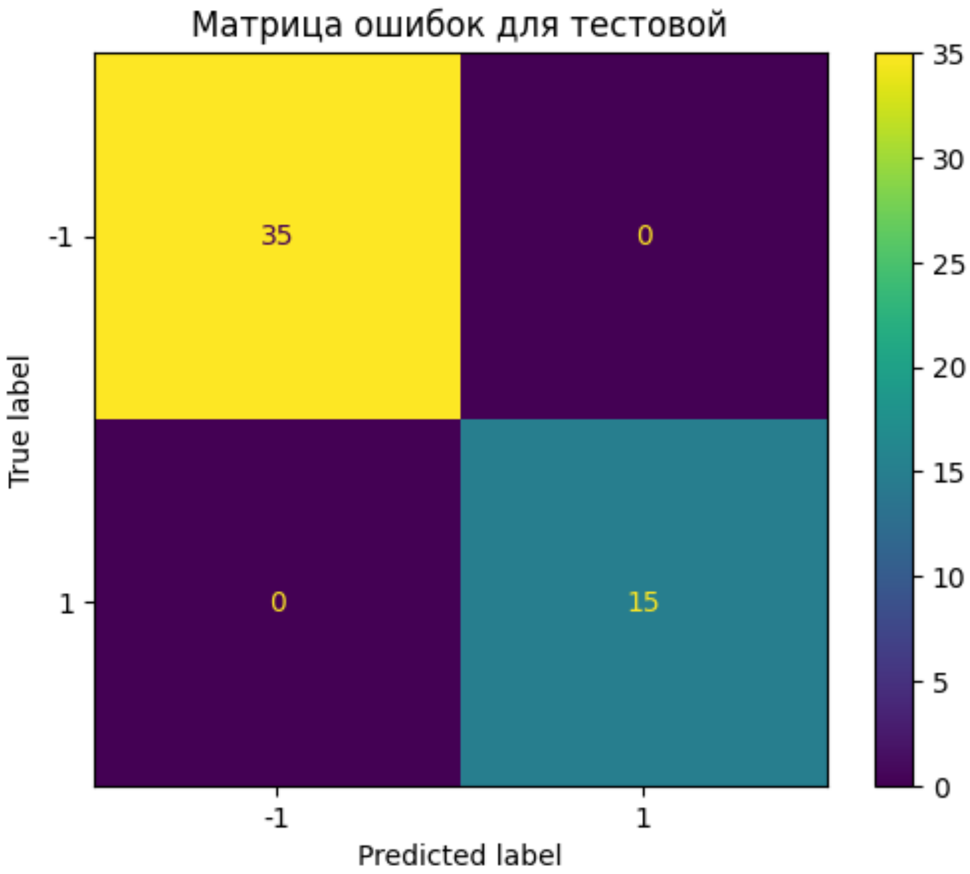

In [27]:
```
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)

w = svm_3.w

xgrid, ygrid = np.meshgrid(x1, x2)
z = w[0] + w[2] * xgrid + w[1]*ygrid


# Обучающая выборка
fig = plt.figure(figsize=(12, 12))


ax = fig.add_subplot(221)
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")

ax.set_title('Обучающая выборка')


legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)


#тестовая выборка
ax = fig.add_subplot(222)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")




legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.set_title('Тестовая выборка')
ax.add_artist(legend1)


plt.show()
```

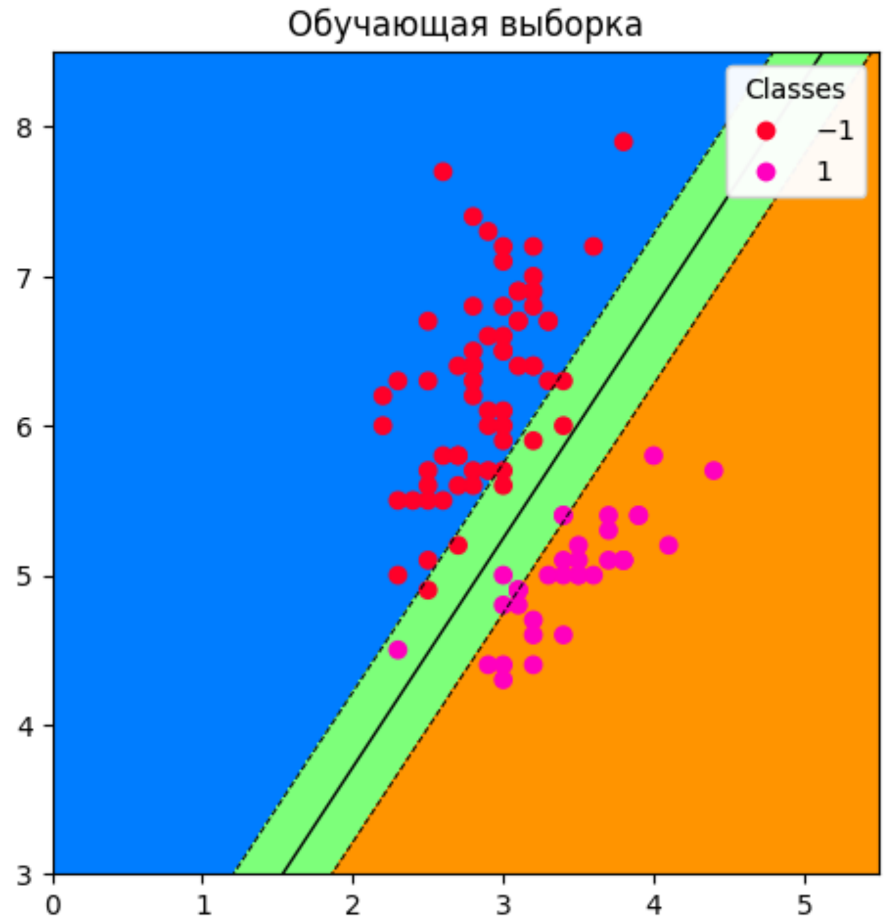

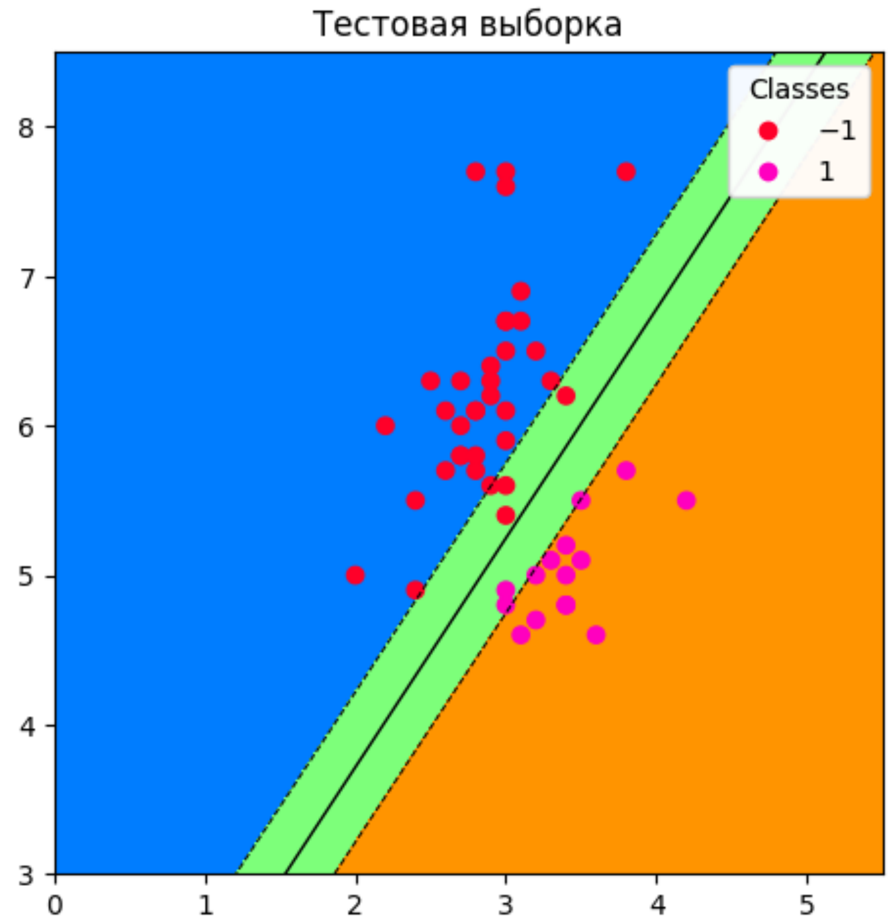

Похожая картина, но теперь из-за бОльшей ширины margin-зоны в неё попало больше объектов. На результатах классификации это не сказалось (такие у нас данные)

Задание 4

Текст задания

Сравните итоги выполненных ранее трёх попыток обучения. Сделайте выводы.

Пояснения

По итогу независимо от разбиения последний объект никак не получается отделить в обучающей выборке(так получилось, то он попал во всех трех разбиениях в обучающую выборку. Однако на всех тестовых выборках метрики 1. Значит модель не переобучилась и имеет хорошую обобщающую способность.

По итогу можно сказать что выборка линейно неразделима, либо с точки зрения линейной модели слишком сильно пострадает обобщающая способность если подстраиваться под одну точку.

Визуально кажется, что выборка линейна неразделима, но так может показаться из-за масштаба, так что для более корректного вывода следует исследовать сами данные

Если предположить, что тот один объект является выбросом (неверно указан класс при сборе датасета), то классы получатся линейно разделимы и всё хорошо.

Задание 5

Текст задания

Реализуйте задачу классификации с квадратичной функцией SVM на последнем наборе обучающей и тестовой выборок (также диаграммой рассеяния и линией раздела).

Пояснения по поводу svm

Если мы не можем решить задачу линейного разделения в исходном пространстве признаков, то повышаем размерность, предполагая, что в новом пространстве признаков большей размерности задачу линейного разделения удастся решить.

Мы применили к объектам отображение

$$f : R^2 \to R^5$$

а именно

$$f(x) = (x_1, x_2, x_1^2, x_2^2, x_1 x_2)$$

In [28]:
```
class QuadraSupportVectorMachine(SupportVectorMachine):#наследуемся от градиентного спуска
    def init_r(self):
        self.width = 6 #переопределим количество признаков
        self.to_new_r() #переведем их в пятимерное пространство
        self.w = np.array([1, 1, 1, 1, 1, 1]) #зададим новые стартовые веса для этого пространства
    def to_new_r(self, X = None): #добавляем переход в пятимерное пространство для данных

        flag_ = True
        if X is None:
```

```python
            flag_ = False
            X = self.X

        X =  np.concatenate((np.ones((len(X), 3)), X), axis=1) #фиктивная единица
        for i in range(len(X)):

            X[i, :] = np.array([1, X[i, -1]**2, X[i, -2]**2, X[i, -1], X[i, -2], X[i, -1] * X[i, -2]])
        if flag_:
            return X
        self.X = X


    def predict(self, X): #переопределение функции предсказания
        X =  np.concatenate((np.ones(len(X)).reshape(-1, 1), X), axis=1) #фиктивная единица
        X = self.to_new_r(X) #перевод в новое пространство данных
        return np.sign(np.dot(X, self.w).reshape(-1, 1)) #предсказание
```

Решение

Используем последнее разбиение для обучения новой модели

In [29]:
```python
qsvm = QuadraSupportVectorMachine(X_train, y_train, h=0.0005, min_iterations=30000) #инициализация метода
qsvm.init_r() #для перехода в новое пространство
w_ = qsvm.fit()
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
1.963 + 0.828 x1 + -1.295 x2 + 2.122 x3 + 3.047 x4 + 0.222 x5 = 0
```

Метрики

In [30]:
```python
cntr_qsvm = Counter(X_train, X_test, y_train, y_test, qsvm)
cntr_qsvm.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000

Метрики для тестовой выборки
accuracy: 1.000
precision: 1.000
recall: 1.000
f1: 1.000
Матрица ошибок, полученная методом confusion_matrix
 [[65  0]
 [ 0 35]]
```

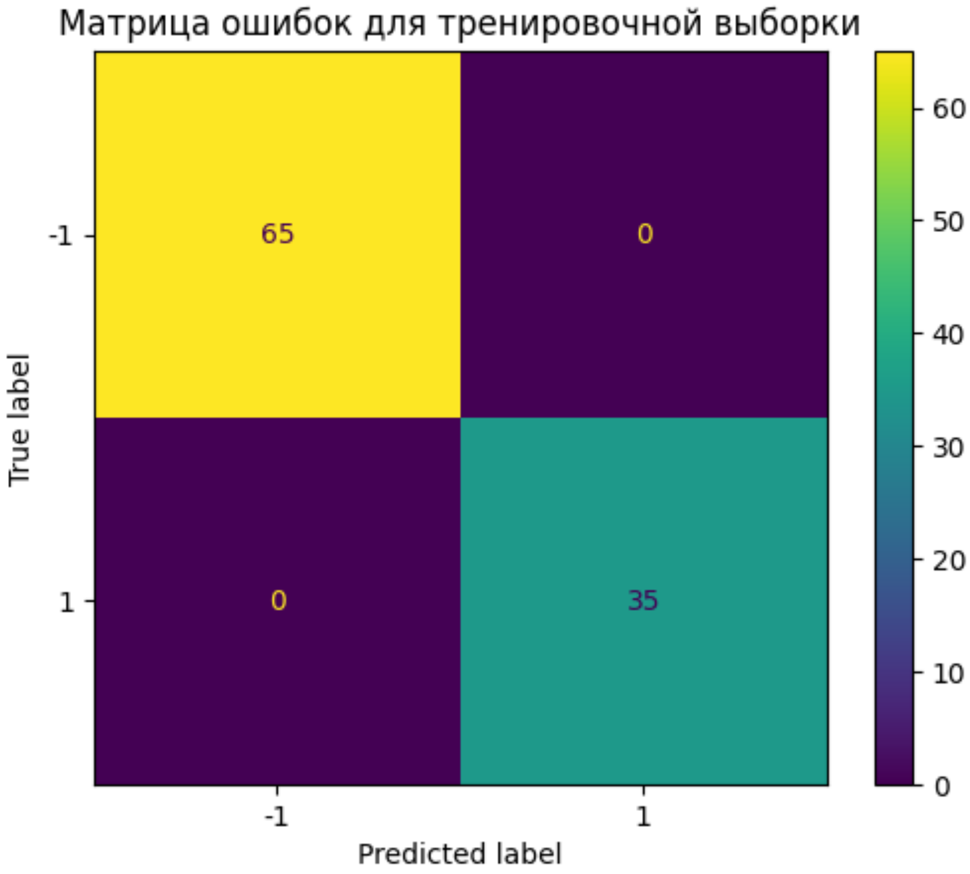


```
Матрица ошибок, полученная методом confusion_matrix
 [[35  0]
 [ 0 15]]
```

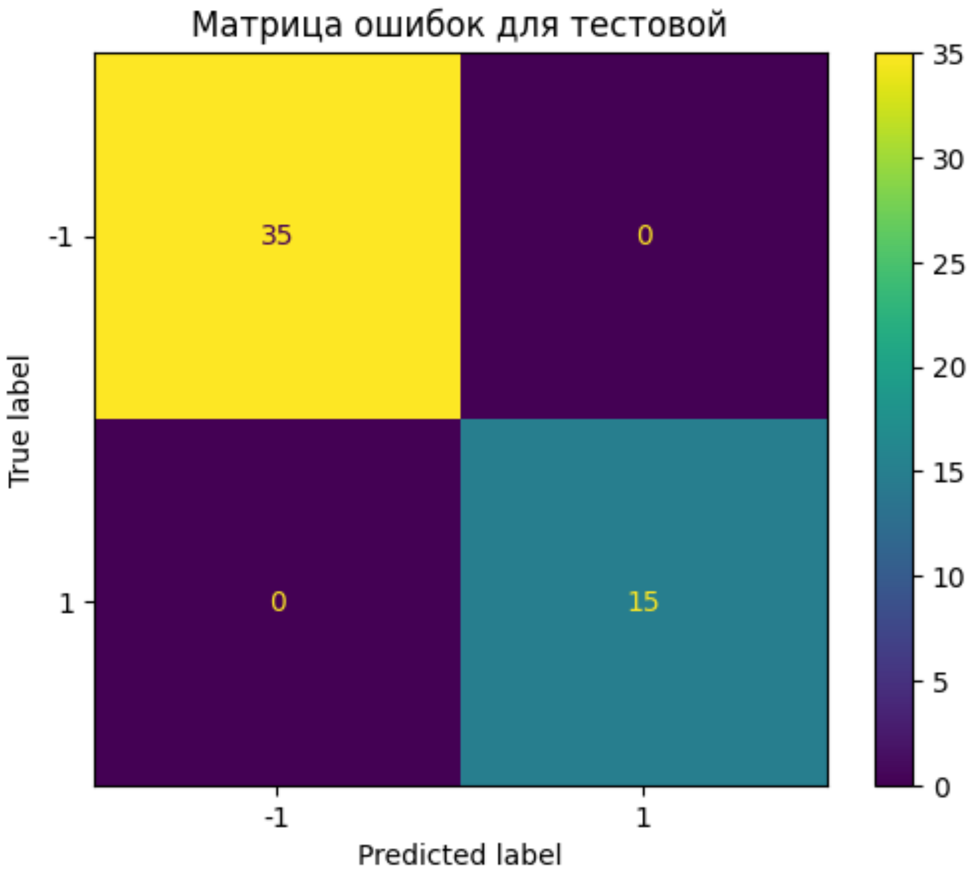

Линии уровня гиперплоскости

In [31]:
```
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)


xgrid, ygrid = np.meshgrid(x1, x2)

w = qsvm.w
z = w[0] + w[1]*xgrid**2 + w[2]*ygrid**2 + w[3]*xgrid + w[4]*ygrid + w[5]*xgrid*ygrid

fig = plt.figure(figsize=(12, 12))
ax = fig.add_subplot(221)

plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")
ax.set_aspect('equal', adjustable='box')
ax.set_title('Тестовая выборка')
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")

ax = fig.add_subplot(222)


plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)
ax.set_aspect('equal', adjustable='box')
ax.set_title('Обучающая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)


plt.show()
```

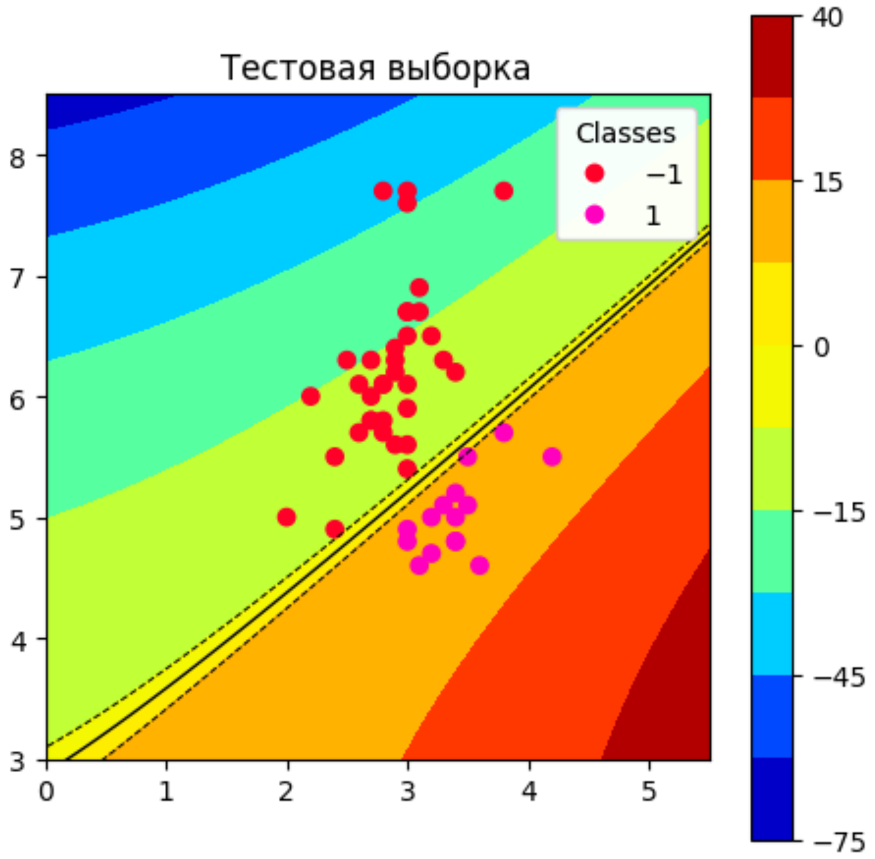

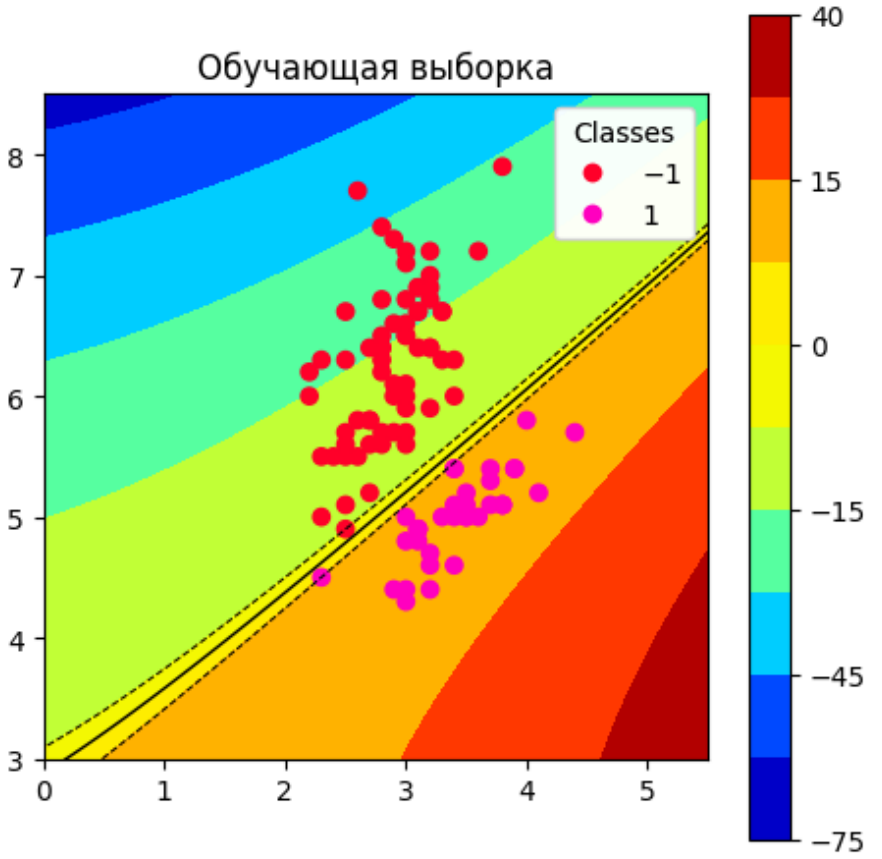

Выводы по svm с квадратичным ядром

Квадратичное ядро даже смогло описать ту точку с которой не справилась линейная svm. Сложно сказать переобучение это или такая природа предметной области. В самом начале мы удалили два признака, потому какие-то выводы сложно делать исходя из визуальных данных

Задание 6

Текст задания

Сравните точность классификации на тестовой выборке с линейной SVM. Объясните результат.

Решение

Точность классификации отличается, казалось бы, несильно, однако точность 1 и любая меньше 1 - абсолютно разные результаты.

В обобщающей способности линейного классификатора нет сомнений поскольку это самая простая модель, за исключением константной, которая только может быть.

Однако квадратичная могла и сильно подстроиться под ту одну точку, хотя в реальных данных там может оказаться много точек другого класса.

Может оказаться так, что все-таки там природно розовые точки, потому можно сделать вывод, что обе модели хорошо справились со своей задачей

Задание 7

Текст задания

Определите сорт 20 объектов из дополнительной выборки (файл «Dop.csv»). Качество определения сорта проверит преподаватель.

Пояснение перед решением

Для предсказания будем использовать две модели, чтобы визуально посмотреть насколько повлияли "выбросы" на предсказание модели в финальной тестовой выборки(мы не знаем ответы)

Решение

In [32]:
```
df_dop = pd.read_csv("data/Dop.csv") ## чтение датасета
df_dop.head()
```

Out[32]:

	Sepal.L	Sepal.W	Petal.L	Petal.W
0	6.0	2.9	4.9	1.6
1	5.2	3.0	2.4	0.5
2	5.7	2.8	4.5	1.4
3	5.4	3.4	2.3	0.9
4	6.7	3.3	5.4	2.0

In [33]:
```
y_dop = pd.DataFrame()
X_dop = df_dop[["Sepal.L", "Sepal.W"]].to_numpy() #отбираем нужные признаки
```

In [34]:
```
y_pred_qsvm_dop = qsvm.predict(X_dop)
y_pred_svm_dop = svm_3.predict(X_dop)
```

Ответы

In [35]:
```
ans = pd.DataFrame()
ans["SVM Квадратичное ядро"] = y_pred_qsvm_dop[:, 0] #Ответы по модели с квадратичным ядром
ans["SVM линейное ядро"] = y_pred_svm_dop[:, 0] # Ответы по линейной модели
ans["Совпадение ответов"] = ans["SVM Квадратичное ядро"] == ans["SVM линейное ядро"]

ans
```

Out[35]:

	SVM Квадратичное ядро	SVM линейное ядро	Совпадение ответов
0	-1.0	-1.0	True
1	1.0	1.0	True
2	-1.0	-1.0	True
3	1.0	1.0	True
4	-1.0	-1.0	True
5	-1.0	-1.0	True
6	-1.0	-1.0	True
7	-1.0	-1.0	True
8	-1.0	-1.0	True
9	-1.0	-1.0	True
10	-1.0	-1.0	True
11	1.0	1.0	True
12	-1.0	1.0	False
13	1.0	1.0	True
14	1.0	1.0	True
15	-1.0	-1.0	True
16	1.0	1.0	True
17	-1.0	-1.0	True
18	-1.0	-1.0	True
19	-1.0	-1.0	True

Пояснение к ответам

Скорее всего можно сказать, что мы гарантировали точность модели 0.95 на финальной тестовой выборке, поскольку у двух хороших моделей 95 процентов ответов совпали

Визуализация ответов

In [36]:
```
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)


xgrid, ygrid = np.meshgrid(x1, x2)

w = qsvm.w
z = w[0] + w[1]*xgrid**2 + w[2]*ygrid**2 + w[3]*xgrid + w[4]*ygrid + w[5]*xgrid*ygrid

fig = plt.figure(figsize=(12, 12))
ax = fig.add_subplot(221)

plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_dop[:, 1], X_dop[:, 0], c=y_pred_qsvm_dop, cmap="gist_rainbow", marker="o")
ax.set_aspect('equal', adjustable='box')
ax.set_title('SVM с квадратичным ядром')
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)

ax = fig.add_subplot(222)
w = svm_3.w
z = w[0] + w[2] * xgrid + w[1]*ygrid

plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
```

```python
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_dop[:, 1], X_dop[:, 0], c=y_pred_svm_dop, cmap="gist_rainbow", marker="o")
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)
ax.set_aspect('equal', adjustable='box')
ax.set_title('SVM с линейным ядром')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
print(z.shape)

plt.show()
```

(500, 500)

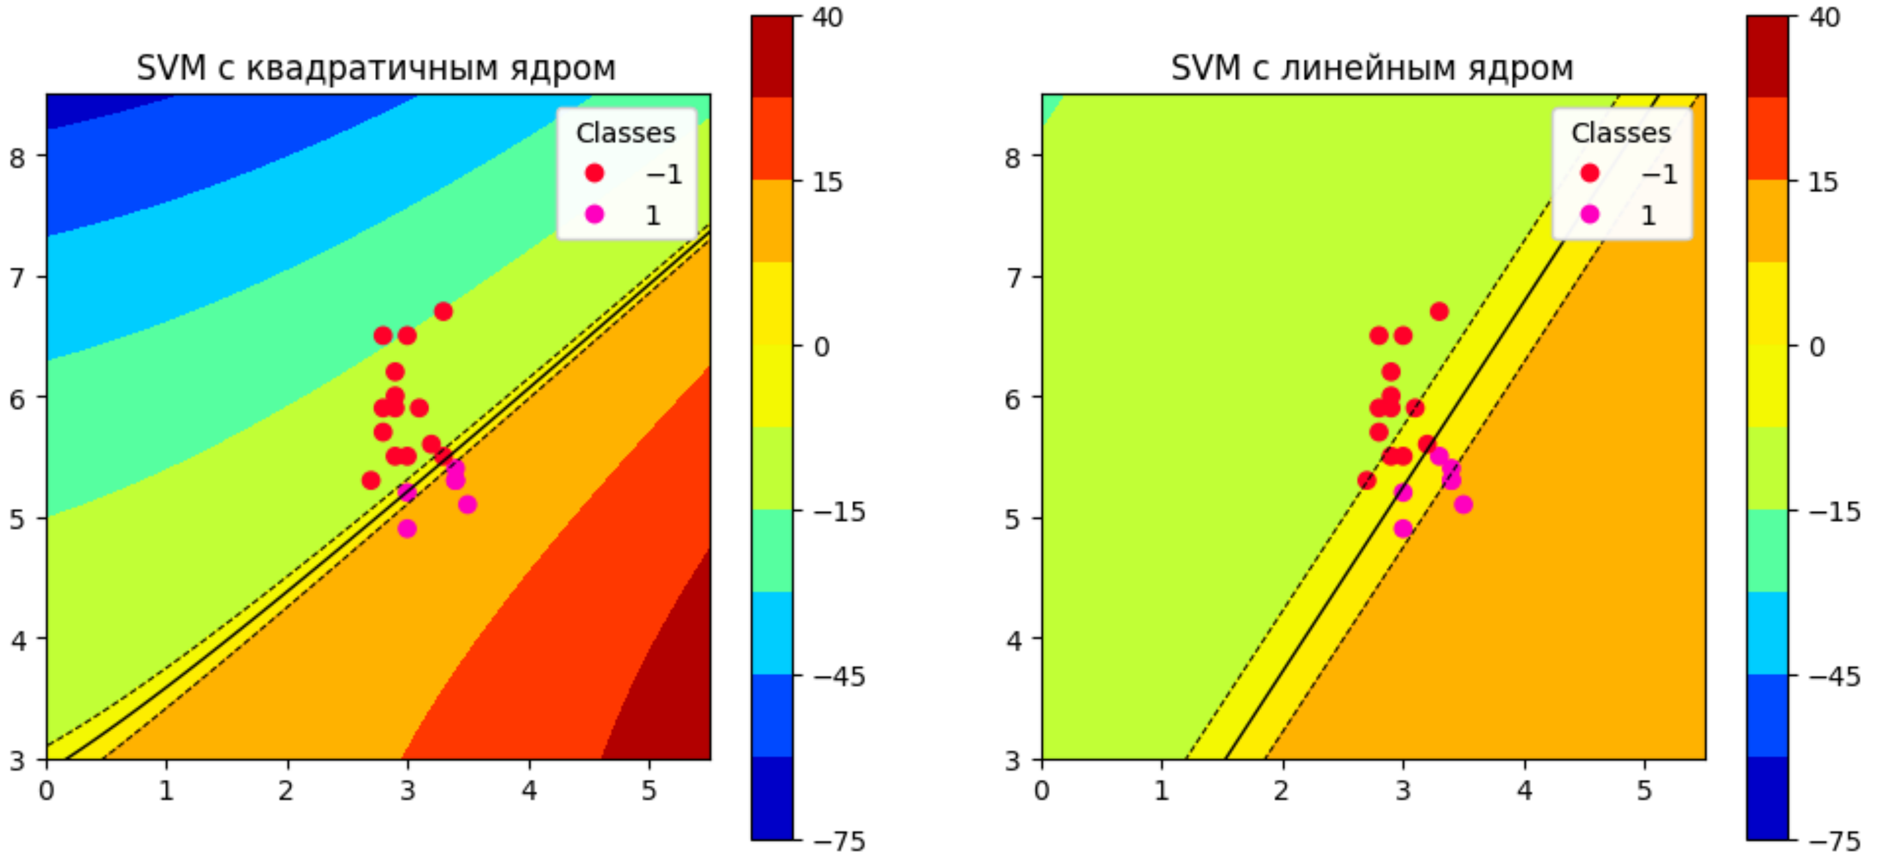

Пояснение к визуализации

Можно сказать, что на ответ повлияла та точка, поскольку сильно оттянулась кривая. Однако гипотетическая точность у обоих моделей все равно очень хорошая

Дополнительно

Задание 1

Текст задания

Реализуйте нелинейную SVM с гауссовой или сигмоидальной функцией ядра. Сравните результаты с предыдущими вариантами классификации +3 балла.

Запишем задачу оптимизации для SMO Эта постановка была взята отсюда 46 страница

$$\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{m} y_i Y_j \alpha_i \alpha_j K(x_i, X_j) - \sum_{i=1}^{m}\alpha_i \to min_\alpha$$

Где $K(x_i, x_j)$ - функция ядра

Гауссовское ядро (RBF ядро):

$$K(\mathbf{x_i}, \mathbf{x_j}) = e^{-\frac{\|\mathbf{x_i}-\mathbf{x_j}\|^2}{2\sigma^2}}, \quad \mathbf{x_i}, \mathbf{x_j} \in \mathbb{R}^d, \sigma > 0,$$
$$\text{или}$$
$$K(\mathbf{x_i}, \mathbf{x_j}) = e^{-\lambda\|\mathbf{x_i}-\mathbf{x_j}\|^2}, \quad \mathbf{x_i}, \mathbf{x_j} \in \mathbb{R}^d, \lambda > 0$$

Где σ и λ — это ширина ядра. В первом случае, чем меньше значение σ, тем меньше значение под экспонентой и тем более чувствительно ядро к изменениям. Во втором, наоборот, чем больше значение λ, тем более чувствительно. Источник: Интуитивное понимание пространств и ядер в машинном обучении

Решение

Для решения этой задачи воспользуемся литературой SMO 9 страница вывод, 12 страница итоговые формулы

Тут происходит очень сложная математика, которую тяжеловато объяснить, но мы вроде разобрались.

Есть проблема что Гауссово ядро не представимо в виде конечномерного спрямляющего пространства, если его расписать в ряд Тейлора, мы получим бесконечномерное пространство. Мы решили апроксимировать гауссово ядро, используя разложение в ряд Тейлора с остаточным членом (ограничились размерностью порядка n).

Для квадратичного ядра, даже необязательно расписывать во формуле Тейлора, так как это полином легко свести

Ещё был другой вариант развития событий - не использовать спремляющее пространство, а использовать только лишь функцию ядра, которая вычислит необходимое нам произведение в бесконечномерном пространстве для признаков из исходного пространства. Идея очень хорошая, однако, возникает проблема оптимизации, потому что градиентный спуск здесь уже ничем не поможет.

Формально, задача, поставленная выше - задача квадратичного программирования. Мы нашли метод SMO - Sequential minimal optimization, который позволяет эффективно данную задачу решить, однако он достаточно сложный для понимания и реализации. Мы хотели его реализовать, но нам, к сожалению, не хватило на это времени.

Источник: John C. Platt; Sequential Minimal Optimization A Fast Algorithm for Training Support Vector Machines Статья 1998 года на английском языке

In [37]:
```
class GaussSVM(SupportVectorMachine):
    def init_r(self, n):
            self.width = n*n #переопределим количество признаков
            self.to_new_r() #переведем их в пятимерное пространство
            self.w = np.ones(n*n)#зададим новые стартовые веса для этого пространства
    def to_new_r(self, X = None): #добавляем переход в пятимерное пространство для данных

        flag_ = True
        if X is None:
            flag_ = False
            X = self.X
        print(X)
        x1 = X[:, 1]
        x2 = X[:, 2]
        C = np.zeros((X.shape[0],self.width))
        new_x1 = np.zeros((int(self.width**(1/2)), x1.shape[0]))
        new_x2 = np.zeros((int(self.width**(1/2)), x1.shape[0]))

        for x in range(int(self.width**(1/2))):
            new_x1[x] = -(1 - x1)**(2*x)/math.factorial(x)
            new_x2[x] = -(1 - x2)**(2*x)/math.factorial(x)
        for i in range(int(self.width**(1/2))):
            for j in range(int(self.width**(1/2))):
                C[:, i * int(self.width**(1/2)) + j] = new_x1.T[:, i] * new_x2.T[:, j]

        if flag_:
            return C
        self.X = C


    def predict(self, X): #переопределение функции предсказания
        X =  np.concatenate((np.ones(len(X)).reshape(-1, 1), X), axis=1) #фиктивная единица
        X = self.to_new_r(X) #перевод в новое пространство данных
        return np.sign(np.dot(X, self.w).reshape(-1, 1)) #предсказание
```

In [38]:
```
from sklearn import preprocessing
scaler = preprocessing.MinMaxScaler()
X_scaled = scaler.fit_transform(X)
X_scaled_train, X_scaled_test, y_train, y_test = train_test_split(X_scaled, y, random_state=0)
```

In [39]:
```
test_svm = GaussSVM(X_scaled_train, y_train, h=0.0005, min_iterations=500)
test_svm.init_r(5)
```

```
[[1.         0.44444444 0.41666667]
 [1.         0.41666667 0.25      ]
 [1.         0.69444444 0.41666667]
 [1.         0.11111111 0.5       ]
 [1.         0.72222222 0.45833333]
 [1.         0.19444444 0.625     ]
 [1.         0.30555556 0.70833333]
 [1.         0.19444444 0.        ]
 [1.         0.61111111 0.41666667]
 [1.         0.66666667 0.54166667]
 [1.         0.47222222 0.08333333]
 [1.         0.66666667 0.20833333]
 [1.         0.36111111 0.20833333]
 [1.         0.94444444 0.41666667]
 [1.         0.55555556 0.54166667]
 [1.         0.33333333 0.16666667]
 [1.         0.55555556 0.29166667]
 [1.         0.55555556 0.33333333]
 [1.         0.16666667 0.20833333]
 [1.         0.55555556 0.20833333]
 [1.         0.75       0.5       ]
 [1.         0.61111111 0.41666667]
 [1.         0.47222222 0.58333333]
 [1.         0.13888889 0.45833333]
 [1.         0.41666667 0.29166667]
 [1.         0.36111111 0.29166667]
 [1.         0.36111111 0.375     ]
 [1.         0.33333333 0.20833333]
 [1.         0.5        0.41666667]
 [1.         0.80555556 0.5       ]
 [1.         0.27777778 0.70833333]
 [1.         0.         0.41666667]
 [1.         0.58333333 0.29166667]
 [1.         0.38888889 0.41666667]
 [1.         0.30555556 0.58333333]
 [1.         0.38888889 1.        ]
 [1.         0.72222222 0.45833333]
 [1.         0.08333333 0.45833333]
 [1.         0.44444444 0.41666667]
 [1.         0.22222222 0.20833333]
 [1.         0.08333333 0.58333333]
 [1.         0.52777778 0.08333333]
 [1.         0.80555556 0.66666667]
 [1.         0.38888889 0.375     ]
 [1.         0.13888889 0.41666667]
 [1.         0.77777778 0.41666667]
 [1.         0.72222222 0.5       ]
 [1.         0.61111111 0.41666667]
 [1.         0.58333333 0.33333333]
 [1.         0.22222222 0.75      ]
 [1.         0.13888889 0.58333333]
 [1.         0.61111111 0.5       ]
 [1.         0.66666667 0.54166667]
 [1.         0.05555556 0.125     ]
 [1.         0.52777778 0.58333333]
 [1.         0.16666667 0.41666667]
 [1.         0.38888889 0.20833333]
 [1.         0.72222222 0.45833333]
 [1.         0.02777778 0.5       ]
 [1.         0.19444444 0.66666667]
 [1.         0.80555556 0.41666667]
 [1.         0.22222222 0.625     ]
 [1.         0.02777778 0.41666667]
 [1.         0.30555556 0.79166667]
 [1.         0.33333333 0.125     ]
 [1.         0.69444444 0.5       ]
 [1.         0.91666667 0.41666667]
 [1.         0.22222222 0.625     ]
 [1.         0.16666667 0.45833333]
 [1.         0.25       0.58333333]
 [1.         0.38888889 0.33333333]
 [1.         0.63888889 0.41666667]
 [1.         0.19444444 0.5       ]
 [1.         0.22222222 0.54166667]
 [1.         0.58333333 0.375     ]
 [1.         0.30555556 0.58333333]
 [1.         0.94444444 0.25      ]
 [1.         0.16666667 0.16666667]
 [1.         1.         0.75      ]
 [1.         0.66666667 0.45833333]
 [1.         0.25       0.875     ]
 [1.         0.47222222 0.41666667]
 [1.         0.41666667 0.83333333]
 [1.         0.94444444 0.33333333]
 [1.         0.22222222 0.75      ]
 [1.         0.11111111 0.5       ]
 [1.         0.86111111 0.33333333]
 [1.         0.19444444 0.54166667]
 [1.         0.55555556 0.58333333]
 [1.         0.38888889 0.33333333]
 [1.         0.41666667 0.29166667]
 [1.         0.38888889 0.25      ]
 [1.         0.58333333 0.5       ]
 [1.         0.66666667 0.41666667]
 [1.         0.55555556 0.20833333]
 [1.         0.66666667 0.41666667]
```

```
[1.         0.19444444 0.41666667]
[1.         0.33333333 0.16666667]
[1.         0.66666667 0.45833333]
[1.         0.41666667 0.29166667]
[1.         0.22222222 0.58333333]
[1.         0.63888889 0.375     ]
[1.         0.36111111 0.41666667]
[1.         0.44444444 0.5       ]
[1.         0.55555556 0.125     ]
[1.         0.33333333 0.625     ]
[1.         0.22222222 0.70833333]
[1.         0.16666667 0.45833333]
[1.         0.55555556 0.375     ]
[1.         0.41666667 0.29166667]
[1.         0.94444444 0.75      ]
[1.         0.08333333 0.5       ]]
```

In [40]:
```
test_svm.fit()
```

Out[40]:
```
array([-0.975     , -2.156125  , -0.0791477 ,  0.75839291,  0.95748102,
        2.42424113,  0.17927104,  0.5970671 ,  0.89719135,  0.98050506,
        1.82609038,  0.91833883,  0.91529159,  0.97509192,  0.99494552,
        1.22737557,  1.0063809 ,  0.98742866,  0.99563211,  0.99905624,
        1.04358082,  1.00391296,  0.9985805 ,  0.99939269,  0.99986095])
```

Видим, что размерность растёт с квадратичной скоростью

In [41]:
```
test_svm_cntr = Counter(X_scaled_train, X_scaled_test, y_train, y_test, test_svm)
test_svm_cntr.try_model()
```

```
[[1.         0.44444444 0.41666667]
 [1.         0.41666667 0.25      ]
 [1.         0.69444444 0.41666667]
 [1.         0.11111111 0.5       ]
 [1.         0.72222222 0.45833333]
 [1.         0.19444444 0.625     ]
 [1.         0.30555556 0.70833333]
 [1.         0.19444444 0.        ]
 [1.         0.61111111 0.41666667]
 [1.         0.66666667 0.54166667]
 [1.         0.47222222 0.08333333]
 [1.         0.66666667 0.20833333]
 [1.         0.36111111 0.20833333]
 [1.         0.94444444 0.41666667]
 [1.         0.55555556 0.54166667]
 [1.         0.33333333 0.16666667]
 [1.         0.55555556 0.29166667]
 [1.         0.55555556 0.33333333]
 [1.         0.16666667 0.20833333]
 [1.         0.55555556 0.20833333]
 [1.         0.75       0.5       ]
 [1.         0.61111111 0.41666667]
 [1.         0.47222222 0.58333333]
 [1.         0.13888889 0.45833333]
 [1.         0.41666667 0.29166667]
 [1.         0.36111111 0.29166667]
 [1.         0.36111111 0.375     ]
 [1.         0.33333333 0.20833333]
 [1.         0.5        0.41666667]
 [1.         0.80555556 0.5       ]
 [1.         0.27777778 0.70833333]
 [1.         0.         0.41666667]
 [1.         0.58333333 0.29166667]
 [1.         0.38888889 0.41666667]
 [1.         0.30555556 0.58333333]
 [1.         0.38888889 1.        ]
 [1.         0.72222222 0.45833333]
 [1.         0.08333333 0.45833333]
 [1.         0.44444444 0.41666667]
 [1.         0.22222222 0.20833333]
 [1.         0.08333333 0.58333333]
 [1.         0.52777778 0.08333333]
 [1.         0.80555556 0.66666667]
 [1.         0.38888889 0.375     ]
 [1.         0.13888889 0.41666667]
 [1.         0.77777778 0.41666667]
 [1.         0.72222222 0.5       ]
 [1.         0.61111111 0.41666667]
 [1.         0.58333333 0.33333333]
 [1.         0.22222222 0.75      ]
 [1.         0.13888889 0.58333333]
 [1.         0.61111111 0.5       ]
 [1.         0.66666667 0.54166667]
 [1.         0.05555556 0.125     ]
 [1.         0.52777778 0.58333333]
 [1.         0.16666667 0.41666667]
 [1.         0.38888889 0.20833333]
 [1.         0.72222222 0.45833333]
 [1.         0.02777778 0.5       ]
 [1.         0.19444444 0.66666667]
 [1.         0.80555556 0.41666667]
 [1.         0.22222222 0.625     ]
 [1.         0.02777778 0.41666667]
 [1.         0.30555556 0.79166667]
 [1.         0.33333333 0.125     ]
 [1.         0.69444444 0.5       ]
 [1.         0.91666667 0.41666667]
 [1.         0.22222222 0.625     ]
 [1.         0.16666667 0.45833333]
 [1.         0.25       0.58333333]
 [1.         0.38888889 0.33333333]
 [1.         0.63888889 0.41666667]
 [1.         0.19444444 0.5       ]
 [1.         0.22222222 0.54166667]
 [1.         0.58333333 0.375     ]
 [1.         0.30555556 0.58333333]
 [1.         0.94444444 0.25      ]
 [1.         0.16666667 0.16666667]
 [1.         1.         0.75      ]
 [1.         0.66666667 0.45833333]
 [1.         0.25       0.875     ]
 [1.         0.47222222 0.41666667]
 [1.         0.41666667 0.83333333]
 [1.         0.94444444 0.33333333]
 [1.         0.22222222 0.75      ]
 [1.         0.11111111 0.5       ]
 [1.         0.86111111 0.33333333]
 [1.         0.19444444 0.54166667]
 [1.         0.55555556 0.58333333]
 [1.         0.38888889 0.33333333]
 [1.         0.41666667 0.29166667]
 [1.         0.38888889 0.25      ]
 [1.         0.58333333 0.5       ]
 [1.         0.66666667 0.41666667]
 [1.         0.55555556 0.20833333]
 [1.         0.66666667 0.41666667]
```

```
 [1.         0.19444444 0.41666667]
 [1.         0.33333333 0.16666667]
 [1.         0.66666667 0.45833333]
 [1.         0.41666667 0.29166667]
 [1.         0.22222222 0.58333333]
 [1.         0.63888889 0.375     ]
 [1.         0.36111111 0.41666667]
 [1.         0.44444444 0.5       ]
 [1.         0.55555556 0.125     ]
 [1.         0.33333333 0.625     ]
 [1.         0.22222222 0.70833333]
 [1.         0.16666667 0.45833333]
 [1.         0.55555556 0.375     ]
 [1.         0.41666667 0.29166667]
 [1.         0.94444444 0.75      ]
 [1.         0.08333333 0.5       ]]
[[1.         0.41666667 0.33333333]
 [1.         0.47222222 0.08333333]
 [1.         0.33333333 0.91666667]
 [1.         0.83333333 0.375     ]
 [1.         0.19444444 0.58333333]
 [1.         0.55555556 0.54166667]
 [1.         0.19444444 0.625     ]
 [1.         0.66666667 0.45833333]
 [1.         0.69444444 0.33333333]
 [1.         0.5        0.33333333]
 [1.         0.5        0.25      ]
 [1.         0.58333333 0.5       ]
 [1.         0.5        0.33333333]
 [1.         0.61111111 0.33333333]
 [1.         0.5        0.375     ]
 [1.         0.16666667 0.45833333]
 [1.         0.47222222 0.375     ]
 [1.         0.33333333 0.25      ]
 [1.         0.13888889 0.41666667]
 [1.         0.30555556 0.79166667]
 [1.         0.36111111 0.33333333]
 [1.         0.36111111 0.41666667]
 [1.         0.13888889 0.58333333]
 [1.         0.02777778 0.375     ]
 [1.         0.52777778 0.33333333]
 [1.         0.08333333 0.66666667]
 [1.         0.22222222 0.75      ]
 [1.         0.52777778 0.375     ]
 [1.         0.19444444 0.125     ]
 [1.         0.19444444 0.58333333]
 [1.         0.58333333 0.45833333]
 [1.         0.30555556 0.41666667]
 [1.         0.25       0.625     ]
 [1.         0.5        0.41666667]
 [1.         0.58333333 0.33333333]
 [1.         0.25       0.29166667]
 [1.         0.38888889 0.75      ]
 [1.         0.47222222 0.29166667]]
[[1.         0.44444444 0.41666667]
 [1.         0.41666667 0.25      ]
 [1.         0.69444444 0.41666667]
 [1.         0.11111111 0.5       ]
 [1.         0.72222222 0.45833333]
 [1.         0.19444444 0.625     ]
 [1.         0.30555556 0.70833333]
 [1.         0.19444444 0.        ]
 [1.         0.61111111 0.41666667]
 [1.         0.66666667 0.54166667]
 [1.         0.47222222 0.08333333]
 [1.         0.66666667 0.20833333]
 [1.         0.36111111 0.20833333]
 [1.         0.94444444 0.41666667]
 [1.         0.55555556 0.54166667]
 [1.         0.33333333 0.16666667]
 [1.         0.55555556 0.29166667]
 [1.         0.55555556 0.33333333]
 [1.         0.16666667 0.20833333]
 [1.         0.55555556 0.20833333]
 [1.         0.75       0.5       ]
 [1.         0.61111111 0.41666667]
 [1.         0.47222222 0.58333333]
 [1.         0.13888889 0.45833333]
 [1.         0.41666667 0.29166667]
 [1.         0.36111111 0.29166667]
 [1.         0.36111111 0.375     ]
 [1.         0.33333333 0.20833333]
 [1.         0.5        0.41666667]
 [1.         0.80555556 0.5       ]
 [1.         0.27777778 0.70833333]
 [1.         0.         0.41666667]
 [1.         0.58333333 0.29166667]
 [1.         0.38888889 0.41666667]
 [1.         0.30555556 0.58333333]
 [1.         0.38888889 1.        ]
 [1.         0.72222222 0.45833333]
 [1.         0.08333333 0.45833333]
 [1.         0.44444444 0.41666667]
 [1.         0.22222222 0.20833333]
 [1.         0.08333333 0.58333333]
 [1.         0.52777778 0.08333333]
```

```
 [1.         0.80555556 0.66666667]
 [1.         0.38888889 0.375     ]
 [1.         0.13888889 0.41666667]
 [1.         0.77777778 0.41666667]
 [1.         0.72222222 0.5       ]
 [1.         0.61111111 0.41666667]
 [1.         0.58333333 0.33333333]
 [1.         0.22222222 0.75      ]
 [1.         0.13888889 0.58333333]
 [1.         0.61111111 0.5       ]
 [1.         0.66666667 0.54166667]
 [1.         0.05555556 0.125     ]
 [1.         0.52777778 0.58333333]
 [1.         0.16666667 0.41666667]
 [1.         0.38888889 0.20833333]
 [1.         0.72222222 0.45833333]
 [1.         0.02777778 0.5       ]
 [1.         0.19444444 0.66666667]
 [1.         0.80555556 0.41666667]
 [1.         0.22222222 0.625     ]
 [1.         0.02777778 0.41666667]
 [1.         0.30555556 0.79166667]
 [1.         0.33333333 0.125     ]
 [1.         0.69444444 0.5       ]
 [1.         0.91666667 0.41666667]
 [1.         0.22222222 0.625     ]
 [1.         0.16666667 0.45833333]
 [1.         0.25       0.58333333]
 [1.         0.38888889 0.33333333]
 [1.         0.63888889 0.41666667]
 [1.         0.19444444 0.5       ]
 [1.         0.22222222 0.54166667]
 [1.         0.58333333 0.375     ]
 [1.         0.30555556 0.58333333]
 [1.         0.94444444 0.25      ]
 [1.         0.16666667 0.16666667]
 [1.         1.         0.75      ]
 [1.         0.66666667 0.45833333]
 [1.         0.25       0.875     ]
 [1.         0.47222222 0.41666667]
 [1.         0.41666667 0.83333333]
 [1.         0.94444444 0.33333333]
 [1.         0.22222222 0.75      ]
 [1.         0.11111111 0.5       ]
 [1.         0.86111111 0.33333333]
 [1.         0.19444444 0.54166667]
 [1.         0.55555556 0.58333333]
 [1.         0.38888889 0.33333333]
 [1.         0.41666667 0.29166667]
 [1.         0.38888889 0.25      ]
 [1.         0.58333333 0.5       ]
 [1.         0.66666667 0.41666667]
 [1.         0.55555556 0.20833333]
 [1.         0.66666667 0.41666667]
 [1.         0.19444444 0.41666667]
 [1.         0.33333333 0.16666667]
 [1.         0.66666667 0.45833333]
 [1.         0.41666667 0.29166667]
 [1.         0.22222222 0.58333333]
 [1.         0.63888889 0.375     ]
 [1.         0.36111111 0.41666667]
 [1.         0.44444444 0.5       ]
 [1.         0.55555556 0.125     ]
 [1.         0.33333333 0.625     ]
 [1.         0.22222222 0.70833333]
 [1.         0.16666667 0.45833333]
 [1.         0.55555556 0.375     ]
 [1.         0.41666667 0.29166667]
 [1.         0.94444444 0.75      ]
 [1.         0.08333333 0.5       ]]
[[1.         0.41666667 0.33333333]
 [1.         0.47222222 0.08333333]
 [1.         0.33333333 0.91666667]
 [1.         0.83333333 0.375     ]
 [1.         0.19444444 0.58333333]
 [1.         0.55555556 0.54166667]
 [1.         0.19444444 0.625     ]
 [1.         0.66666667 0.45833333]
 [1.         0.69444444 0.33333333]
 [1.         0.5        0.33333333]
 [1.         0.5        0.25      ]
 [1.         0.58333333 0.5       ]
 [1.         0.5        0.33333333]
 [1.         0.61111111 0.33333333]
 [1.         0.5        0.375     ]
 [1.         0.16666667 0.45833333]
 [1.         0.47222222 0.375     ]
 [1.         0.33333333 0.25      ]
 [1.         0.13888889 0.41666667]
 [1.         0.30555556 0.79166667]
 [1.         0.36111111 0.33333333]
 [1.         0.36111111 0.41666667]
 [1.         0.13888889 0.58333333]
 [1.         0.02777778 0.375     ]
 [1.         0.52777778 0.33333333]
 [1.         0.08333333 0.66666667]
```

```
 [1.         0.22222222 0.75      ]
 [1.         0.52777778 0.375     ]
 [1.         0.19444444 0.125     ]
 [1.         0.19444444 0.58333333]
 [1.         0.58333333 0.45833333]
 [1.         0.30555556 0.41666667]
 [1.         0.25       0.625     ]
 [1.         0.5        0.41666667]
 [1.         0.58333333 0.33333333]
 [1.         0.25       0.29166667]
 [1.         0.38888889 0.75      ]
 [1.         0.47222222 0.29166667]]
Метрики для тренировочной выборки
accuracy: 0.973
precision: 0.947
recall: 0.973
f1: 0.960

Метрики для тестовой выборки
accuracy: 0.974
precision: 1.000
recall: 0.923
f1: 0.960
Матрица ошибок, полученная методом confusion_matrix
 [[73  2]
 [ 1 36]]
```

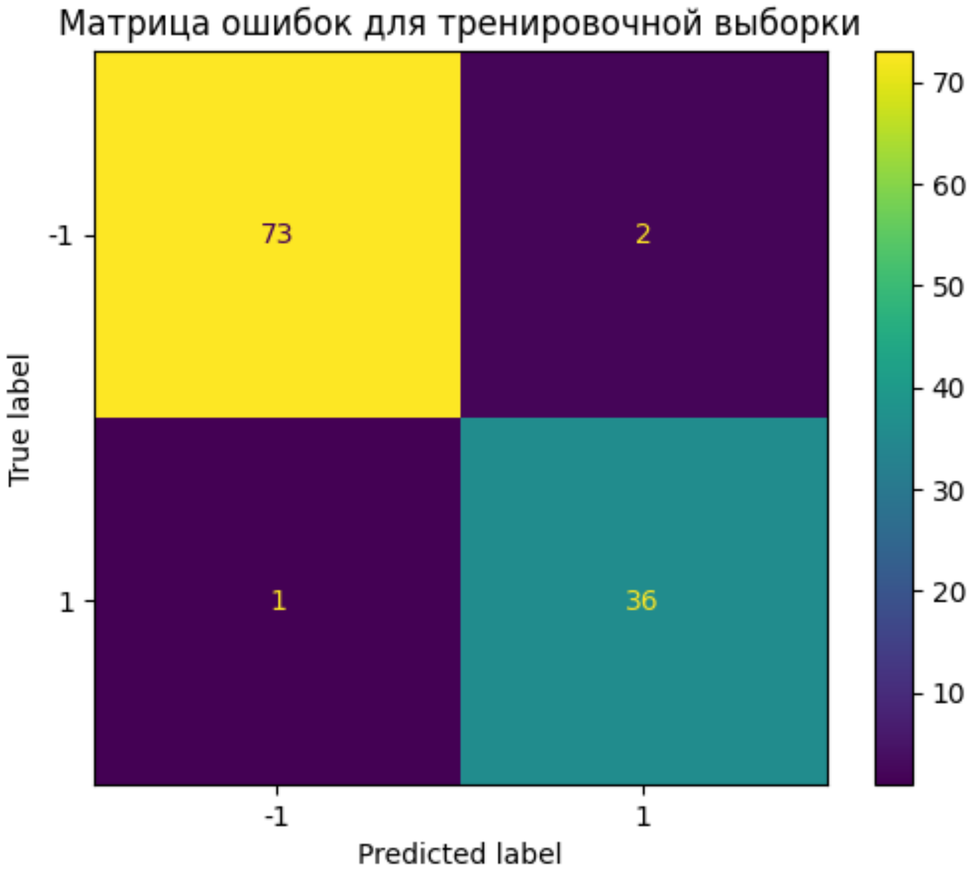


```
Матрица ошибок, полученная методом confusion_matrix
 [[25  0]
 [ 1 12]]
```

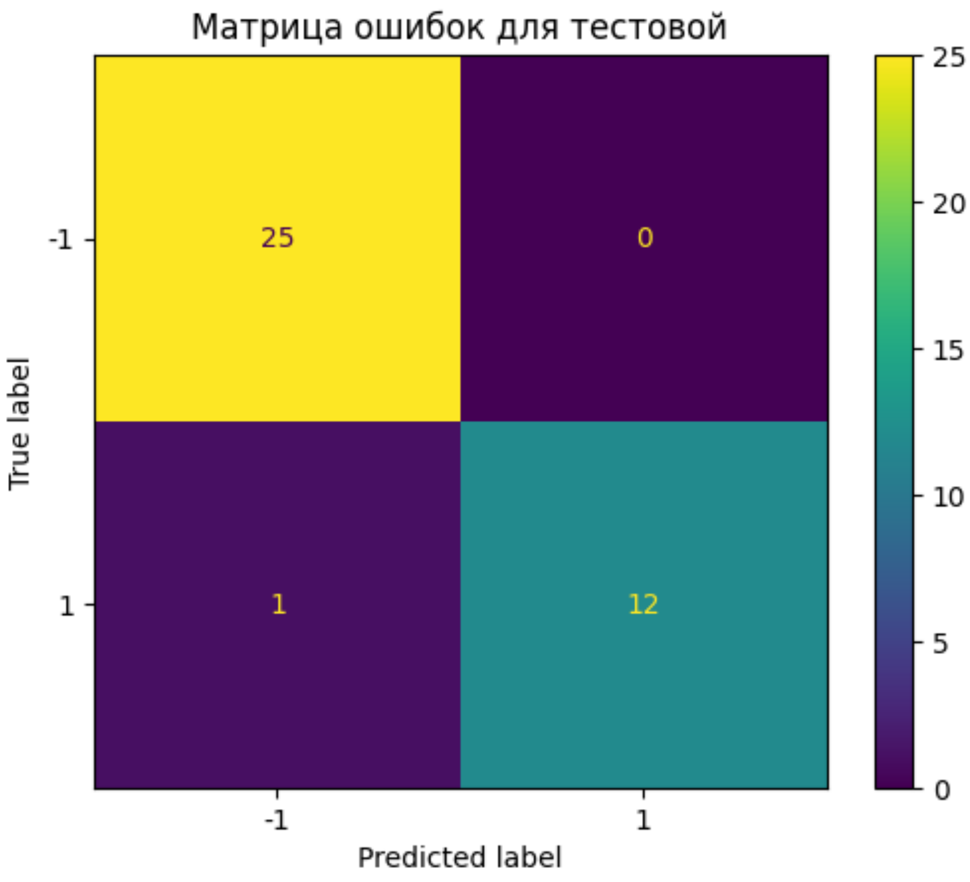

Получилось не хуже, чем в прошлых разах

In [42]:
```
x1 = np.arange(-10, 10, 0.05)
x2 = np.arange(-10, 10, 0.05)


xgrid, ygrid = np.meshgrid(x1, x2)


wid = test_svm.width
w = test_svm.w
```

```
C = np.zeros(( x1.shape[0], x1.shape[0], test_svm.width))
new_x1 = np.zeros(( int(wid**(1/2)), x1.shape[0], x1.shape[0]))
new_x2 = np.zeros(( int(wid**(1/2)), x1.shape[0], x1.shape[0]))

for x in range(int(wid**(1/2))):
    new_x1[x] = -(1 - xgrid)**(2*x)/math.factorial(x)
    new_x2[x] = -(1 - ygrid)**(2*x)/math.factorial(x)

for i in range(int(wid**(1/2))):
    for j in range(int(wid**(1/2))):

        C[: , :, i * int(wid**(1/2)) + j] = new_x1.T[:, :,  i] * new_x2.T[:, :, j]


z = np.ones((C.shape[0], C.shape[1]))
for i in range(C.shape[0]):
    for j in range(C.shape[1]):
        z[i, j] = (C[i, j, :]*w).sum()



fig = plt.figure(figsize=(12, 12))
ax = fig.add_subplot(221)
plt.xlim(-1, 2)
plt.ylim(-1, 2)
plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_scaled_test[:, 1], X_scaled_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")
ax.set_aspect('equal', adjustable='box')
ax.set_title('Тестовая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")

ax = fig.add_subplot(222)


plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_scaled_train[:, 1], X_scaled_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")
plt.xlim(-1, 2)
plt.ylim(-1, 2)
ax.set_aspect('equal', adjustable='box')
ax.set_title('Обучающая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
ax = fig.add_subplot(223)

ax.set_aspect('equal', adjustable='box')

plt.contourf(x1, x2, z, cmap="jet")
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])

plt.show()
```

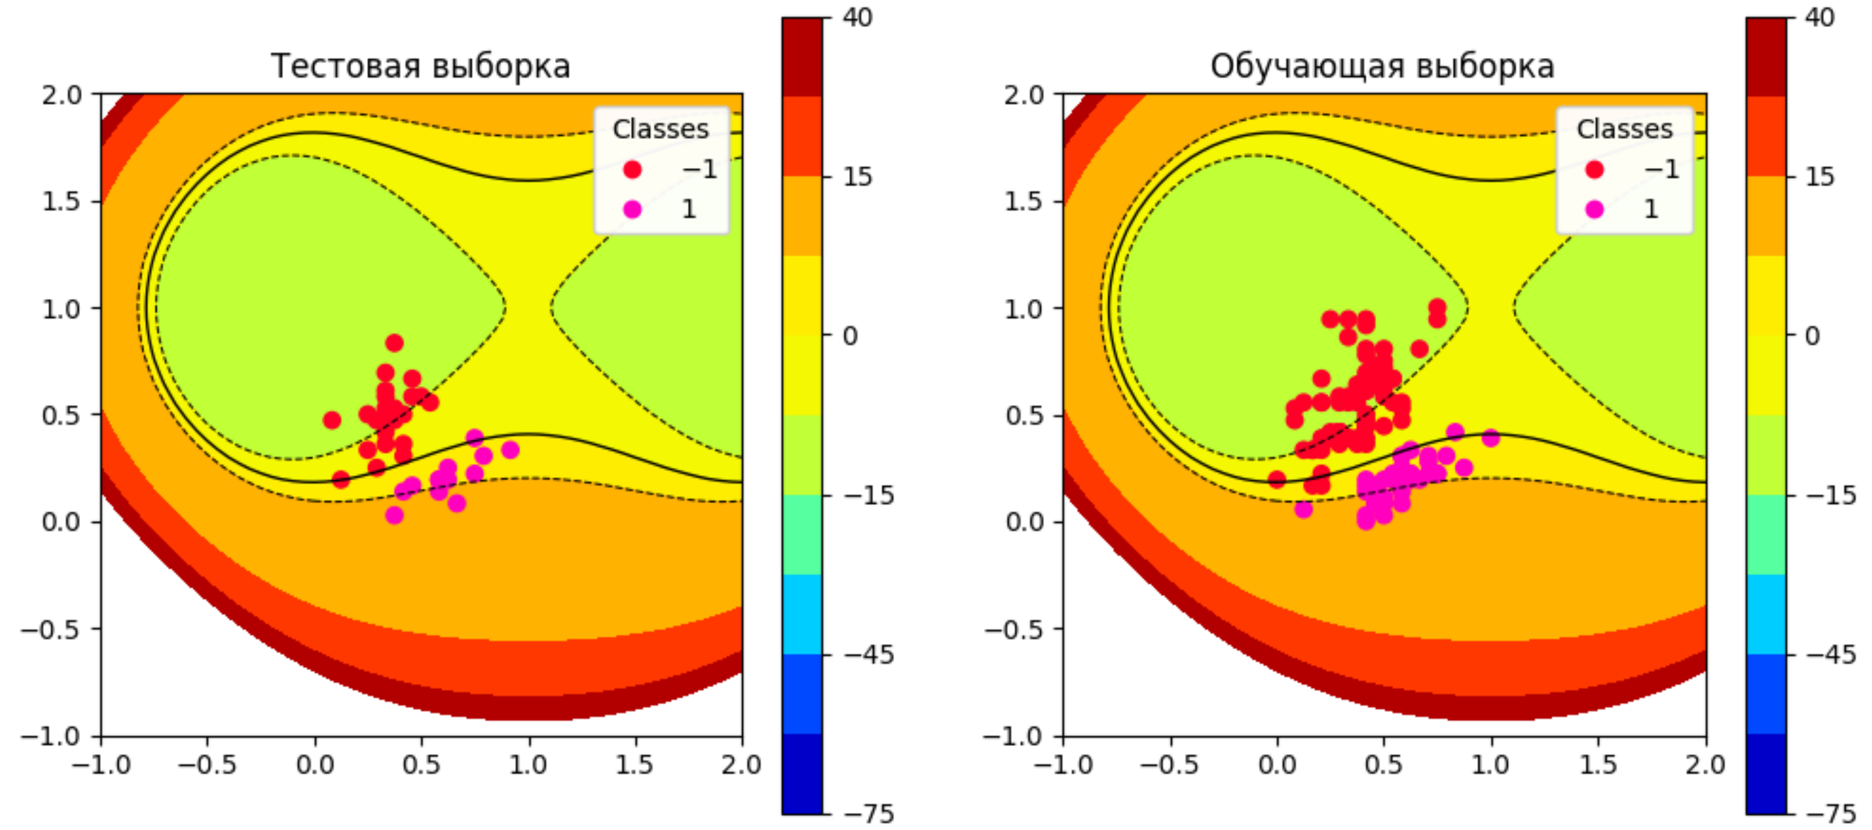

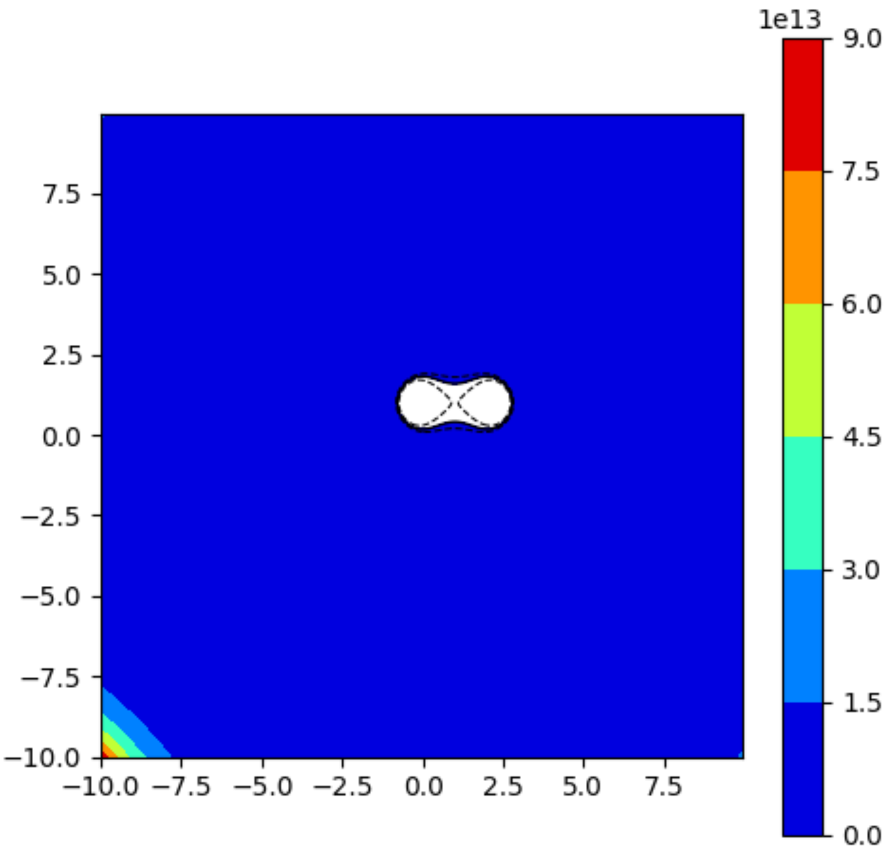

Получилось достаточно интересное ядро. На самом деле вряд ли можно его назвать гауссовым, скорее это апроксимация гауссова ядра с помошью полиномиального ядра. Выглядит красиво. На этих данных модель скорее переобучилась - слишком хорошо подстроилась под исходные точки, однако, для более сложных и запутанных распределений данных такое едро будет работать заметно лучше чем линейное или квадратичное.

In [43]:
```
ax = plt.axes(projection ='3d')
ax.plot3D(xgrid, ygrid, z, 'green')
ax.set_title('3D')
ax.set_xlim(-1, 2)
ax.set_ylim(-1, 2)
ax.set_zlim(-1, 2)
plt.show()
```

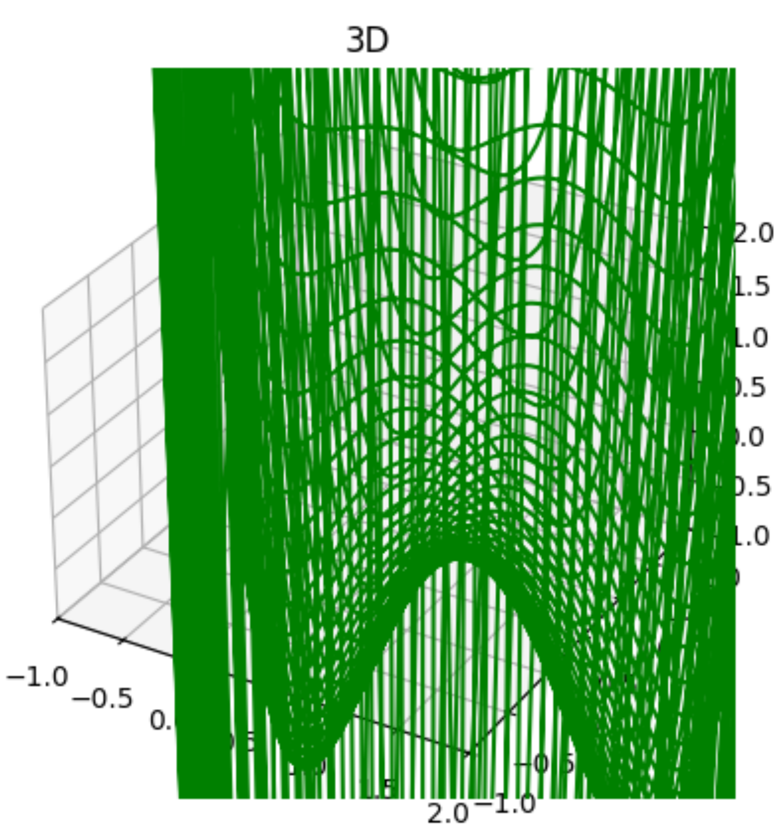

Тут хотели вывести трёхмерный график. Вероятно мы просчитались - но где?

Задание 2

Текст задания

Найдите датасет с 50+ объектами с 2-мя числовыми признаками (или сгенерируйте датасет программно с интерпретацией признаков с 100+ объектами), для которого линейная классификация SVM достаточно проблемна, а квадратичная даёт качественные результаты. Покажите это практическими расчётами +2 балла.

Пояснения

Нарисуем две окружности с одним центром, но разными радиусами, тогда svm с квадратичным ядром разделит две выборки, а линейное не сможет

In [44]:
```
from sklearn.datasets import make_circles
```

In [45]:
```
X_blob, y_blob =  make_circles(
    n_samples=150, factor=0.5, noise=0.05, random_state=170
)
```

In [46]:
```
y_blob = pd.DataFrame(y_blob)
y_blob.head()
```

Out[46]:

	0
0	0
1	1
2	1
3	0
4	0

Сгенерировали датасет

In [47]:
```
y_blob[0] = y_blob[0].apply(lambda x: x - int(x == 0))
```

In [48]:
```
y_blob = y_blob[0].to_numpy().reshape(-1, 1)
```

In [49]:
```
fig = plt.figure(figsize=(12, 12))
ax = fig.add_subplot(221)


scatter = ax.scatter(X_blob[:, 1], X_blob[:, 0], c=y_blob, cmap="gist_rainbow", marker="o")
```

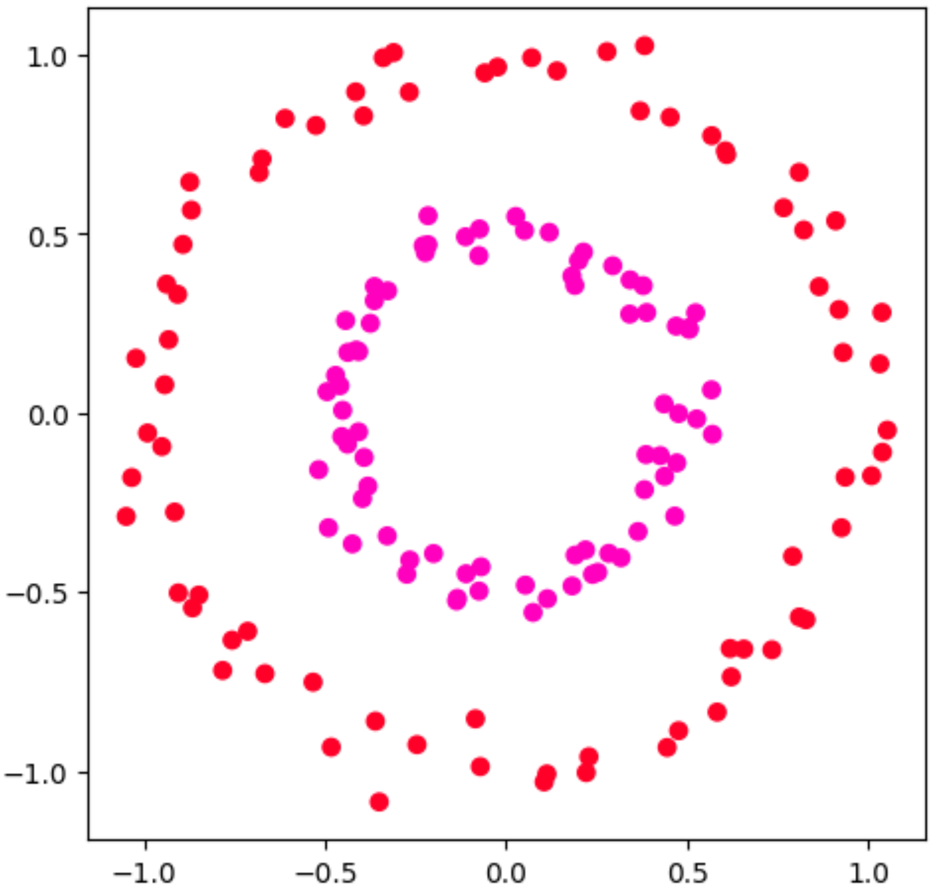

Получилось вот такое интересное распределение

In [50]:
```
X_blob_train, X_blob_test, y_blob_train, y_blob_test = train_test_split(X_blob, y_blob, test_size=0.33, random_state=19)
```

In [51]:
```
blob_svm = SupportVectorMachine(X_blob_train, y_blob_train, h=0.0005, min_iterations=1000, logging=False)
blob_svm.fit()
print()
```

In [52]:
```
blob_qsvm = QuadraSupportVectorMachine(X_blob_train, y_blob_train, h=0.0005, min_iterations=1000)
blob_qsvm.fit()
print()
```

In [53]:
```python
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)

w = blob_svm.w

xgrid, ygrid = np.meshgrid(x1, x2)
z = w[0] + w[2] * xgrid + w[1]*ygrid


# Обучающая выборка
fig = plt.figure(figsize=(12, 12))


ax = fig.add_subplot(223)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.colorbar()
scatter = ax.scatter(X_blob_test[:, 1], X_blob_test[:, 0], c=y_blob_test, cmap="gist_rainbow", marker="o")


plt.xlim(-1.5, 1.5)
plt.ylim(-1.5, 2.5)

ax.set_aspect('equal', adjustable='box')
ax.set_title('Линейное SVM, тестовая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
ax = fig.add_subplot(221)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.colorbar()
scatter = ax.scatter(X_blob_train[:, 1], X_blob_train[:, 0], c=y_blob_train, cmap="gist_rainbow", marker="o")


plt.xlim(-1.5, 1.5)
plt.ylim(-1.5, 2.5)

ax.set_aspect('equal', adjustable='box')
ax.set_title('Линейное SVM, обучающая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)

w = blob_qsvm.w
z = w[0] + w[1]*xgrid**2 + w[2]*ygrid**2 + w[3]*xgrid + w[4]*ygrid + w[5]*xgrid*ygrid


ax = fig.add_subplot(222)

plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_blob_train[:, 1], X_blob_train[:, 0], c=y_blob_train, cmap="gist_rainbow", marker="o")
ax.set_aspect('equal', adjustable='box')
ax.set_title('Квадратичное SVM, обучающая выборка')
plt.xlim(-1.5, 1.5)
plt.ylim(-1.5, 2.5)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")


ax = fig.add_subplot(224)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40], linestyles=["--", '-', '--'])
plt.colorbar()
scatter = ax.scatter(X_blob_test[:, 1], X_blob_test[:, 0], c=y_blob_test, cmap="gist_rainbow", marker="o")


plt.xlim(-1.5, 1.5)
plt.ylim(-1.5, 2.5)

ax.set_aspect('equal', adjustable='box')
ax.set_title('Квадратичное SVM, тестовая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
```

```
---------------------------------------------------------------------------
IndexError                                Traceback (most recent call last)
Cell In[53], line 52
     49 ax.add_artist(legend1)
     51 w = blob_qsvm.w
---> 52 z = w[0] + w[1]*xgrid**2 + w[2]*ygrid**2 + w[3]*xgrid + w[4]*ygrid + w[5]*xgrid*ygrid
     55 ax = fig.add_subplot(222)
     57 plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])

IndexError: index 3 is out of bounds for axis 0 with size 3
```

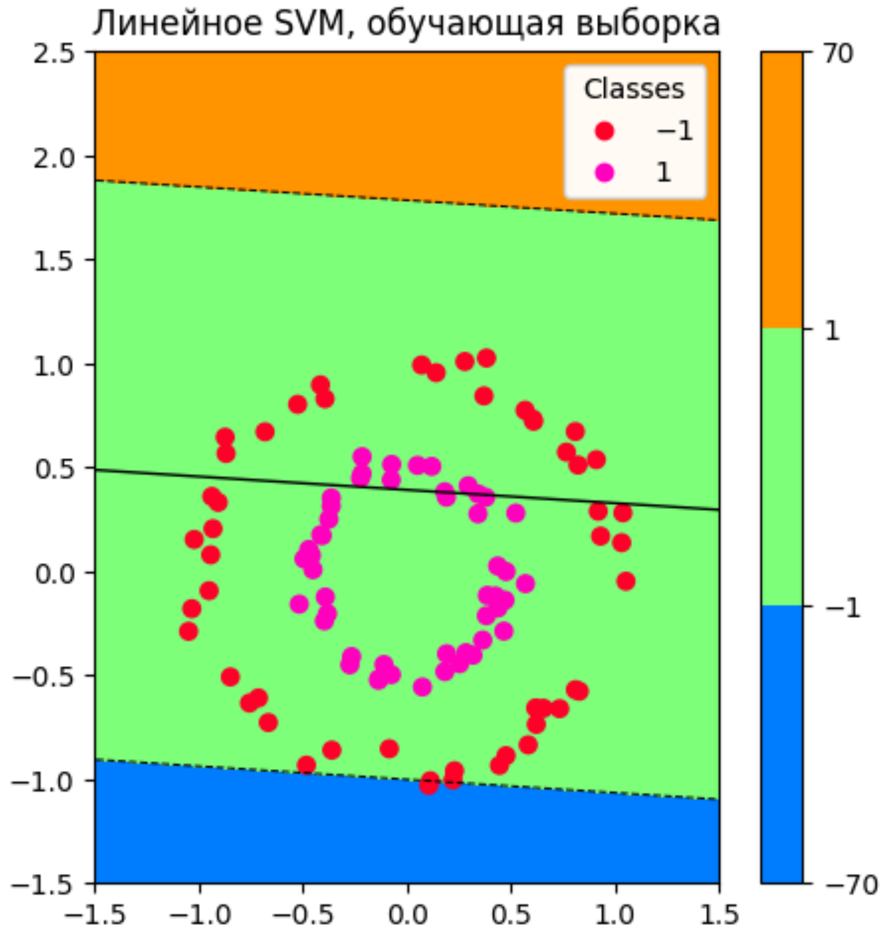

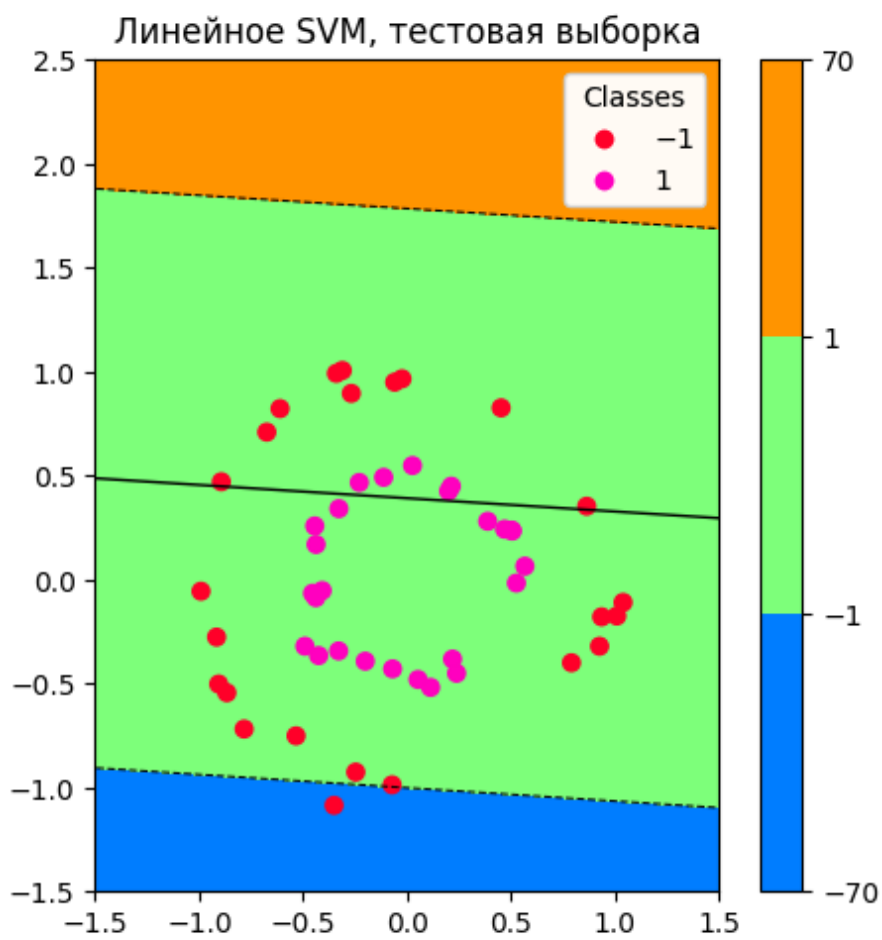

Как мы видим, квадратичное ядро справилось с классификацией на ура, а вот линейное нам тут не поможет. В модели с квадратичным ядром оптимальное разбиение, а также такая # 1 и 2 Задания

3 задание дополнительное

1 и 2 задания

Текст заданий

1 Следует привести задачу классификации к бинарной. Т.е. рассматриваем ирисы 2-х классов: Setosa и non-Setosa.

2 Из признаков оставляем только 2: sepal length и sepal width.

Небольшие пояснения

Оставляем признаки "sepal_length" и "petal_length", а также выделяем variety в отдельный dataframe. Класс iris-virginica помечаем 1, остальные классы помечаем -1.

In [65]:
```
y = pd.DataFrame()
X = df[["sepal_length", "sepal_width"]].to_numpy() #отбираем нужные признаки
y['variety'] = df["variety"].apply(lambda x: int(x == "Iris-virginica") - int(x != "Iris-virginica")) #функция для 1 и -1
y = y[['variety']].to_numpy() #переводим в пиру так как наш градиентный спуск работает с нампаем
```

In [66]:
```
print("Матрица признаков объектов:")
print(X[:10])
print("\nМатрица-столбец меток классов:")
print(y[45:55])
```

```
Матрица признаков объектов:
[[5.1 3.5]
 [4.9 3. ]
 [4.7 3.2]
 [4.6 3.1]
 [5.  3.6]
 [5.4 3.9]
 [4.6 3.4]
 [5.  3.4]
 [4.4 2.9]
 [4.9 3.1]]

Матрица-столбец меток классов:
[[-1]
 [-1]
 [-1]
 [-1]
 [-1]
 [-1]
 [-1]
 [-1]
 [-1]
 [-1]]
```

Выводы по первому и второму заданию

Импортировали данные и убедились в их корректности. Данные нам известные и хорошо знакомые.

Задание 3

Текст задания

Выполните процедуру классификации 3 раза. В рамках данной процедуры:

- Разбейте выборку случайным образом на обучающую (100 объектов) и тестовую.
- Проведите на обучающей выборке обучение с линейной моделью SVM и выведите диаграмму рассеяния классов с линией гиперплоскости разделения.
- Приведите формулу разделяющей гиперплоскости.
- Оцените точность классификации на тестовой и обучающей выборках.

Первая модель(три в одном)

Разбиение выборки на обучающую (мы помним, что объектов 150, потому параметр тестовой части 0.33, чтобы в обучающей было 100)

In [67]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=19) #устанавливаем random_state 19, чтобы не
```

Проведите на обучающей выборке обучение с линейной моделью SVM и выведите диаграмму рассеяния классов с линией гиперплоскости разделения. Мы хотим обучить тремя методами градиентного спуска и их сравнить для проведения дальнейших двух запусков

На первом запуске будем сравнивать пакетный, mini-batch и стохастический, на остальных двух будем запускать только один из них

Пакетный градиентный спуск

In [68]:
```
svm = SupportVectorMachine(X_train,y_train, h=0.005, min_iterations=1000) #вызываем пакетный градиентный спуск
w_ = svm.fit()  #веса
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
-15.000 + 3.961 x1 + -4.761 x2 = 0
```

Посчитаем метрики

In [69]:
```
cntr_svm = Counter(X_train, X_test, y_train, y_test, svm)
cntr_svm.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.710
precision: 1.000
recall: 0.121
f1: 0.216

Метрики для тестовой выборки
accuracy: 0.700
precision: 1.000
recall: 0.118
f1: 0.211
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [29  4]]
```

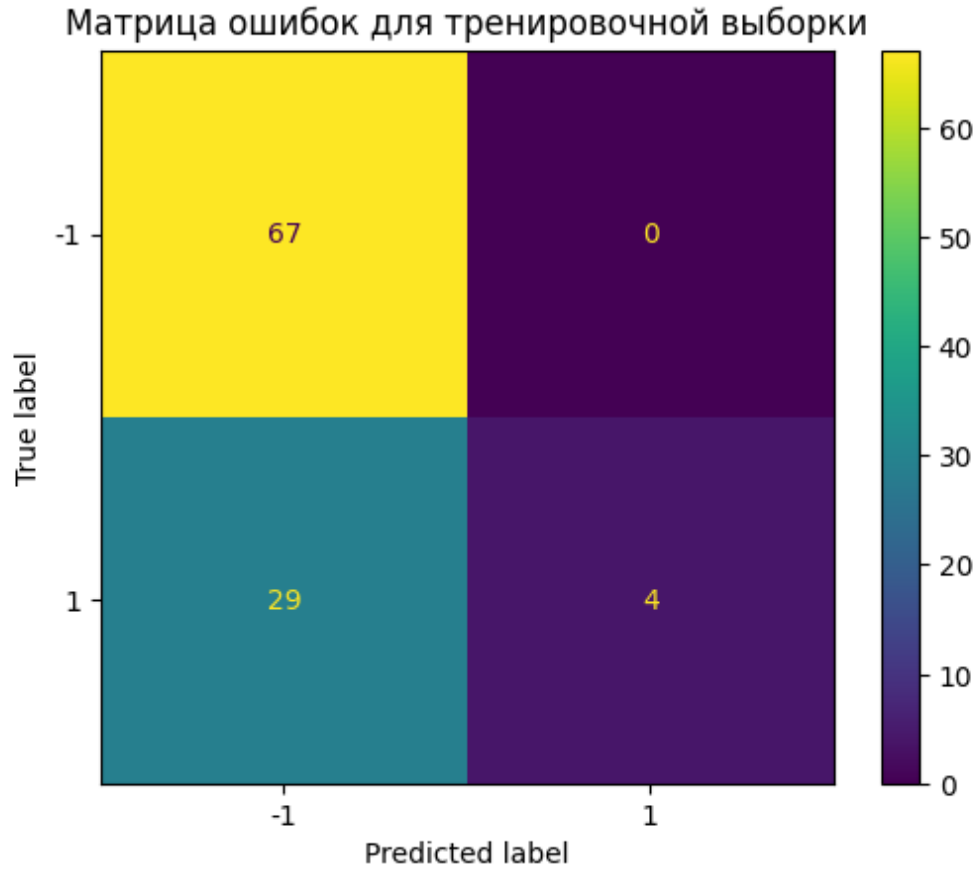


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [15  2]]
```

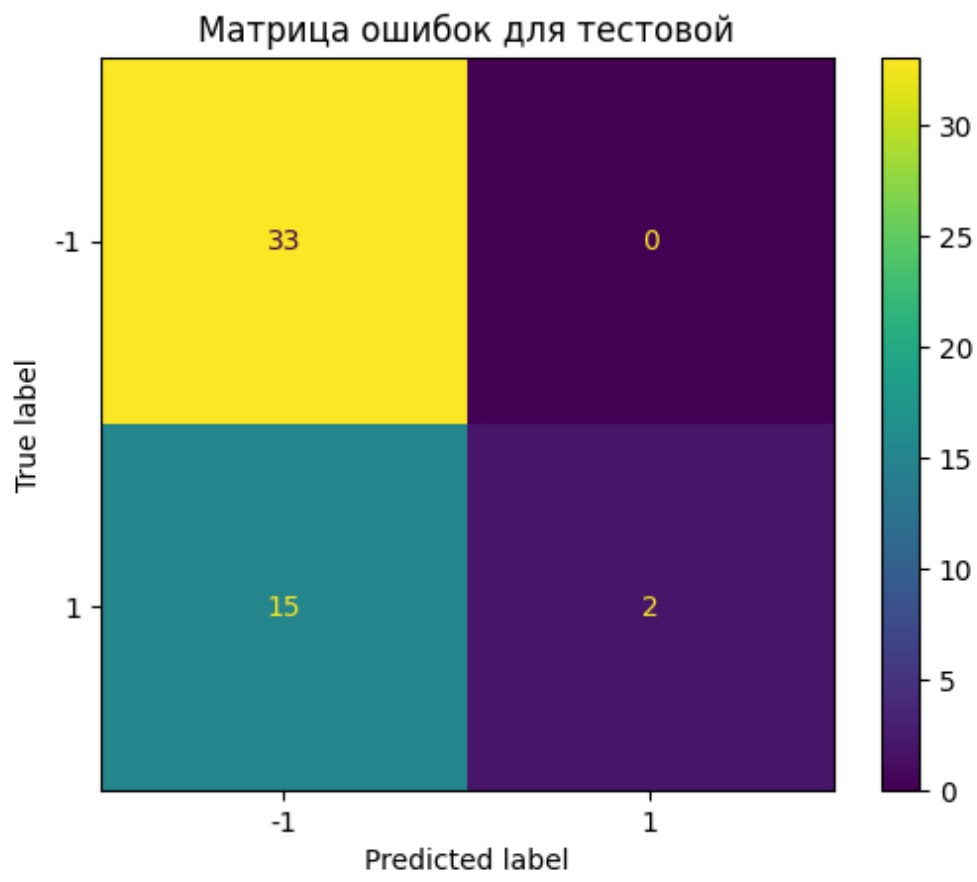

mini-batch

Всё то же самое для mini batch, но у него поменяем шаг, чтобы не разошелся

In [70]:
```
svm_mini_batch = SupportVectorMachine(X_train, y_train, h=0.005, min_iterations=1000, strategy='mini-batch', batch_size=10)
w_ = svm_mini_batch.fit()  #веса
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
-1.060 + 0.989 x1 + -1.721 x2 = 0
```

Вновь считаем метрики

In [71]:
```
cntr_svm_mini_batch = Counter(X_train, X_test, y_train, y_test, svm_mini_batch)
cntr_svm_mini_batch.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.720
precision: 0.556
recall: 0.758
f1: 0.641

Метрики для тестовой выборки
accuracy: 0.700
precision: 0.556
recall: 0.588
f1: 0.571
Матрица ошибок, полученная методом confusion_matrix
 [[47 20]
 [ 8 25]]
```

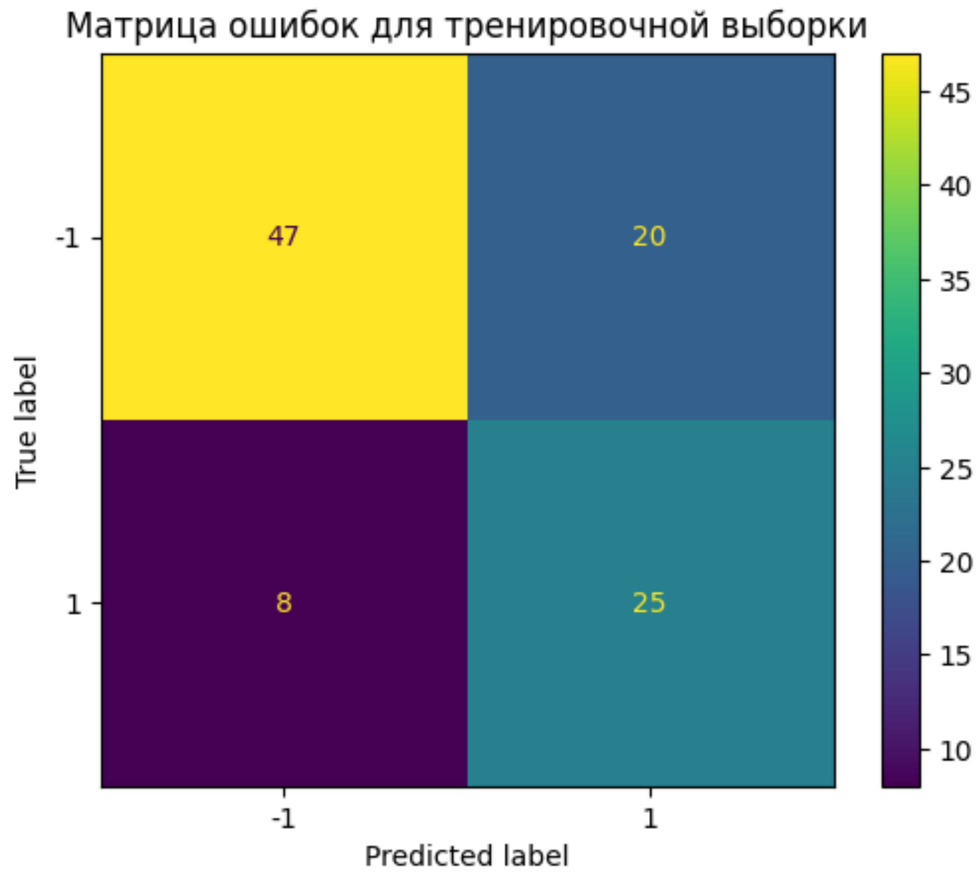


```
Матрица ошибок, полученная методом confusion_matrix
 [[25  8]
 [ 7 10]]
```

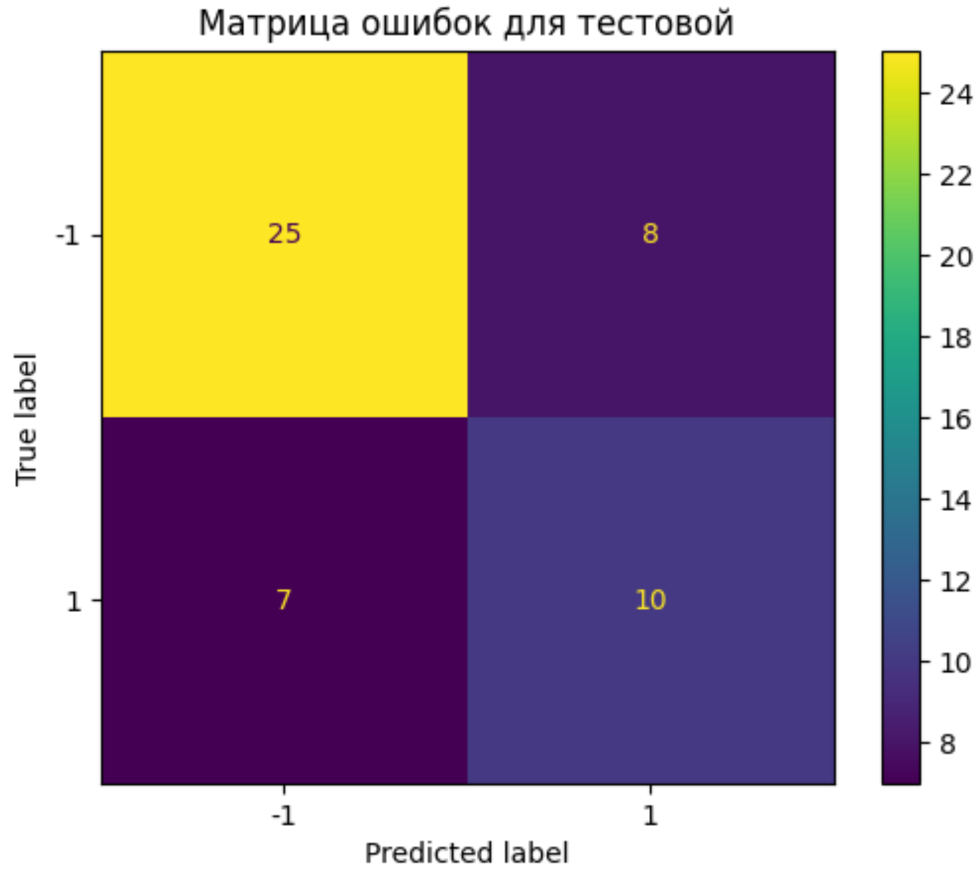

Стохастический градиентный спуск

Остался последний способ, реализованный у нас, это стохастический градиент спуск задаем те же параметры, что и у mini-batch

In [72]:
```
svm_stochastic = SupportVectorMachine(X_train, y_train, h=0.005, min_iterations=1000, strategy='stochastic')
w_ = svm_stochastic.fit()
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
0.475 + 0.118 x1 + -0.660 x2 = 0
```

Метрики для стохастического

In [73]:
```
cntr_svm_stochastic = Counter(X_train, X_test, y_train, y_test, svm_stochastic)
cntr_svm_stochastic.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.670
precision: 0.000
recall: 0.000
f1: 0.000

Метрики для тестовой выборки
accuracy: 0.660
precision: 0.000
recall: 0.000
f1: 0.000
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [33  0]]
```

```
C:\Users\Andrey\PycharmProjects\pythonProject\.venv\Lib\site-packages\sklearn\metrics\_classification.py:1531: UndefinedMetricWarnin
g: Precision is ill-defined and being set to 0.0 due to no predicted samples. Use `zero_division` parameter to control this behavio
r.
  _warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
C:\Users\Andrey\PycharmProjects\pythonProject\.venv\Lib\site-packages\sklearn\metrics\_classification.py:1531: UndefinedMetricWarnin
g: Precision is ill-defined and being set to 0.0 due to no predicted samples. Use `zero_division` parameter to control this behavio
r.
  _warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
```

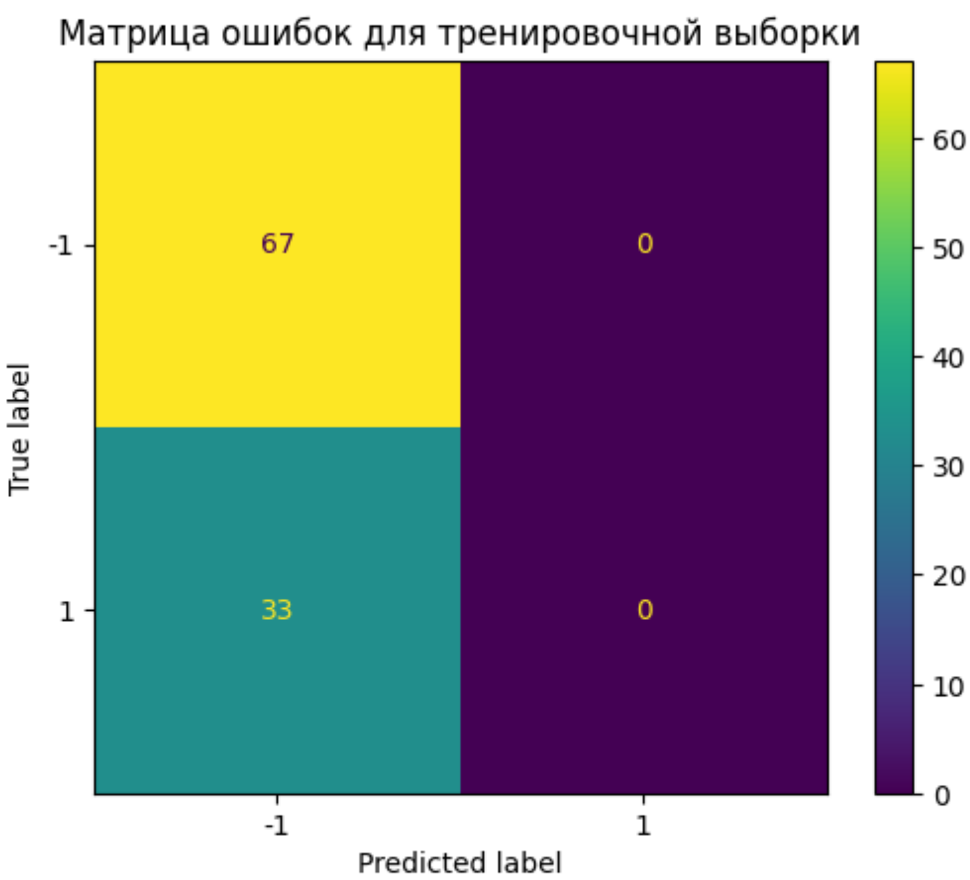


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [17  0]]
```

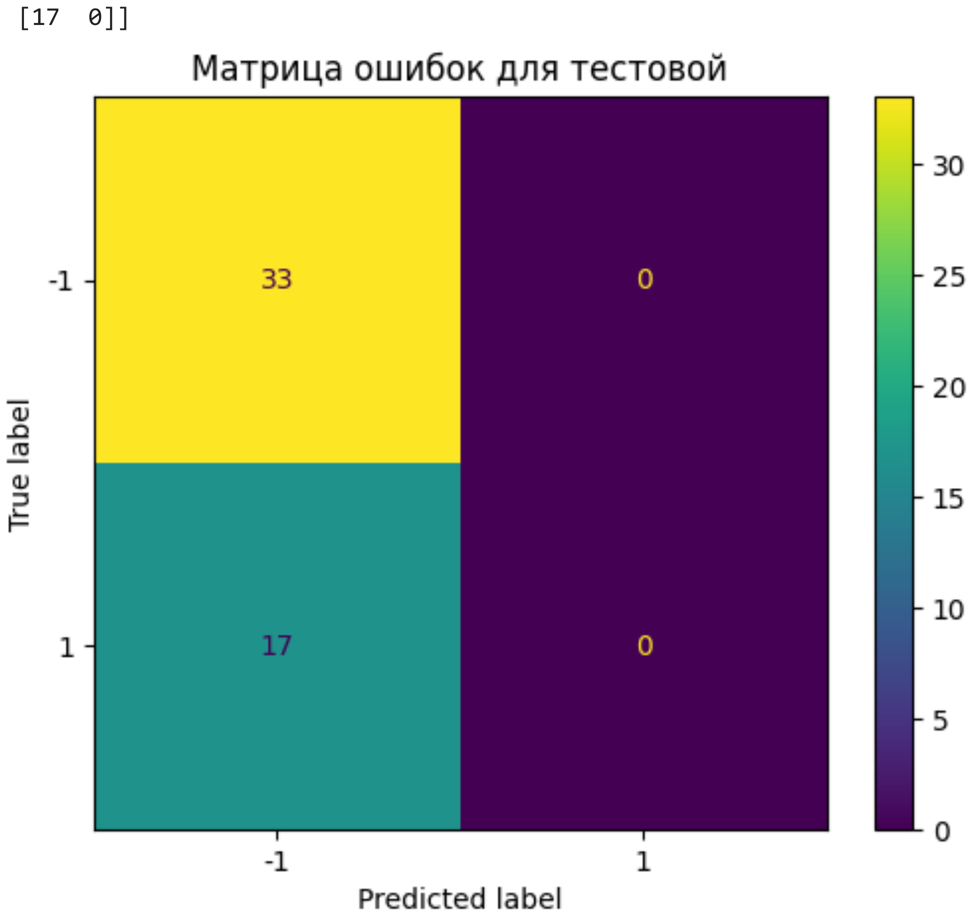

Разделяющая гиперплоскость для всех трех

Строим гиперплоскость всех троих способов разделения

In [75]:
```
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)


xgrid, ygrid = np.meshgrid(x1, x2)

svm_w = svm.w
svm_stochastic_w = svm_stochastic.w
svm_mini_batch_w = svm_mini_batch.w

svm_z = svm_w[0] + svm_w[2] * xgrid + svm_w[1]*ygrid
```

```
svm_stochastic_z = svm_stochastic_w[0] + svm_stochastic_w[2] * xgrid + svm_stochastic_w[1]*ygrid
svm_mini_batch_z = svm_mini_batch_w[0] + svm_mini_batch_w[2] * xgrid + svm_mini_batch_w[1]*ygrid

fig = plt.figure(figsize=(12, 12))

# Обучающая выборка

ax = fig.add_subplot(221)


scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")
plt.contour(x1, x2, svm_z, colors="yellow", levels=[0])
plt.contour(x1, x2, svm_stochastic_z, colors="black", levels=[0])
plt.contour(x1, x2, svm_mini_batch_z, colors="green", levels=[0])

svm_patch = mpatches.Patch(color="yellow", label='Пакетный градиентный спуск')
svm_s_patch = mpatches.Patch(color="black", label='Стохастический градиентный спуск')
svm_m_patch = mpatches.Patch(color="green", label='Mini-batch градиентный спуск')

plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

ax.set_title('Обучающая выборка')
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
ax.legend(handles=[svm_patch, svm_s_patch, svm_m_patch])


#тестовая выборка
ax = fig.add_subplot(222)

scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")

plt.contour(x1, x2, svm_z, colors="yellow", levels=[0])
plt.contour(x1, x2, svm_stochastic_z, colors="black", levels=[0])
plt.contour(x1, x2, svm_mini_batch_z, colors="green", levels=[0])

svm_patch = mpatches.Patch(color="yellow", label='Пакетный градиентный спуск')
svm_s_patch = mpatches.Patch(color="black", label='Стохастический градиентный спуск')
svm_m_patch = mpatches.Patch(color="green", label='Mini-batch градиентный спуск')

plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")

ax.set_title('Тестовая выборка')
ax.add_artist(legend1)

ax.legend(handles=[svm_patch, svm_s_patch, svm_m_patch])
```

Out[75]: <matplotlib.legend.Legend at 0x212bc5020c0>

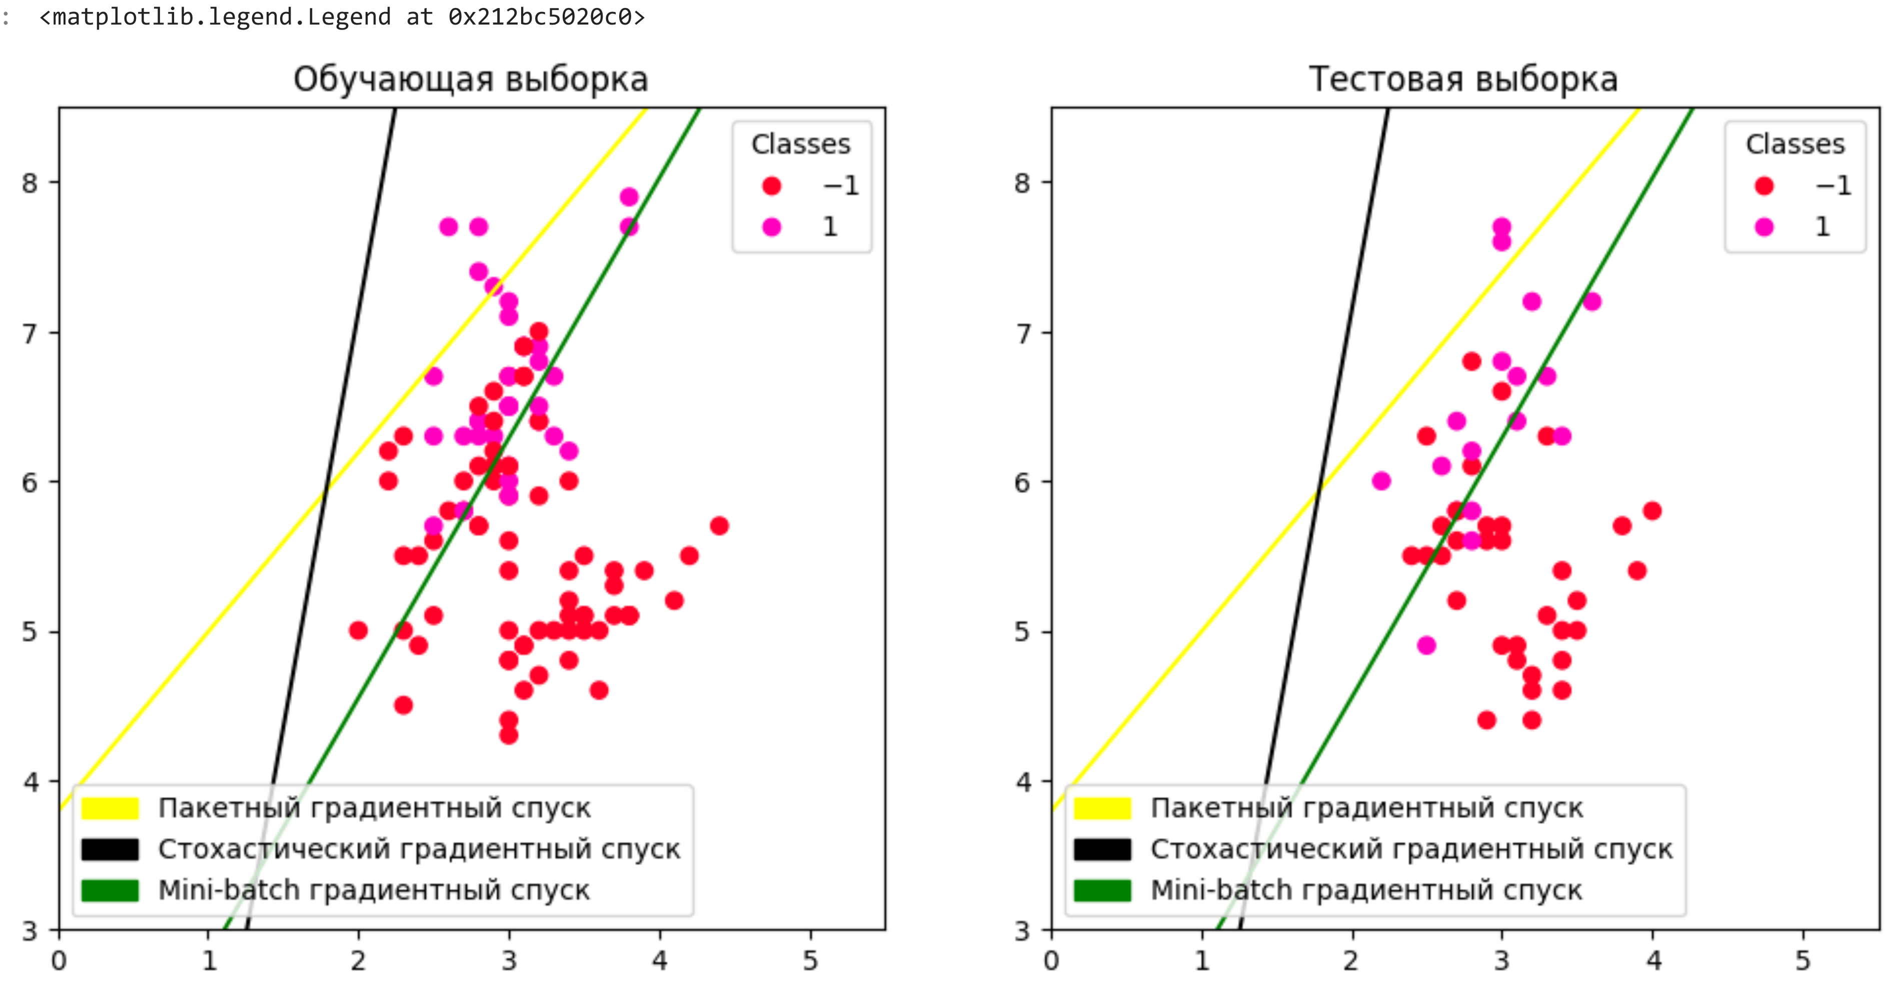

Мини-выводы

По итогу видно, что стохастический оказался худшим, а mini-batch показал лучшие метрики чем пакетный, это странно скорее всего повлиял случайный подсчет градиента, однако теперь для сравнения с остальными будем использовать его, ниже даже можно увидеть что стохастический с меньшей ошибкой оказался хуже пакетного по нашим метрикам

In [76]:
```
print(f"SVM с пакетной оптимизацией: {svm.q[0]:.02f}")
print(f"SVM с мини-батч оптимизацией: {svm_mini_batch.q[0]:.02f}")
print(f"SVM с стохастической оптимизацией: {svm_stochastic.q[0]:.02f}")
```

```
SVM с пакетной оптимизацией: 130.92
SVM с мини-батч оптимизацией: 60.82
SVM с стохастической оптимизацией: 69.47
```

Вторая модель(только пакетный)

Новое разбиение для новой модели

In [79]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=20, )
svm_2 = SupportVectorMachine(X_train,y_train,  h=0.0005, min_iterations=10000, strategy='mini-batch', batch_size=10)
svm_2.fit()  #веса
w_ = svm_2.fit()
```

In [80]:
```
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
-1.584 + 0.928 x1 + -1.266 x2 = 0
```

In [81]:
```
### Метрики
cntr_svm_2 = Counter(X_train, X_test, y_train, y_test, svm_2)
cntr_svm_2.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.710
precision: 0.550
recall: 0.943
f1: 0.695

Метрики для тестовой выборки
accuracy: 0.720
precision: 0.519
recall: 0.933
f1: 0.667
Матрица ошибок, полученная методом confusion_matrix
 [[38 27]
 [ 2 33]]
```

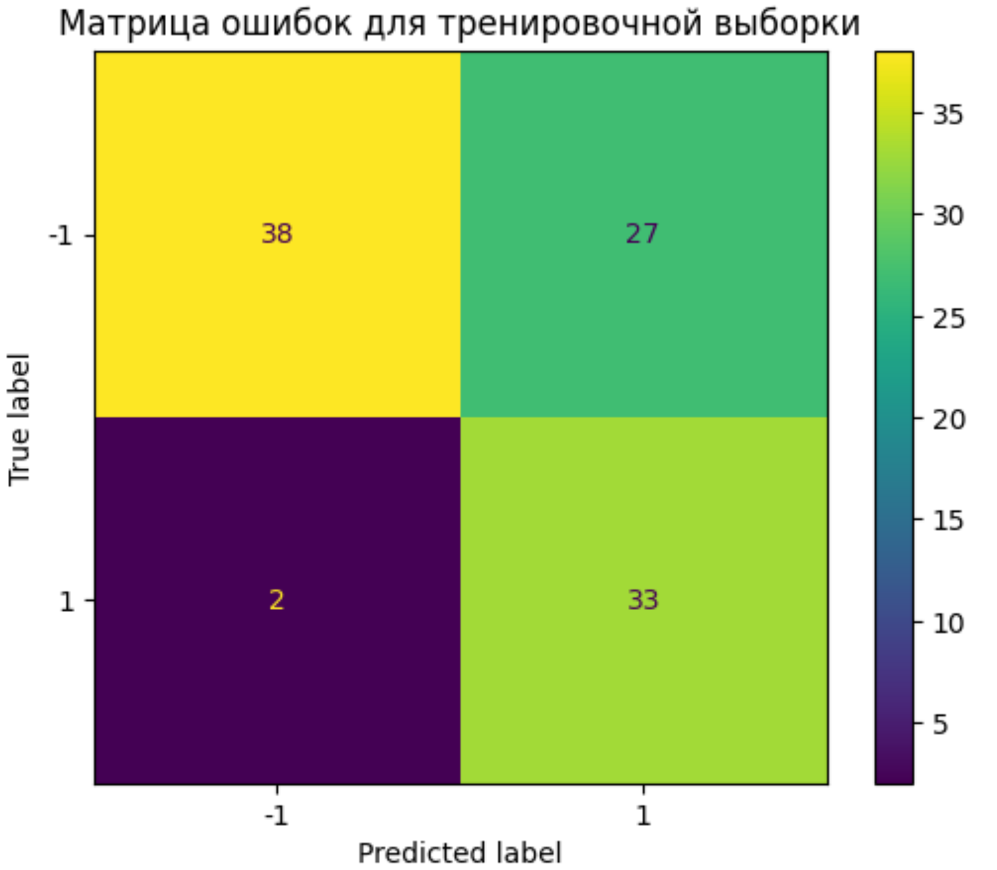


```
Матрица ошибок, полученная методом confusion_matrix
 [[22 13]
 [ 1 14]]
```

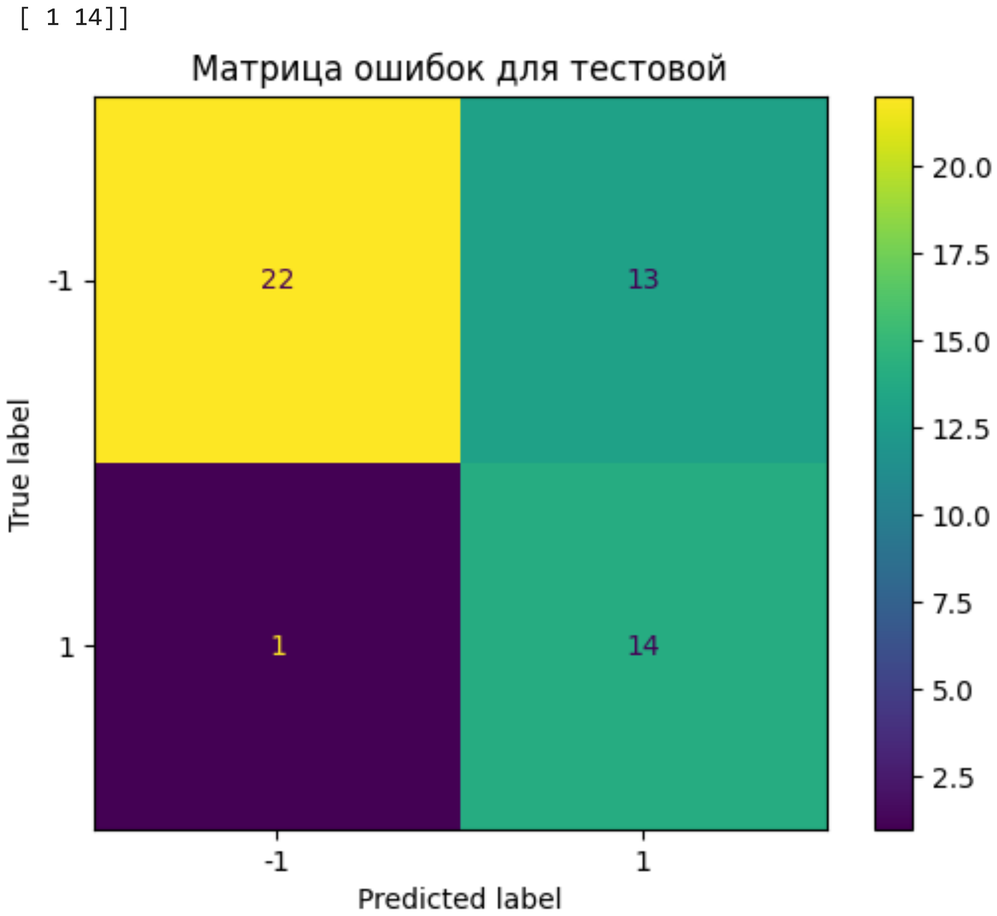

In [82]:
```
### График гиперплоскости
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)

w = svm_2.w

xgrid, ygrid = np.meshgrid(x1, x2)
z = w[0] + w[2] * xgrid + w[1]*ygrid


# Обучающая выборка
fig = plt.figure(figsize=(12, 12))


ax = fig.add_subplot(221)
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")

ax.set_title('Обучающая выборка')


legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)


#тестовая выборка
ax = fig.add_subplot(222)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")




legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.set_title('Тестовая выборка')
ax.add_artist(legend1)


plt.show()
```

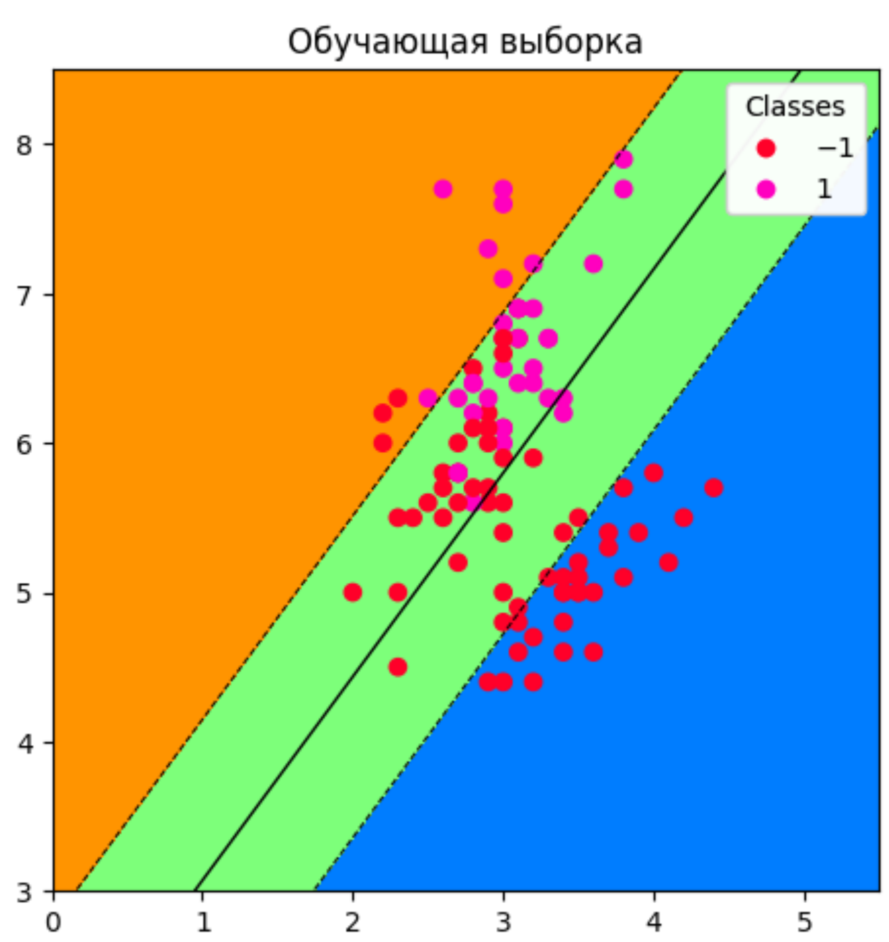

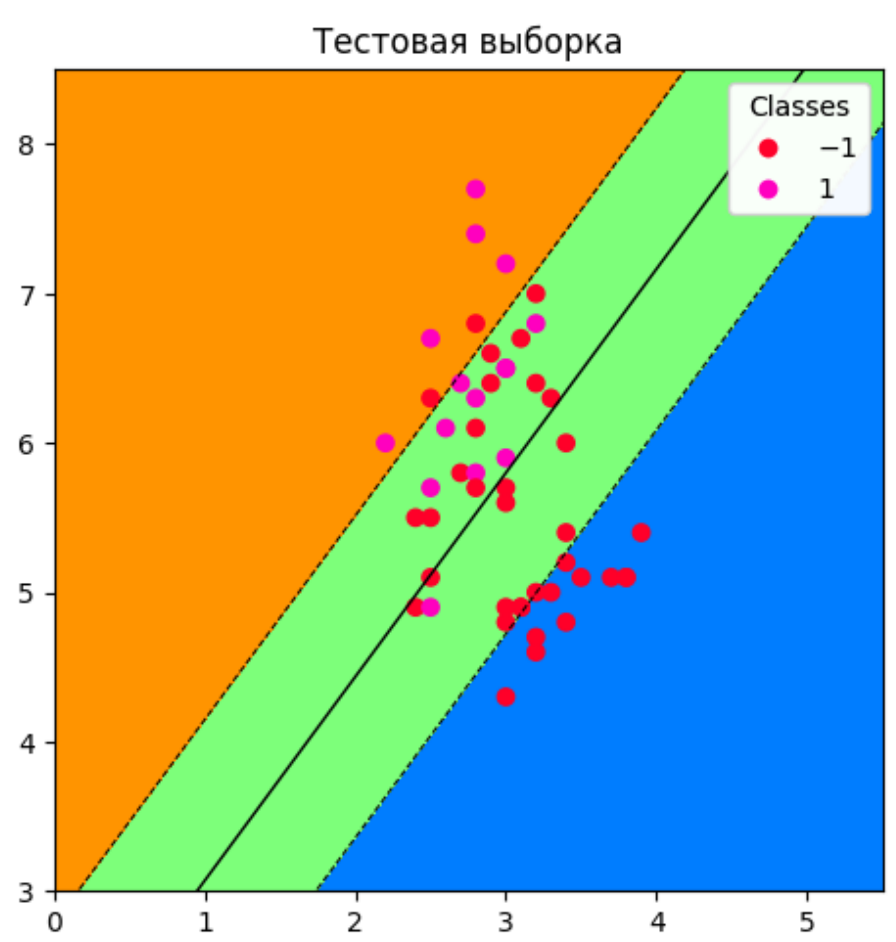

По итогу все равно модель не сильно хорошая, рандомит только так из-за того что выборка линейно неразделима

Третья модель

In [87]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=122)
svm_3 = SupportVectorMachine(X_train, y_train, min_iterations=10000, strategy='mini-batch', batch_size=10)
w_ = svm_3.fit()
```

In [88]:
```
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
0.464 + 0.027 x1 + -0.519 x2 = 0
```

In [89]:
```
cntr_svm_3 = Counter(X_train, X_test, y_train, y_test, svm_3)
cntr_svm_3.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.670
precision: 0.000
recall: 0.000
f1: 0.000

Метрики для тестовой выборки
accuracy: 0.660
precision: 0.000
recall: 0.000
f1: 0.000
Матрица ошибок, полученная методом confusion_matrix
 [[67  0]
 [33  0]]
C:\Users\Andrey\PycharmProjects\pythonProject\.venv\Lib\site-packages\sklearn\metrics\_classification.py:1531: UndefinedMetricWarnin
g: Precision is ill-defined and being set to 0.0 due to no predicted samples. Use `zero_division` parameter to control this behavio
r.
  _warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
C:\Users\Andrey\PycharmProjects\pythonProject\.venv\Lib\site-packages\sklearn\metrics\_classification.py:1531: UndefinedMetricWarnin
g: Precision is ill-defined and being set to 0.0 due to no predicted samples. Use `zero_division` parameter to control this behavio
r.
  _warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
```

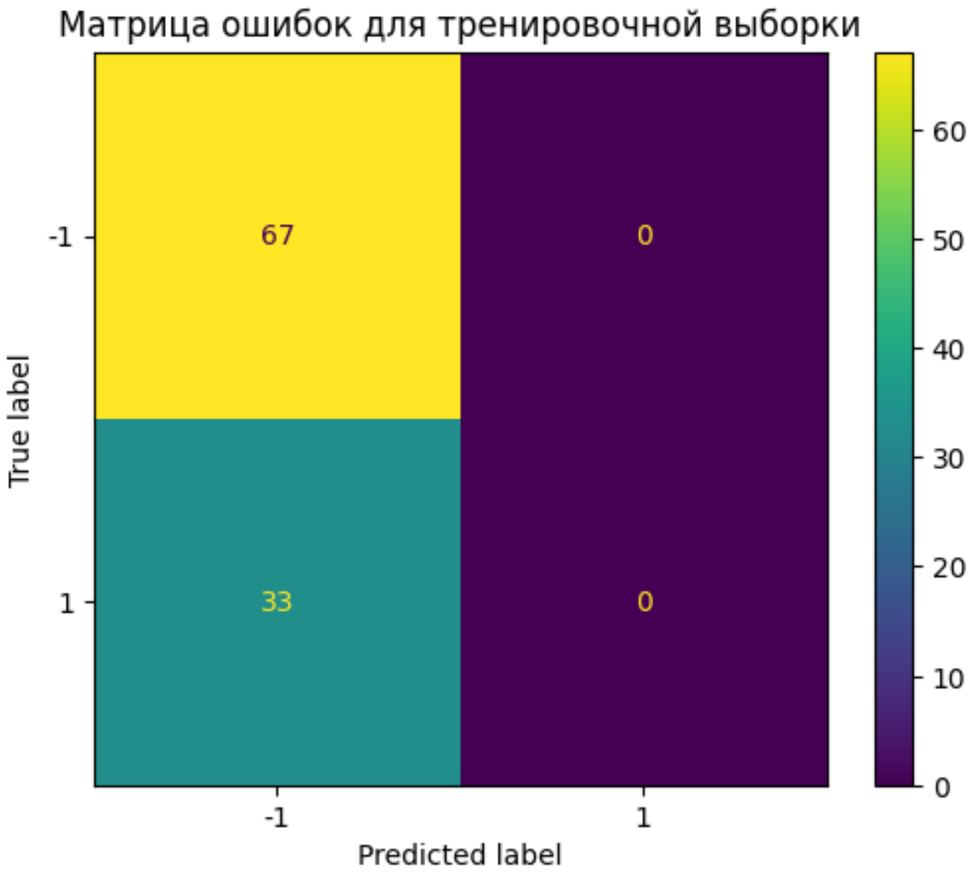


```
Матрица ошибок, полученная методом confusion_matrix
 [[33  0]
 [17  0]]
```

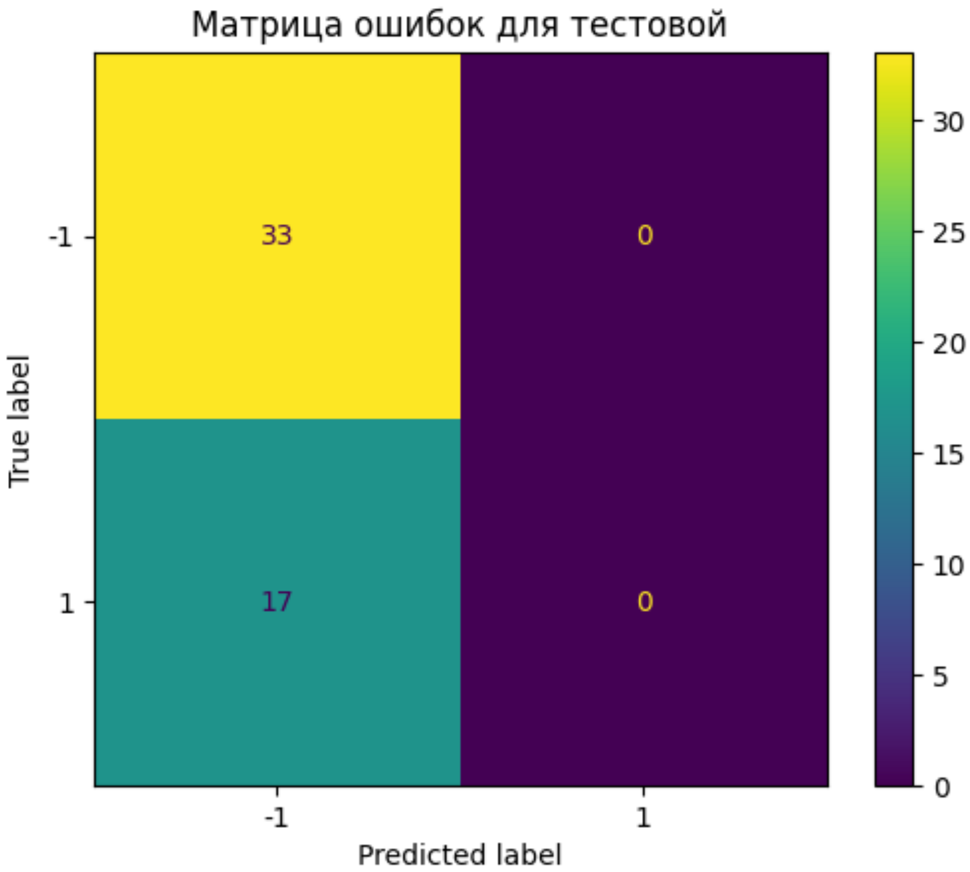

In [91]:
```
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)

w = svm_3.w

xgrid, ygrid = np.meshgrid(x1, x2)
z = w[0] + w[2] * xgrid + w[1]*ygrid


# Обучающая выборка
fig = plt.figure(figsize=(12, 12))
```

```
ax = fig.add_subplot(221)
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")

ax.set_title('Обучающая выборка')


legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)


#тестовая выборка
ax = fig.add_subplot(222)


plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
plt.contourf(x1, x2, z, cmap="jet", levels=[-70,-1, 1, 70], linestyles=["--", '-', '--'])
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)

scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")




legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.set_title('Тестовая выборка')
ax.add_artist(legend1)


plt.show()
```

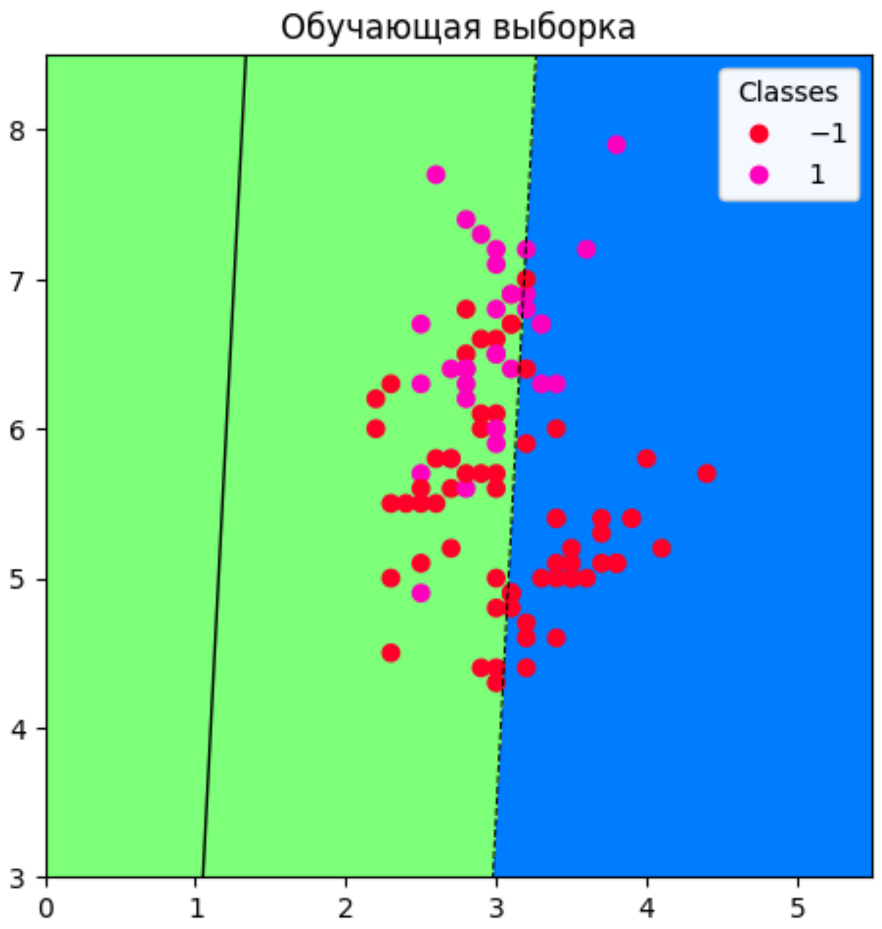

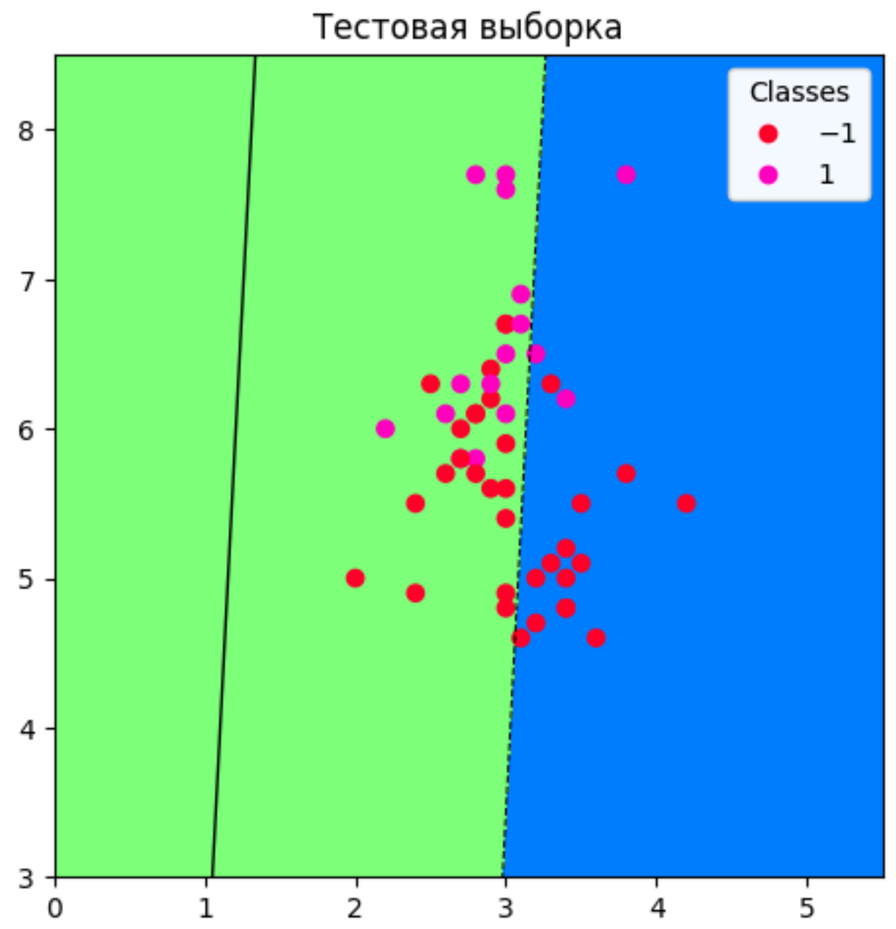

Из-за линейной неразделимости выборки модель решила, стать константной, что ж это ее выбор мы не в праве ее осуждать за это

Задание 4

Текст задания

Сравните итоги выполненных ранее трёх попыток обучения. Сделайте выводы.

Пояснения

По итогу везде получилось так, что модель обучалось случайно не имея каких-то конкретных закономерностей связано с тем что выборка линейно неразделима, так что мы теоретически не можем получить хорошие метрики

Задание 5

Текст задания

Реализуйте задачу классификации с квадратичной функцией SVM на последнем наборе обучающей и тестовой выборок (также диаграммой рассеяния и линией раздела).

Уже реализована, так что воспользуемся ей сразу

Решение

Используем последнее разбиение для обучения новой модели

In [92]:
```
qsvm = QuadraSupportVectorMachine(X_train, y_train, h=0.0005, min_iterations=30000) #инициализация метода
qsvm.init_r() #для перехода в новое пространство
w_ = qsvm.fit()
```

In [93]:
```
print("Уравнение разделяющей гиперплоскости:")
print(f"{w_[0]:.03f}" + "".join([f" + {w_[i]:.03f} x{i}" for i in range(1, len(w_))]) + " = 0")
```

```
Уравнение разделяющей гиперплоскости:
-3.469 + -9.299 x1 + 0.009 x2 + -5.291 x3 + -14.619 x4 + 10.656 x5 = 0
```

Метрики

In [94]:
```
cntr_qsvm = Counter(X_train, X_test, y_train, y_test, qsvm)
cntr_qsvm.try_model()
```

```
Метрики для тренировочной выборки
accuracy: 0.820
precision: 0.683
recall: 0.848
f1: 0.757

Метрики для тестовой выборки
accuracy: 0.800
precision: 0.667
recall: 0.824
f1: 0.737
Матрица ошибок, полученная методом confusion_matrix
 [[54 13]
 [ 5 28]]
```

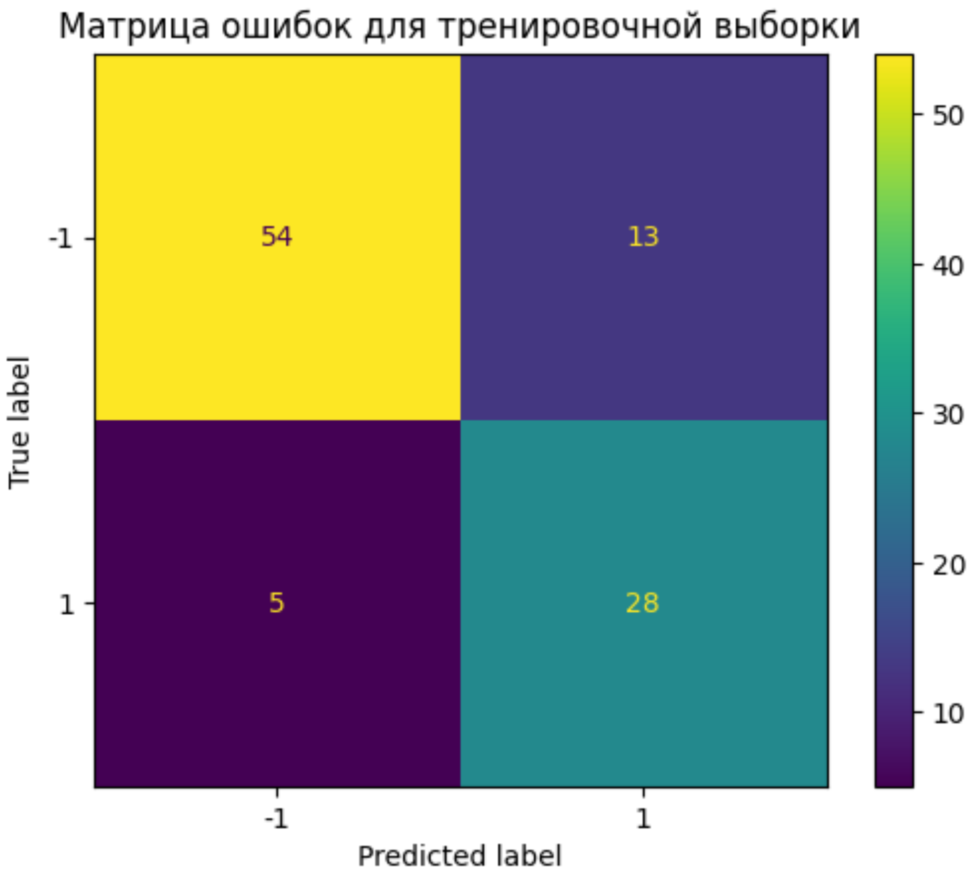


```
Матрица ошибок, полученная методом confusion_matrix
 [[26  7]
 [ 3 14]]
```

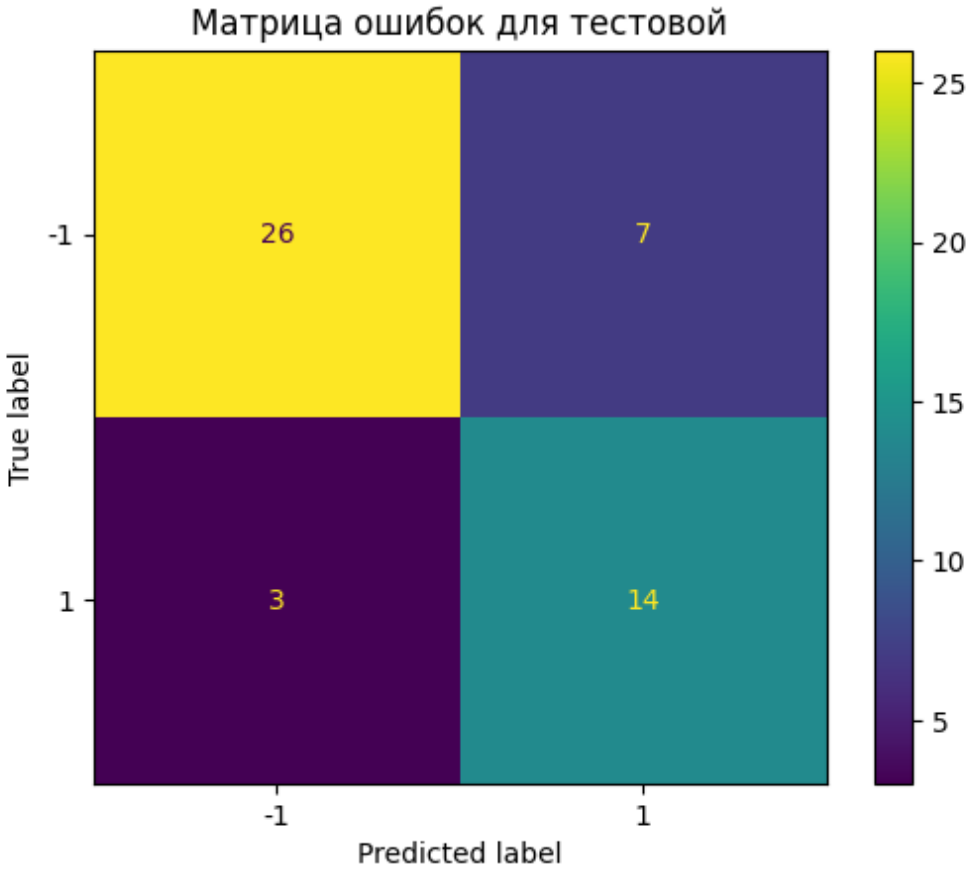

Линии уровня гиперплоскости

In [106…

```
x1 = np.arange(-15, 20, 0.05)
x2 = np.arange(-15, 20, 0.05)


xgrid, ygrid = np.meshgrid(x1, x2)

w = qsvm.w
z = w[0] + w[1]*xgrid**2 + w[2]*ygrid**2 + w[3]*xgrid + w[4]*ygrid + w[5]*xgrid*ygrid

fig = plt.figure(figsize=(12, 12))
ax = fig.add_subplot(221)

plt.contourf(x1, x2, z, cmap="jet", levels=[-120, -75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40, 80])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_test[:, 1], X_test[:, 0], c=y_test, cmap="gist_rainbow", marker="o")
ax.set_aspect('equal', adjustable='box')
ax.set_title('Тестовая выборка')
plt.xlim(1, 4.5)
plt.ylim(4, 8.5)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")

ax = fig.add_subplot(222)


plt.contourf(x1, x2, z, cmap="jet", levels=[-130, -75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40, 80])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_train[:, 1], X_train[:, 0], c=y_train, cmap="gist_rainbow", marker="o")
plt.xlim(1, 4.5)
plt.ylim(4, 8.5)
ax.set_aspect('equal', adjustable='box')
ax.set_title('Обучающая выборка')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)


plt.show()
```

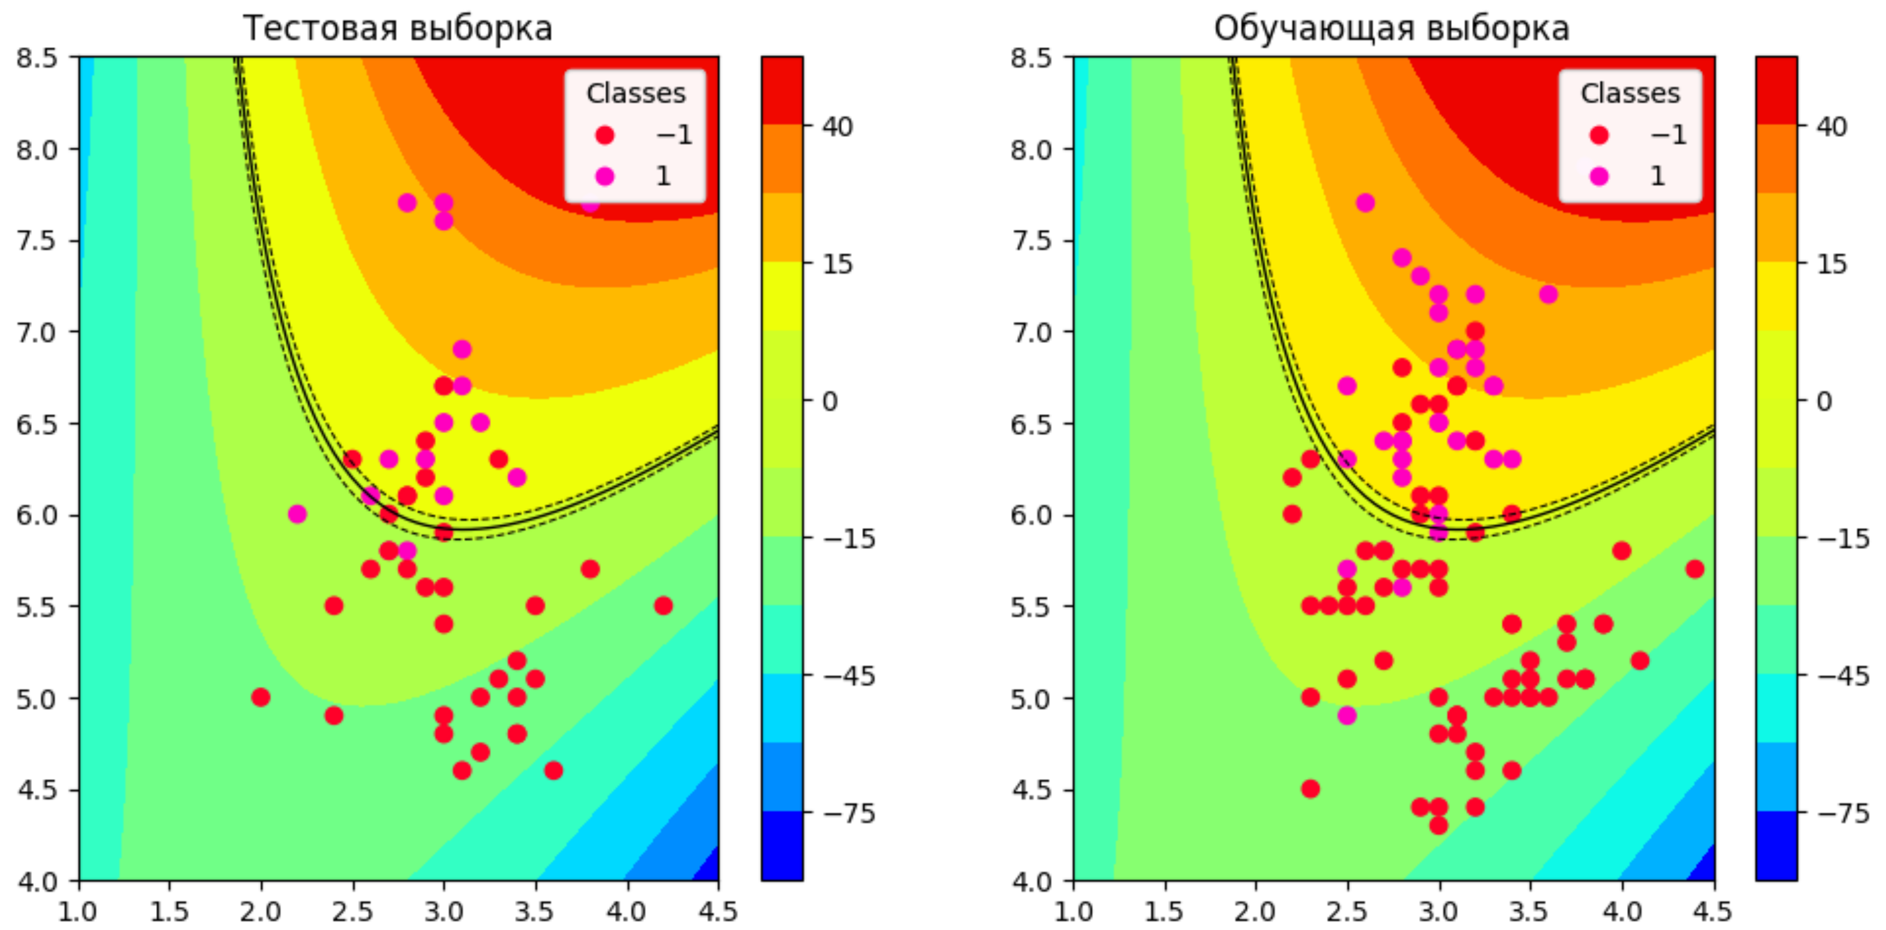

Выводы по svm с квадратичным ядром

Намного лучше справляется с задачей обобщения, и даже метрики неплохие, можно сделать вывод, что модель не так уж плоха и с помощью нее уже можно выполнить седьмое задание

Задание 6

Текст задания

Сравните точность классификации на тестовой выборке с линейной SVM. Объясните результат.

Решение

Точность классификации отличается, казалось бы, несильно, однако точность 1 и любая меньше 1 - абсолютно разные результаты.

В обобщающей способности линейного классификатора нет сомнений поскольку это самая простая модель, за исключением константной, которая только может быть.

Однако квадратичная могла и сильно подстроиться под ту одну точку, хотя в реальных данных там может оказаться много точек другого класса.

Может оказаться так, что все-таки там природно розовые точки, потому можно сделать вывод, что обе модели хорошо справились со своей задачей

Задание 7

Текст задания

Определите сорт 20 объектов из дополнительной выборки (файл «Dop.csv»). Качество определения сорта проверит преподаватель.

In [107…

```
y_dop = pd.DataFrame()
X_dop = df_dop[["Sepal.L", "Petal.L"]].to_numpy()  #отбираем нужные признаки

y_pred_qsvm_dop = qsvm.predict(X_dop)
y_pred_svm_dop = svm_3.predict(X_dop)
```

In [108…

```
y_pred_qsvm_dop = qsvm.predict(X_dop)
y_pred_svm_dop = svm_3.predict(X_dop)
```

Ответы

In [109…

```
ans = pd.DataFrame()
ans["SVM Квадратичное ядро"] = y_pred_qsvm_dop[:, 0]  #Ответы по модели с квадратичным ядром
ans["SVM линейное ядро"] = y_pred_svm_dop[:, 0]  # Ответы по линейной модели
ans["Совпадение ответов"] = ans["SVM Квадратичное ядро"] == ans["SVM линейное ядро"]

ans
```

Out[109…

	SVM Квадратичное ядро	SVM линейное ядро	Совпадение ответов
0	-1.0	-1.0	True
1	-1.0	-1.0	True
2	-1.0	-1.0	True
3	-1.0	-1.0	True
4	-1.0	-1.0	True
5	-1.0	-1.0	True
6	-1.0	-1.0	True
7	-1.0	-1.0	True
8	-1.0	-1.0	True
9	-1.0	-1.0	True
10	-1.0	-1.0	True
11	-1.0	-1.0	True
12	-1.0	-1.0	True
13	-1.0	-1.0	True
14	-1.0	-1.0	True
15	-1.0	-1.0	True
16	-1.0	-1.0	True
17	-1.0	-1.0	True
18	-1.0	-1.0	True
19	-1.0	-1.0	True

Пояснение к ответам

Неожиданные результаты более-менее интепретируемая модель и константная сошлись в едином мнении

In [112…

```
##  Визуализация ответов
x1 = np.arange(-10, 15, 0.05)
x2 = np.arange(-10, 15, 0.05)

xgrid, ygrid = np.meshgrid(x1, x2)

w = qsvm.w
z = w[0] + w[1] * xgrid ** 2 + w[2] * ygrid ** 2 + w[3] * xgrid + w[4] * ygrid + w[5] * xgrid * ygrid

fig = plt.figure(figsize=(12, 12))
```

```
ax = fig.add_subplot(221)

plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_dop[:, 1], X_dop[:, 0], c=y_pred_qsvm_dop, cmap="gist_rainbow", marker="o")
ax.set_aspect('equal', adjustable='box')
ax.set_title('SVM с квадратичным ядром')
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)
legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)

ax = fig.add_subplot(222)
w = svm_3.w
z = w[0] + w[2] * xgrid + w[1] * ygrid

plt.contourf(x1, x2, z, cmap="jet", levels=[-75, -60, -45, -30, -15, -1, 0, 1, 15, 30, 40])
plt.colorbar()
plt.contour(x1, x2, z, colors="black", levels=[-1, 0, 1], linewidths=[0.75, 1, 0.75], linestyles=["--", '-', '--'])
scatter = ax.scatter(X_dop[:, 1], X_dop[:, 0], c=y_pred_svm_dop, cmap="gist_rainbow", marker="o")
plt.xlim(0, 5.5)
plt.ylim(3, 8.5)
ax.set_aspect('equal', adjustable='box')
ax.set_title('SVM с линейным ядром')

legend1 = ax.legend(*scatter.legend_elements(),
                    loc="upper right", title="Classes")
ax.add_artist(legend1)
print(z.shape)

plt.show()
```

```
(500, 500)
```

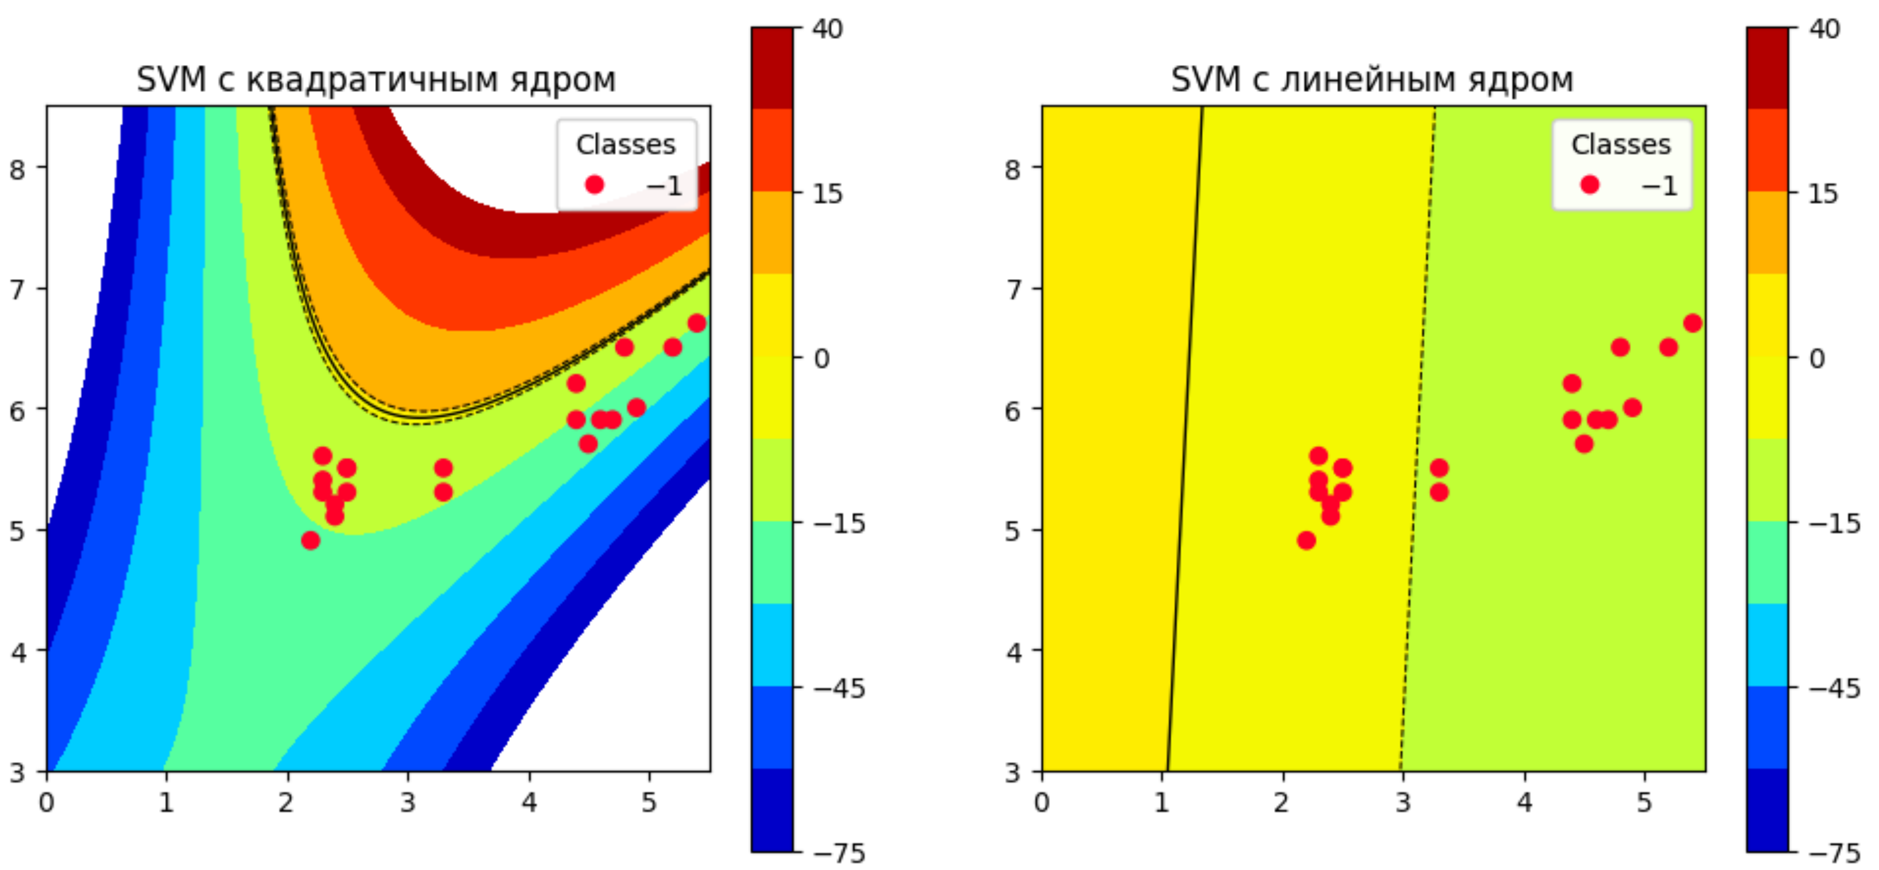

Модели сошлись к единому мнению, константная и квадратичная. Среди них нет virginica. По факту у квадратичной модели есть четкое обоснование и интерпретация, в то время как у линейной своя философия

Финальный вывод для 3 задания

Понятно почему так произошло, из-за линейной неразделимости выборки. Используя квадратичное ядро нам удалось избежать проблем связанных с этим, конечно из-за наложения классов друг на друга невозможно описать линию разделения между ними

Самый финальный вывод

Нам удалось изучить SVM и его ядра, а так же посмотреть его поведение в различных ситуациях. Понять математику ядер и функции потерь. Адаптировать SVM для градиентного спуска.

Конец